REPUBLIQUE ALGERIENNE DEMOCRATIQUE ET POPULAIRE

MINISTERE DE L'ENSEIGNEMENT SUPERIEUR ET DE
LA RECHERCHE SCIENTIFIQUE

UNIVERSITÉ MOULOUD MAMMERI DE TIZI-OUZOU

FACULTÉ DE GÉNIE ELECTRIQUE ET D'INFORMATIQUE

DÉPARTEMENT D'INFORMATIQUE

Mémoire de fin d'études

En vue de l'obtention du diplôme de master en informatique

Option : *Systèmes d'information*

Thème :

Application des techniques de data mining pour améliorer l'efficacité des campagnes marketing

Réalisé par :

HAMMA Mohamed Ouamer

RAMDANI Hamid

Encadré par :

SEGHIRI Narimene

Promotion 2018/2019

Dédicaces

Je dédie ce modeste travail à :

A ma très chère Mère et mon très cher Père, qui m'ont soutenue pendant toutes ces années, ils étaient –et ils seront toujours – ma source de motivation ; je leur remercie infiniment pour tous leurs efforts investis. Puisse Dieu, le très haut vous accorder santé, bonheur et longue vie et faire en sorte que jamais je ne vous déçoive.

A tous mes chers grands-pères et chères grands-mères,

A tous mes chères sœurs et chers frères, aucun mot ne pourra exprimer ma reconnaissance envers eux, et tous leurs actes envers moi,

A toute ma famille,

A tous mes chers amis

A tous ceux que j'aime et qui m'aiment,
Mohamed Ouamer

Dédicaces

Je dédie ce modeste travail à :

A mes très chers parents auxquels je souhaite une longue vie pleine de bonheur

A mes frères, ainsi qu'à toute ma famille

A tous ceux qui m'aiment

A toi Mohamed et à toute ta famille

Hamid

Remerciements

Avant tout, nous tenons à remercier Allah le tout Puissant et Miséricordieux qui nous a donné le courage, la patience et la motivation pour mener à bien ce modeste travail.

On tient à adresser toute notre reconnaissance aux personnes avec lesquelles nous avons pu échanger des informations et des conseils pour la réalisation de ce projet.

On veut ensuite remercier notre encadreur, Mme SEGHIRI pour son encadrement et ses remarques qui nous ont servi pour la bonne réalisation du projet.

Nous n'oublions pas nos enseignants qui nous ont accompagné durant nos cinq années d'études, et les remercie pour tous leurs efforts fournis. On remercie tous les membres du jury pour avoir accepté de lire et d'évaluer ce travail.

On finit par remercier nos amis, pour leurs remarques et aides, ainsi que toute autre personne qui a collaboré, de près ou de loin, de manière directe ou indirecte, à la réalisation du projet.

Résumé

A l'ère du Big Data ou l'espace de stockage des données n'est plus vraiment un problème, toutes les entreprises veulent désormais tirer parti de leurs grands volumes de données. Ces données peuvent les aider à comprendre les environnements interne (RH, organisation ...), leur environnement externe (type de clients, parcours clients, image de l'entreprise) et à anticiper les phénomènes qui s'y rattachent. Elles deviennent par conséquent une grande richesse si elles sont bien exploitées, c'est justement l'objectif du data mining.

Les études de Data Mining menées dans les entreprises ont des objectifs très variées. Nous nous intéressons à l'étude du comportement des clients de l'entreprise, cette étude nous permet de répondre à leurs exigences ainsi être en mesure de les cibler avec des offres personnalisées qui s'adaptent au mieux à leurs exigences exprimés ou constatés.

L'objectif à travers ce projet est la mise en place d'un système permettant de récupérer et de stocker les données des clients, d'effectuer des analyses comportementales sur ses données grâce à des techniques de data mining et de visualiser ses données sur des tableaux de bord interactifs, pour ainsi utiliser ses résultats pour l'amélioration de l'efficacité des compagnes marketing (e-mailing, sms, réseaux sociaux ...) grâce au ciblage des clients à fort potentiel et la personnalisation des offres commerciales.

Mots clés : Data mining, CRISP-DM, Comportment client, clustering, classification, marketing, Tableau de board.

Abstract

In the era of Big Data where data storage is no longer a problem, all companies now want to take advantage of their large volumes of data. This data can help them understand the internal environments (HR, organization ...), their external environment (type of customers, customer journey, image of the company) and anticipate the phenomena associated with it. They therefore become a great asset if they are well exploited, this is precisely the objective of data mining.

Data Mining studies carried out in companies have very varied objectives. We are interested in the study of the behavior of customers of the company, this study allows us to meet their requirements so be able to target them with personalized offers that best adapt to their requirements expressed or observed.

The objective through this project is the establishment of a system allowing to recover and store the data of the customers, to carry out behavioral analyzes on its data thanks to techniques of data mining and to visualize its data on interactive dashboards, to use its results to improve the effectiveness of marketing partners (e-mailing, sms, social networks ...) thanks to targeting high-potential customers and personalizing commercial offers.

Keywords: Data mining, CRISP-DM, Client behavior, clustering, classification, marketing, Board table.

ملخص

في عصر البيانات الضخمة حيث لم يعد تخزين البيانات مشكلة، تريد جميع الشركات الآن الاستفادة من كميات البيانات الكبيرة. يمكن أن تساعدهم هذه البيانات على فهم البيئات الداخلية (الموارد البشرية، المنظمة، إلخ)، وبيئتهم الخارجية (نوع العملاء، ورحلات العملاء، وصورة الشركة) وتوقع الظواهر ذات الصلة. وبالتالي يصبحون ثروة كبيرة إذا تم استغلالهم بشكل جيد، وهذا هو بالضبط هدف استخراج البيانات.

يعد استخراج البيانات حقلًا متعدد التخصصات يسمح، من كمية كبيرة جدًا من البيانات الخام، باستخراج معلومات مخفية وذات صلة وغير معروفة سابقًا. يكمن التحدي في الإعداد الناجح للبيانات ومعالجتها وتحليلها بهدف تحويلها إلى أدوات عملية لدعم المعرفة ودعم اتخاذ القرار للشركات.

دراسات التنقيب عن البيانات التي أجريت في الشركات لها أهداف متنوعة للغاية نحن مهتمون بالتحليل السلوكي لعملاء الشركة بفضل تقنيات استخراج البيانات وتصور نتائج هذه التحليلات على لوحات المعلومات، مما سيتيح تحسين فعالية الحملات التسويقية (هـ) -البريد الإلكتروني، والرسائل القصيرة، والشبكات الاجتماعية ...) بفضل استهداف العملاء ذوي الإمكانات العالية وتخصيص العروض التجارية.

كلمات مفتاحية : التنقيب في البيانات، CRISP-DM، تصرفات الزبائن، تجميع، التصنيف، التسويق، لوحات القيادة الذكية.

Table des matières

INTRODUCTION GENERALE 1
1 Contexte 2
2 Problématique 2
3 Objectif 3
4 Organisation du rapport 4
CHAPITRE I : GENERALITES SUR LE DATA MINING 5
1 Introduction 6
2 Le processus ECD 6
2.1 Le processus ECD 6
2.2 Etapes du processus ECD 6
2.2.1 Positionnement du problème 7
2.2.2 Collecte et sélection des données 7
2.2.3 Nettoyage des données 7
2.2.4 Actions sur les attributs 8
2.2.5 Construction du modèle (datamining) 8
2.2.5.1 Définition du data mining 8
2.2.6 Evaluation du résultat 9
2.2.7 Intégration de la connaissance 9
2.3 Tâches de data mining 9
2.4 Techniques de data mining 10
2.5 Domaines d'application 10
2.5.1 Le marketing 10
2.5.2 Banques et finances : 11
2.5.3 Médical et pharmaceutique 11
2.6 Difficultés de data mining 11
3 Conclusion 12
CHAPITRE II : LES TECHNIQUES DE DATA MINING 13
1 Introduction 14
2 La classification automatique supervisée 14
2.1 Problématique 14
2.2 Les algorithmes de classification 14
2.2.1 Les arbres de décision 14

2.2.1.1 Présentation de la méthode : 14
2.2.1.2 Description de l'algorithme : 15
2.2.1.3 Avantages et inconvénients 16
2.2.2 Les machines à support de vecteurs (SVM) 17
2.2.2.1 Présentation de la méthode : 17
2.2.2.2 Avantages et inconvénients : 18
2.2.3 Le plus proche voisin : 19
2.2.3.1 Description de la méthode : 19
2.2.3.2 Avantages et inconvénients : 19
3 La classification automatique non supervisée 19
3.1 Définition 19
3.2 Les algorithmes de clustering 20
3.2.1 Les algorithmes de partitionnement 20
3.2.1.1 L'algorithme K-means 20
3.2.1.2 Algorithme de clustering hiérarchique 21
4 Conclusion 22
CHAPITRE III : APPLICATION DU DATA MINING EN MARKETING ET GESTION DE LA RELATION CLIENT 23
1 Introduction 24
2 Définition du marketing : 24
3 Différentes utilisations du DM en marketing 25
3.1 La prospection 25
3.1.1 Identifier les bonnes perspectives 25
3.1.2 Choisir un canal de communication 25
3.1.3 Choisir les messages appropriés 26
3.2 Data Mining pour choisir le meilleur endroit pour annoncer 26
3.2.1 Qui correspond au profil ? 26
3.3 Data Mining pour améliorer les campagnes de marketing direct 26
3.3.1 Modélisation de la réponse : 27
3.3.2 Optimiser la rentabilité de la campagne 27
3.3.2.1 Comment le modèle affecte la rentabilité ? 27

3.3.3 Atteindre les personnes les plus influencées par le message 28
3.3.4 Analyse de la réponse différentielle 28
3.4 Data Mining pour la gestion de la relation client 28
3.4.1 Faire correspondre les campagnes aux clients 29
3.4.2 Segmentation de la clientèle 29
3.4.2.1 Trouver des segments comportementaux 30
3.4.2.2 Lier des segments de recherche de marché aux données comportementales 30
4 Conclusion 30
CHAPITRE IV : CONCEPTION ET MISE EN ŒUVRE DE LA SOLUTION 32
1 Introduction 33
2 Analyse des besoins 33
2.1 Définition des besoins 33
2.1.1 Besoins fonctionnels 33
2.1.1.1 L'analyse du comportement des clients 33
2.1.1.2 La visualisation des résultats d'analyses 34
2.1.2 Besoins techniques 34
2.2 Définition des cas d'utilisation 34
2.2.1 Vue Décideur 34
2.2.2 Vue Développeur 37
2.2.3 Vue Analyste 39
2.2.4 Vue Administrateur 42
2.3 Analyse du comportement du client 45
2.3.1 Analyse des consommations des clients 46
2.3.2 Analyse des souscriptions des clients 46
2.3.3 Analyse du churn des clients 47
2.4 Indicateurs clés de performance 48
2.4.1 Indicateurs de l'analyse des consommations des clients 48
2.4.2 Indicateurs de l'analyse des souscriptions 49
2.4.3 Indicateurs de l'analyse de churn 50
3 Méthodologie de conception de Data mining 50
3.1 La méthode CRISP-DM 50
3.2 Description de la solution 51

3.3 Nettoyage des données 53
3.3.1 Identification des sources de données 54
3.3.2 Extraction de données 54
3.3.3 Transformation des données 54
3.3.4 Chargement des données 55
3.4 Stockage des données 55
3.5 Module d'analyse du comportement client 58
3.5.1 Modèle de clustering 58
3.5.1.1 Sélection des attributs 59
3.5.1.2 Analyse de corrélation 60
3.5.1.3 Choix des algorithmes 60
3.5.1.4 Sélection du nombre optimal de clusters 61
3.5.1.5 Evaluation 62
3.5.2 Modèle de prédiction 62
3.5.2.1 Sélection des attributs 63
3.5.2.2 Choix des algorithmes 64
3.5.2.3 Echantillonnage de l'ensemble des données 65
3.5.2.4 Apprentissage du modèle prédictif 66
3.5.2.5 Evaluation 66
3.6 Visualisation : tableau de bord 66
3.6.1 Méthodes de mise en œuvre des tableaux de bords 66
3.6.2 Définition des indicateurs de performance (KPI) 67
4 Sécurité du système 71
5 Conclusion 72
CHAPITRE V : REALISATION ET TESTS 73
1 Introduction 74
2 Présentation des technologies utilisées 74
2.1 Data mining : Python 74
2.1.1 Pandas : 74
2.1.2 Numpy : 75
2.1.3 Matplotlib : 75

2.1.4 SciPy : 75
2.1.5 Scikit-Learn : 75
2.1.6 Bokeh 76
2.1.7 Django 76
2.1.8 Jupyter notebook 76
2.2 SGBD : MongoDB 76
3 Présentation de la solution 77
3.1 Implémentation de l'ETL 78
3.2 Implémentation des modèles de Data mining 79
3.2.1 Modèle de clustering 79
3.2.2 Modèle de prédiction 84
3.3 Tableau de bord 85
4 Sécurité du système 91
5 Conclusion 91
CONCLUSION GENERALE 92
Bibliographie 96
ANNEXES 99
Annexe A : Méthodes de conception de Data mining 100
Annexe B : Méthodes de conception de tableau de bord 104
Annexe C : les différentes mesures d'évaluation 107

Table des figures

Figure II-1 : Arbre de décision[10] 15
Figure II-2 : Illustration de la marge maximale d'un hyperplan séparant deux classes[11] ... 18
Figure IV-1 : Diagramme des cas d'utilisations : vue décideur 35
Figure IV-2 : Diagramme d'activité du CU : Modifier paramètre 37
Figure IV-3 : Diagramme des cas d'utilisations : vue développeur 38
Figure IV-4 : Diagramme des cas d'utilisation : vue analyste 39
Figure IV-5 : Diagramme d'activité du CU : Ajouter indicateur 42
Figure IV-6 : Diagramme des cas d'utilisations : Vue Administrateur 43
Figure IV-7 : Diagramme d'activité du CU : Gestion des ressources 45
Figure IV-8 : Les types de consommations client 46
Figure IV-9 : Les types de souscriptions 47
Figure IV-10 : Méthode CRISP-DM 51
Figure IV-11 : Architecture globale de la solution 52
Figure IV-12 : phase de nettoyage des données 53
Figure IV-13 : Processus ETL 54
Figure IV-14 : Processus de chargement des données 55
Figure IV-15 : Exemple de schéma de la base de données SQL 56
Figure IV-16 : structure d'un document de la collection client 57
Figure IV-17 : Diagramme d'activité qui illustre le processus de clustering 59
Figure IV-18 : Exemple de résultat de la méthode Elbow 62
Figure IV-19 : Diagramme d'activité qui illustre le processus de prédiction 63
Figure IV-20 : Algorithmes de prédiction utilisé dans le churn[24] 64
Figure IV-21 : Echantillonnage de l'ensemble des données 66
Figure IV-22 : Diagramme de séquence représentant le processus d'accès aux données en utilisant un ticket. 72
Figure V-1 : Architecture technique de la solution proposée 78
Figure V-2 : chargement des données dans la BDD 79
Figure V-3 : Matrice de corrélation 80
Figure V-4 : Corrélogramme de résultats de corrélations 80
Figure V-5 : Résultat de la méthode Elbow 81
Figure V-6 : Les résultats de validation pour le clustering 83

Figure V-7 : Les résultats de la mesure DB 83
Figure V-8 : Résultat de la mesure de Silhouette 83
Figure V-9 : Segmentation client par rapport aux revenus 86
Figure V-10 : Segmentation client par rapport au trafic 87
Figure V-11 : Segmentation client par rapport aux revenus 88
Figure V-12 : Indicateurs clés du taux de consommation Prépayée et Postpayés 88
Figure V-13 : Indicateurs clés du taux de churn des clients Prépayée et postpaid 89
Figure V-14 : Indicateurs clés du taux de churn des clients Prépayée et Postpaid 90
Figure V-15 : Tableau de bord concernant la consommation client 90
Figure A-1 : Méthode CRISP-DM (Agard & Kusiak, 2005) 100
Figure A-2 : Les étapes de la méthode SEMMA 102
Figure B-1 : Les étapes de la méthode BSC 105

Liste des tableaux

Tableau II-1 : les avantages et inconvénients des arbres de décision 16
Tableau II-2 : Les avantages et inconvénients du SVM 18
Tableau II-3 : Les avantages et inconvénients du plus proche voisin 19
Tableau II-4 : Avantages et inconvénients du K-means 21
Tableau II-5 : Avantages et inconvénients du clustering hiérarchique 22
Tableau IV-1 : Liste des cas d'utilisation du décideur 35
Tableau IV-2 : Documentation CU : Consulter indicateur 36
Tableau IV-3 : Documentation CU : Modifier paramètre 36
Tableau IV-4 : Liste des cas d'utilisation du développeur 38
Tableau IV-5 : Documentation CU : Importer les données 38
Tableau IV-6 : Liste des cas d'utilisation de l'analyste 40
Tableau IV-7 : Documentation CU : Ajouter indicateur 40
Tableau IV-8 : Documentation CU : Créer un rapport 41
Tableau IV-9 : Liste des cas d'utilisation de l'administrateur 43
Tableau IV-10 : Documentation CU : Gestion des utilisateurs 43
Tableau IV-11 : Documentation CU : Gestion des ressources 44
Tableau IV-12 : Indicateurs de l'analyse des consommations des clients 48
Tableau IV-13 : Indicateurs de l'analyse des souscriptions des clients 49
Tableau IV-14 : Indicateurs de l'analyse de churn des clients 50
Tableau IV-15 : les attributs sélectionnés pour le clustering 59
Tableau IV-16 : Les attributs sélectionnés pour le modèle prédictif 64
Tableau IV-17 : Documentation du KPI : Taux de consommation Voix 68
Tableau IV-18 : Documentation du KPI : Taux de consommation on-net 68
Tableau IV-19 : Documentation du KPI : Taux de consommation off-net 68
Tableau IV-20 : Documentation du KPI : Taux de consommation international 68
Tableau IV-21 : Documentation du KPI : Taux de consommation roaming 69
Tableau IV-22 : Documentation du KPI : taux de consommation Data 69
Tableau IV-23 : Documentation du KPI : taux de consommation Sms 69
Tableau IV-24 : Documentation du KPI : taux de souscriptions mensuelle 70
Tableau IV-25 : Documentation du KPI : taux de souscriptions journalière 70
Tableau IV-26 : Documentation du KPI : taux de souscriptions par souscripteurs 70

Tableau IV-27 : Documentation du KPI : taux de churn des clients 70
Tableau V-1 : Evaluation de la prédiction de churn 85
Tableau A-1 : les avantages et inconvénients de chaque méthode 103
Tableau B-1 : analyse comparative des méthodes GIMSI et BSC. 106
Tableau C-1 : Table de confusion..... 109

Table des abreviation

AdaBoost	Adaptive Boosting
BDD	Base De Données
BSC	Balanced Scorecard
BSON	Binary JSON (JavaScript Object Notation)
CAH	Classification Ascendante Hiérarchique
CART	Classification And Regression Trees
CRISP-DM	Cross Industry Standard Process for Data Mining
CU	Cas d'Utilisation
DM	Data Mining
ECD	Extraction des connaissances à partir de données
EM	Esperance Maximisation
ETL	Extract Transform Load
GIMSI	Généralisation, Information, Méthode, Système, Individualité
JPEG	Joint Photographic Experts Group
JSO	JavaScript Object
JSON	JavaScript Object Notation
KDD	Knowledge Data Discovery
k-Means	L'algorithme des centres mobiles, k-moyennes
k-NN	k Nearest Neigbours
KPI	Key Performance Indicator
MongoDB	Mongo Data Base
NoSQL	Not Only SQL (Structured Query Language)
PDF	Portable Document Format
PNG	Portable Network Graphics
PPV	La méthode des plus proches voisins
SEMMA	Sample, Explore, Modify, Model, Assess
SGBD	Système de Gestion de Base de Données
SMS	Short Message Service
SQL	Structured Query Language
SSL	Secure Socket Layer
SVG	Scalable Vector Graphics

SVM	Support Vector Machines
SWOT	Strengths, Weaknesses, Opportunities, Threats
XOR	Exclusive Or

INTRODUCTION GENERALE

1 Contexte

Le monde ne cesse d'évoluer dans une économie de consommation ou le client se retrouve devant des produits similaires et identiques remplissant les mêmes fonctions. Ce qui a incité les différents acteurs économiques à changer d'orientation et de s'intéresser dorénavant à leurs clients avant qu'ils soient attirés vers la concurrence. Le client est ainsi devenu le principal sujet de conversation et de mobilisation et doit être étudié sous toutes ces facettes.

Toutefois, il existe deux types de clients : "des bons clients", qui génèrent un chiffre d'affaire conséquent, participent à la conception de nouveaux produits et restent fidèles à l'entreprise et "des moins bons", qui sont difficile à satisfaire, se plaignent constamment et finissent par nuire à la réputation de l'entreprise et coûter plus cher qu'ils ne rapportent. Entre ces deux extrêmes, il s'agit de trouver toutes les combinaisons possibles, et la distribution ne sera pas uniforme. Or, on préférera sélectionner et conserver les clients se rapprochant le plus possible de la première catégorie.

Pour ce faire, les entreprises doivent tisser des liens étroits et établir une communication permanente avec chacun de leurs clients afin de pouvoir par la suite, étudier et analyser leurs comportements.

L'étude du comportement des clients, permet à l'entreprise, de mieux cerner les besoins de ses clients et ainsi être en mesure de les cibler avec des offres personnalisées se rapprochant le plus possible de leurs besoins exprimés ou constatés.

La préservation des clients est devenue un enjeu primordial pour toutes entreprise ayant un marché important en termes de nombre de clients, ce qui suscite un intérêt majeur de comprendre le comportement de ses clients afin de maximiser leur satisfaction d'une part et augmenter son chiffre d'affaire d'autre part, à travers des campagnes marketing de fidélisation et de prospection.

2 Problématique

L'entreprise dispose d'un marché très important en termes de nombre de clients (plusieurs millions). Elle génère ainsi une quantité considérable de données concernant l'activité de tous ses clients, d'autant plus que ces données sont générées automatiquement chaque jour.

De plus, elle fait face à une rude concurrence sur le marché dont elle risque de perdre la clientèle aux dépens des autres concurrents.

L'entreprise se retrouve donc face à deux principaux enjeux :

- D'une part, elle doit exploiter les données générées sur ces clients afin d'en extraire des informations utiles. Ces informations constituent un atout pour l'entreprise car elles lui permettent de mieux analyser le comportement de ces clients.
- D'autres part, elle doit à tout prix conserver ces clients de la concurrence et pour ce faire, elle doit trouver un moyen de les fidéliser.

Pour répondre à ces besoins, l'entreprise s'engage dans un projet qui lui permet de comprendre et d'analyser le comportement de ces clients à travers les données qu'elles génèrent sur ces derniers. Les résultats de cette analyse, vont lui offrir la possibilité de se rapprocher le plus possible de ces clients, et pouvoir répondre à leurs besoins dans le but ultime est de les fidéliser et les préserver de la concurrence ainsi améliorer l'efficacité de ces campagnes marketing.

La problématique traitée dans le cadre de notre projet de fin d'études est la mise en place d'un système d'analyse du comportement des clients pour répondre à une problématique décisionnelle dans le but d'améliorer l'efficacité de ces campagnes marketing. De plus, ce dernier doit traiter les tâches de collecte des données ainsi que l'affichage des résultats.

Afin de poursuivre, il est important de souligner quelques points déterminants pour la suite du projet. Ces points soulèvent des questions et requièrent des décisions à prendre. Nous tenterons donc de répondre aux questions suivantes :

1. Quelle sont les types de données à prendre en compte dans l'analyse du comportement client ?
2. Quel mécanisme adopter pour récupérer ces données ?
3. Quel serait la meilleure méthode à appliquer pour analyser ces données ?
4. Quelle serait la meilleure façon de présenter les résultats du processus de façon à offrir une vue synthétique et compréhensible par les utilisateurs ?

Nous répondrons à ces questions à différentes phases de notre conception du système final.

3 Objectif

L'objectif principal de notre projet est de mettre en place un système qui permet d'analyser le comportement des clients à travers l'étude des données générées sur les clients et d'afficher une synthèse de l'analyse dans le but d'améliorer l'efficacité des campagnes marketing. Nous distinguons donc quatre sous objectifs à savoir :

- ✓ Récupérer et sauvegarder les données ;

- ✓ Réaliser des analyses décrivant le comportement des clients basé sur les données recueillies ;
- ✓ Afficher les résultats des analyses réalisées.
- ✓ Réaliser des campagnes marketing efficaces

Dans le but de couvrir ces sous-objectifs, nous nous sommes fixés des tâches qui doivent être accomplies :

- ➢ Proposer et réaliser une approche qui permet d'extraire les données clients, les traiter et les sauvegarder ;
- ➢ Mettre en place un système d'analyse du comportement des clients avec tout ce que cela implique comme tâche ;
- ➢ Tester et évaluer différents algorithmes et techniques dédiés à l'analyse du comportement dans le but d'opter pour les meilleurs ;
- ➢ Assurer une interface d'administration pour la gestion des utilisateurs ;
- ➢ Présenter les résultats de l'analyse sous une forme synthétique.

4 Organisation du rapport

Pour mieux présenter le contenu de ce mémoire, nous l'avons organisé en cinq chapitres :

- ➢ Le premier chapitre est consacré à une présentation générale du concept de data mining, dans lequel nous introduirons le processus ECD, la place du data mining dans ce processus et les différents types de problèmes que l'on peut résoudre à l'aide de data mining.
- ➢ Le deuxième chapitre présente les différentes techniques et algorithmes de data mining utilisés, notamment, pour la classification automatique de données (supervisé et non supervisé) et l'extraction des règles d'association.
- ➢ Le troisième chapitre présente les différentes applications du data mining pour améliorer l'efficacité des campagnes marketing.
- ➢ Le quatrième chapitre décrit la partie conceptuelle. Nous présentons, entre autres, la conception de la solution que nous avons proposée ainsi que la démarche et la méthodologie suivie.
- ➢ Enfin le cinquième et dernier chapitre qui est consacré à l'implémentation et la réalisation de notre solution en décrivant les différents langages et technologies utilisées.

CHAPITRE I : GENERALITES SUR LE DATA MINING

1 Introduction

Les technologies de data mining permettent, grâce aux processus d'intelligence artificielle, de traiter des masses gigantesques de données afin d'en extraire l'information cruciale (connaissance), celle qui sera déterminante pour une prise de décision efficace.

Le data mining est l'un des maillons de la chaine de traitement pour la découverte de connaissances à partir de données (ECD). Sous forme imagée, on pourrait dire que l'ECD est un véhicule dont le data mining est le moteur[1].

Dans ce chapitre introductif, nous allons présenter le data mining et ses différents concepts. Il s'agit d'une première introduction du sujet qui sera affinée et approfondie tout au long du reste de ce document.

2 Le processus ECD

Le data mining est une étape d'une chaine de traitement plus complète, le processus d'extraction de connaissances à partir de données (ECD). Qu'est-ce que l'ECD ? Quels sont ses étapes ?

2.1 Le processus ECD

L'extraction de connaissances à partir de données (ECD) est une procédure interactive et itérative, qui tente d'extraire des connaissances implicites, utiles et précédemment inconnues à partir des données[2].

Les objectifs de l'ECD sont définis par l'utilisation envisagée du système. Nous pouvons distinguer deux types d'objectifs : Vérification, où le système est limité à la vérification de l'hypothèse de l'utilisateur, et découverte, où le système de manière autonome trouve de nouveaux modèles. Nous subdivisons ainsi le but de la découverte en prévision, où le système trouve des motifs dans le but de prédire le comportement futur de certaines entités ; et description, où le système trouve des motifs dans le but de les présenter à un utilisateur dans une forme humaine compréhensible[3].

2.2 Etapes du processus ECD

L'ECD est un processus complexe qui se déroule suivant une suite d'opérations. Selon[4] , l'ECD peut être vu comme un processus en sept étapes :

2.2.1 Positionnement du problème

Il s'agit de comprendre le contexte de la recherche pour donner une signification logique aux variables de sa problématique. Dans cette étape, toutes les variables susceptibles d'expliquer le phénomène étudié sont identifiées.

Une première approche consiste à reformuler le problème pour qu'il puisse être traité par les techniques et les outils de modélisation (par exemple modéliser le problème sous forme d'une fonction mathématique).

Une autre approche, des plus efficaces, consiste à découper le problème complexe en sous- problèmes plus simples et à traiter, indépendamment, chacun de ces sous-problèmes.

2.2.2 Collecte et sélection des données

On procède d'abord par une collecte de données. Ces dernières se trouvant généralement dans des bases de données. Les données collectées, ne faisant état d'aucun critère de sélection préalable, nécessitent habituellement une phase de sélection pour n'en garder que les données dont on a besoin.

Une sélection optimale des données nécessite souvent l'aide d'experts du domaine pour déterminer les facteurs, ou variables, les plus aptes à décrire la problématique.

Dans le cas où les experts ne sont pas disponibles, une recherche des variables les plus déterminantes est effectuée par des techniques d'analyse (comme la régression, les réseaux de neurones…).

2.2.3 Nettoyage des données

Une faible qualité de données (erreurs de saisie, champs nuls, valeurs aberrantes…) impose généralement une phase de nettoyage de celles-ci. Cette étape a pour objectif de corriger ou de contourner les inexactitudes ou les erreurs de données.

On commence par rechercher et éliminer les valeurs aberrantes. Ensuite, on vise à gérer les données manquantes par l'une des méthodes suivantes :

- Exclure les enregistrements incomplets ;
- Remplacer les valeurs manquantes (généralement par la moyenne) ;
- Gérer les valeurs manquantes (lorsque l'absence de donnée est acceptable du point de vue de la performance).

2.2.4 Actions sur les attributs

Bien que les données soient maintenant pertinentes et fiables, elles ne peuvent être directement exploitées par les outils de Data Mining. C'est pour cela que nous devons passer par une phase de transformation des variables.

Ces transformations se résument généralement par trois actions :

- **Uniformisation d'échelle (normalisation)** : et cela afin d'éviter toutes disproportions dans les systèmes d'unité et de variables.
- **Regroupement** : fusionner plusieurs variables en une seule dans le cas où l'information unitaire est insignifiante.
- **Modification de type** : des fois, un type a beaucoup moins de valeurs, du point de vue modélisation, qu'un autre (comme les dates et les durées). Il vaut mieux stocker l'ancienneté d'un client que la date de son premier achat ou de son dernier achat.

Les techniques de data mining ont généralement des difficultés à appréhender des codes postaux ou des adresses. Une approche habile consiste à joindre des coordonnées de longitude et de latitude (géocodage).

2.2.5 Construction du modèle (datamining)

Cette phase consiste à extraire la connaissance utile à partir d'un large volume de données et à la présenter sous une forme synthétique. Elle repose sur une recherche exploratoire, c'est à dire dépourvue de préjugés concernant les relations entre les données[4].

2.2.5.1 Définition du data mining

De multiples définitions ont été présentées pour déterminer l'essence du DM. Nous donnons les trois définitions suivantes que nous jugeons les plus importantes et les plus utilisées :

- **Définition1 :** Cette définition est due à U.M. FAYYAD l'un des pionniers du DM, elle est communément admise. « Le DM est un processus non trivial d'extraction, à partir de gros ensembles de données de l'information valide, compréhensible, préalablement inconnue et potentiellement utile pour l'utilisateur » [5].
- **Définition2 :** (Hand et al., 2001) est une référence consacrée au DM d'un point de vue statistique, le DM y défini ainsi :« Le DM est l'analyse d'un ensemble, souvent important, d'observations qui a pour but de trouver des relations insoupçonnées et résumer les données d'une nouvelle manière, de façon qu'elles soient plus compréhensibles et utiles pour leurs détenteurs ».

- **Définition3 :** Le groupe Garthner[1] est un leader américain en consulting dans le domaine des technologies de l'information. Sa définition pour le DM est la suivante :« La fouille de données est le processus de découverte de corrélations, formes et tendances nouvelles et significatives en passant au crible de grandes quantités de données stockées dans des bases patrimoniales et en utilisant la technologie de reconnaissance de formes conjointement aux techniques statistiques et mathématiques » [6].

Le modèle choisi dépend principalement du type du problème à résoudre et de la tâche (certaines techniques sont plus aptes à résoudre un certain type de tâches). Il faudra faire des compromis selon les besoins dégagés et les caractéristiques communes des techniques.

2.2.6 Evaluation du résultat

Cette étape permet d'estimer la fiabilité du modèle c'est-à-dire sa qualité à déterminer correctement les valeurs, qu'il est censé avoir apprises, sur des cas nouveaux.

A l'issue de la construction du modèle, il est possible d'en tester la pertinence sur l'ensemble des tests. En général, la performance d'un modèle s'apprécie au travers une matrice qui compare la situation réelle et la situation prévue par le modèle. La qualité globale du modèle est la portion de prédictions exactes par rapport aux nombre total de prédictions. Un niveau de prédiction de 80% est jugé moyen[4].

2.2.7 Intégration de la connaissance

On intègre le modèle dans le processus de l'entreprise, c'est l'étape de la transition du domaine des études au domaine opérationnel[4].

2.3 Tâches de data mining

Le data mining est un ensemble de techniques complémentaires dédiées à différentes tâches. Selon[7], ces technique sont partagées, principalement, entre la classification automatique (supervisée et non supervisée) et la recherche d'associations.

- **La classification automatique supervisée :** La classification automatique supervisée consiste à examiner les caractéristiques d'un objet nouvellement présenté afin de l'affecter à une classe d'un ensemble prédéfini [7]. .

[1] visitez leurs site : http://www.gartner.com

- **La classification automatique non supervisée :** C'est une tâche qui vise à identifier des ensembles d'éléments qui partagent certaines similarités. Elle se distingue de la classification automatique supervisée par le fait qu'elle ne se base pas sur des classes prédéfinies[7].Le principe général de la classification automatique non supervisée, également appelée clustering, repose sur le regroupement des objets de telle manière que ceux qui appartiennent à la même classe soient fortement similaires entre eux et fortement dissimilaires avec les objets qui appartiennent aux autres classes.

- **Les règles d'association :** C'est une tâche qui permet de découvrir les rapports de lien qui peuvent exister dans une base de données. Ces liens sont généralement exprimés sous la forme « A⟹B » qui signifie que la présence de A implique la présence de B (avec une certaine probabilité). Par exemple : Un étudiant qui réussit en mathématiques réussira en algorithmique dans 80% des cas.

2.4 Techniques de data mining

Les techniques de data mining diffèrent en fonction des besoins de l'utilisateur, entre autres la tâche à effectuer.

Selon[8], les dix algorithmes les plus populaires dans le domaine de data mining sont, dans l'ordre: C4.5, k-Means, SVM, Apriori, EM, PageRank, AdaBoost, k-NN, Naive Bayes et CART. Ces algorithmes sont classifiés, selon la tâche associée, comme suit:

- Algorithmes de construction des arbres de décision : CART, C4.5;
- Algorithmes de classification non supervisée : k-Means, EM;
- Algorithmes de classification supervisée : k-NN, SVM, Naive Bayes et AdaBoost;
- Algorithme d'extraction des règles d'association : Apriori;
- Algorithme de classification automatique des pages Web : PageRank.

Un état de l'art des principales techniques de data mining fait l'objet du chapitre 2.

2.5 Domaines d'application

Le data mining est une spécialité transverse, elle regroupe un ensemble de théories et d'algorithmes ouverts à tout domaine susceptible de drainer une masse importante de données. Parmi ces domaines, on cite :

2.5.1 Le marketing

Le data mining répond aux besoins de comprendre la relation client, de connaître les comportements des clients, d'optimiser et de rentabiliser les opérations de prospection afin de

diminuer les coûts d'acquisition des clients. Les solutions de data mining vont faire des prédictions de comportement et indiquer quels types de prospects devront en priorité être contactés par des opérations de marketing direct afin d'augmenter le taux de retour.

2.5.2 Banques et finances :

L'utilisation du data mining fut aussi une étape clé dans le domaine bancaire car il a permis d'assurer plusieurs objectifs vitaux à l'activité de la banque, nous citons :

- La détection d'usage frauduleux de cartes bancaires
- La gestion du risque lié à l'attribution de prêts
- La détection de règles de comportement boursier par l'analyse des données du marché

2.5.3 Médical et pharmaceutique

Le data mining est aussi utilisé dans le domaine de la santé. Par exemple dans l'analyse des patients, leurs caractéristiques et symptômes, et ce dans le but d'effectuer des diagnostiques. Parmi les diffèrent usage du data mining dans la santé nous pouvons citer quelques-uns :

- Diagnostique assisté par ordinateur
- Explication ou prédiction de la réponse d'un patient à un traitement
- Identification des thérapies à succès
- Étude des corrélations entre le dosage dans un traitement et l'apparition d'effets secondaires

2.6 Difficultés de data mining

La mise en œuvre de data mining rencontre trois difficultés principales [9]:

- **Qualité des données :** Les statistiques ont montré que 60% à 70% du temps de travail dans un projet de data mining est consacré au prétraitement des données (sélection, correction, transcodage, chargement…), ce qui montre que le temps de préparation est un inconvénient majeur qui influe sur le temps global du projet.
- **Choix des algorithmes et de l'itinéraire du travail :** Pour pouvoir répondre aux questions qui se posent, les algorithmes doivent être choisis en fonction du problème traité. Il faut que l'expert en datamining soit aussi un animateur et possède des qualités que l'on trouve rarement ensemble chez la même personne : rigueur dans la méthode, ouverture et chaleur humaine dans la communication.

- **Évaluation des résultats :** Avant de procéder au déploiement final du modèle, il est important de l'évaluer plus complètement et de passer en revue toutes les différentes étapes exécutées pour construire ce modèle. Ceci permettra d'être certain qu'il permet d'atteindre les objectifs fixés. Lors de la définition du problème, un objectif principal est de déterminer s'il y a un aspect important du problème à résoudre qui n'a pas été suffisamment considéré. A la fin de cette phase, une décision sur l'utilisation des résultats fournis par les outils de data mining devrait être prise.

3 Conclusion

Nous avons exposé, à travers ce chapitre introductif, les principaux concepts liés au data mining qui n'est qu'une étape de traitement au sein du processus ECD. Ce dernier est né de la nécessité d'englober et de compléter le data mining pour que le traitement soit le plus automatisé possible.

Nous avons vu que les techniques de data mining ne font pas état des hypothèses fixées à priori, comme le font les statistiques traditionnelles, mais cherchent à établir un modèle par l'exploration des bases de données. Le data mining fait passer de l'analyse confirmatoire à l'analyse exploratoire.

Nous avons également montré que les tâches de data mining sont partagées entre la classification automatique supervisée, la classification automatique non supervisée et les règles d'association. Ces tâches se distinguent, chacune, par ses objectifs, ses algorithmes et ses résultats.

Le chapitre suivant sera consacré à l'étude des principales techniques de data mining.

CHAPITRE II : LES TECHNIQUES DE DATA MINING

1 Introduction

Le data mining offre une très grande variété de techniques et d'algorithmes de fouille de données ayant des origines diverses, certains sont issus des statistiques (régression…), d'autres de l'intelligence artificielle (réseaux de neurones, arbres de décision…), certains encore s'inspirent de la théorie de l'évolution (algorithmes génétiques…) ou de l'éthologie (colonies d'abeilles…). Cette combinaison de technologies facilite la résolution, la compréhension, la modélisation et l'anticipation des problèmes.

Ce chapitre est consacré à l'étude des bases théoriques et les concepts mathématiques liés au data mining. Nous présentons les différentes techniques et nous montrons les caractéristiques, les avantages et les inconvénients de chacune.

2 La classification automatique supervisée

2.1 Problématique

On dispose d'un ensemble X, comportant N données étiquetées (dont la classe est connue). Chaque donnée x est caractérisée, par P attributs et par sa classe $C_i \in C$, C étant l'ensemble des classes. Le problème consiste alors, en s'appuyant sur l'ensemble $X = \{(x_i ; C_i) ; i \in \{1 ... N\}\}$, à prédire la classe de toute nouvelle donnée x.

2.2 Les algorithmes de classification

Parmi les algorithmes de classification supervisée les plus populaires dans la littérature, on trouve : les arbres de décision, l'algorithme SVM et le plus proche voisin.

2.2.1 Les arbres de décision

2.2.1.1 Présentation de la méthode :

Un arbre de décision est un outil d'aide à la décision, qui permet de répartir une population d'individus en groupes homogènes selon des attributs discriminants en fonction d'un objectif fixés et connu. Il permet d'émettre des prédictions à partir des données connues sur le problème par réduction, niveau par niveau, du domaine des solutions. Chaque nœud interne d'un arbre de décision porte sur un attribut discriminant des éléments à classifier qui permet de répartir ces éléments de façon homogène entre les différents fils de ce nœud. Les branches liant un nœud à ses fils représentent les valeurs discriminantes de l'attribut du nœud. Et enfin, les feuilles d'un arbre de décision sont ses prédictions concernant les données à classifier[10].

2.2.1.2 **Description de l'algorithme :**

La technique de l'arbre de décision est employée en classement pour détecter des critères permettant de répartir les individus d'une population en n classes (souvent n=2) prédéfinies.

On commence par choisir la variable qui, par ses modalités, sépare le mieux les individus de chaque classe, de façon à avoir des sous-populations, que l'on appelle nœuds, contenant chacune le plus possible d'individus d'une seule classe, puis on réitère la même opération sur chaque nouveau nœud obtenu jusqu'à ce que la séparation des individus ne soit plus possible ou plus souhaitable.

Par construction, les nœuds terminaux (les feuilles) sont tous majoritairement constitués d'individus d'une seule classe avec une assez forte probabilité, quand il satisfait l'ensemble des règles permettant d'arriver à cette feuille. L'ensemble des règles de toutes les feuilles constitue le modèle de classement (Figure II-1)[11].

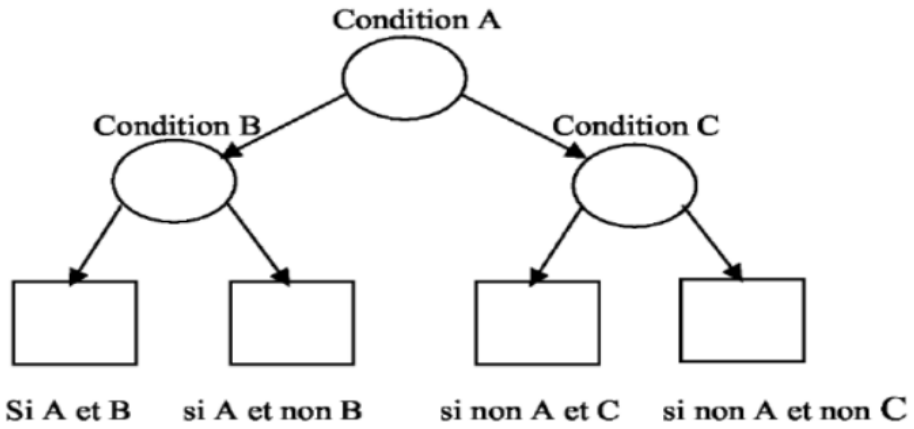

Figure II-1 : *Arbre de décision*[11]

L'algorithme d'apprentissage par l'arbre de décision est décrit comme suit :

Donnée : un échantillon S de m enregistrements classés (x, c(x))
Initialisation : A ← arbre vide
noeud_courant ← racine
échantillon_courant ← S
Répéter
Décider si le noeud courant est terminal
Si (noeud_courant est terminal) alors
Étiqueter le noeud courant par une feuille
Sinon
Sélectionner un test :
Créer les fils
Définir les échantillons sortants du noeud
Finsi
noeud_courant ← un noeud non encore étudié de A
échantillon_courant : échantillon atteignant noeud_courant
Jusque (noeud_courant = Ø)
Élaguer l'arbre de décision A obtenu
Sortie : l'arbre A élagué

2.2.1.3 Avantages et inconvénients

Le tableau suivant présente les avantages et inconvénients de la technique des arbres de décision [2]:

Tableau II-1 : *les avantages et inconvénients des arbres de décision*

Avantages	Inconvénients
- Traduction directe de l'arbre vers une base de règles. - Sélection automatique des variables pertinentes. - Non paramétrique.	- Problèmes de stabilité des petites bases de données. - Recherche « pas-à-pas » : difficulté de trouver certaines interactions (exemple XOR)

[2]https://www.rocq.inria.fr/axis/modulad/archives/numero-33/tutorial-rakotomalala-33/rakotomalala-33-tutorial.pdf

- Robuste face aux données aberrantes, solutions pour les données manquantes. - Robuste face aux variables redondantes. - Rapidité et capacité à traiter de très grandes bases de données. - Possibilité pour l'analyste d'intervenir dans la construction de l'arbre.	- Performances moins bonnes en générale par rapport aux autres méthodes (performance hautement dépendante de la taille de la base d'apprentissage).

2.2.2 Les machines à support de vecteurs (SVM)

2.2.2.1 Présentation de la méthode :

L'idée de l'approche SVM est de séparer deux classes par l'hyper plan optimal qui garantit que l'écart entre elle soit maximal.

Les machines à vecteurs de support (ou séparateur à vaste marge) sont des techniques d'apprentissage supervisé qui s'appuient sur deux idées fortes : le principe de la maximisation de la marge (1) ; lorsque les données ne sont pas linéairement séparables, il est possible, par le principe des noyaux, de se projeter dans un espace de plus grande dimension (2) pour trouver la solution adéquate, sans avoir à former explicitement ce nouvel espace de représentation. De par sa remarquable stabilité (faible variance), les SVM sont très performants dans les espaces à très grande dimension, lorsque le ratio nombre de variables / nombre d'observations est très élevé.

- **Marge Maximale :** La marge est la distance entre la frontière de séparation et les échantillons les plus proches. Ces derniers sont appelés vecteurs supports. Dans les SVM, la frontière de séparation est choisie comme celle qui maximise la marge. Ce choix est justifié par la théorie de Vapnik-Chervonenkis (ou théorie statistique de l'apprentissage), qui montre que la frontière de séparation de marge maximale possède la plus petite capacité. Le problème est de trouver cette frontière séparatrice optimale, à partir d'un ensemble d'apprentissage. Ceci est fait en formulant le problème comme un problème d'optimisation quadratique, pour lequel il existe des algorithmes connus. On se place désormais dans le cas où le problème est linéairement séparable. Même dans ce cas simple, le choix de l'hyperplan séparateur n'est pas évident.

  Il existe en effet une infinité d'hyperplans séparateurs, dont les performances en apprentissage sont identiques (le risque empirique est le même), mais dont les performances en généralisation peuvent être très différentes. Pour résoudre ce problème,

il a été montré, qu'il existe un unique hyperplan optimal, défini comme l'hyperplan qui maximise la marge entre les échantillons et l'hyperplan séparateur

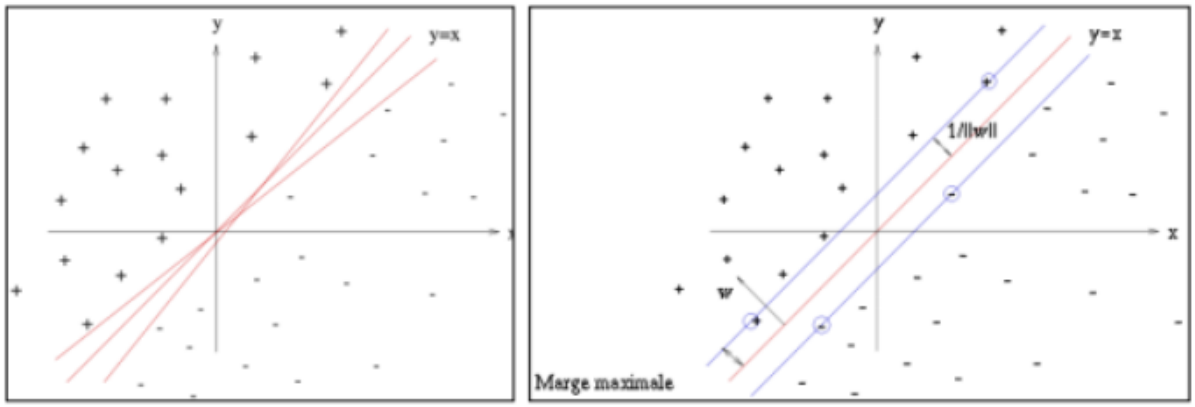

Figure II-2 *: Illustration de la marge maximale d'un hyperplan séparant deux classes*[12]

- **Projection dans un espace vectoriel de plus grande dimension :** Afin de pouvoir traiter des cas où les données ne sont pas linéairement séparables, la deuxième idée clé des SVM est de transformer l'espace de représentation des données d'entrées en un espace de plus grande dimension (possiblement de dimension infinie), dans lequel il est probable qu'il existe un séparateur linéaire. Ceci est réalisé grâce à une fonction noyau, qui doit respecter certaines conditions, et qui a l'avantage de ne pas nécessiter la connaissance explicite de la transformation à appliquer pour le changement d'espace. Les fonctions noyau permettent de transformer un produit scalaire dans un espace de grande dimension, ce qui est coûteux, en une simple évaluation ponctuelle d'une fonction. Cette technique est connue sous le nom de kernel trick.

2.2.2.2 Avantages et inconvénients :

Tableau II-2 : *Les avantages et inconvénients du SVM*

Avantages	Inconvénients
- Les SVM offrent une bonne performance de classification sur les données d'apprentissage. - Les SVM est plus efficace pour classer des données futures. - Aucune hypothèse forte n'est faite sur les données. - Pas de sur apprentissage.	- Elles utilisent des fonctions mathématiques complexes pour la classification. - Les machines à support de vecteurs demandent un temps énorme durant les phases de test.

2.2.3 Le plus proche voisin :

2.2.3.1 Description de la méthode :

La méthode des plus proches voisins (PPV en bref, nearest neighbor en anglais) est une méthode dédiée à la classification qui peut être étendue à des tâches d'estimation. La méthode PPV est une méthode de raisonnement à partir de cas. Elle part de l'idée de prendre des décisions en recherchant un ou des cas similaires.

Contrairement aux autres méthodes de classification, il n'y a pas d'étape d'apprentissage consistant en la construction d'un modèle à partir d'un échantillon d'apprentissage. C'est l'échantillon d'apprentissage, associé à une fonction de distance et d'une fonction de choix de la classe en fonction des classes des voisins les plus proches, qui constitue le modèle[11].

L'algorithme générique de classification d'un nouvel exemple par la méthode PPV est dressé dans la table.

Paramètre : le nombre k de voisins

Donnée : un échantillon de m exemples et leurs classes //La classe d'un exemple X est c(X)

- **Entrée** : un enregistrement Y

1- Déterminer les k plus proches exemples de Y en calculant les distances

2- Combiner les classes de ces k exemples en une classe c

- **Sortie** : la classe de Y est c(Y)= c

2.2.3.2 Avantages et inconvénients :

Tableau II-3 : *Les avantages et inconvénients du plus proche voisin*

Avantages	Inconvénients
- Clarté des résultats ; - Traiter tout type de données avec un nombre d'attributs élevé - Ne pas refaire l'apprentissage lors de l'introduction de nouveaux attributs	- D'une part, le temps pour calculer les voisins peut être prohibitif ; - Il faut toujours stocker le modèle durant toute l'opération de classification

3 La classification automatique non supervisée

3.1 Définition

La classification automatique non supervisée, aussi appelée segmentation ou clustering[13], consiste à diviser une population d'objets en sous-ensembles d'objets appelés

classes pour que tous les objets dans une même classe soient similaires et les objets de classes distinctes soient dissimilaires.

Parmi les objectifs que le clustering doit permettre d'atteindre, citons la réduction des données et la prédiction basée sur les groupes.

3.2 Les algorithmes de clustering

La majorité des algorithmes de clustering peuvent être répartis en trois grandes familles [14],[15] et[16]:

- **Les algorithmes de partitionnement** : Ils adoptent une recherche itérative des classes jusqu'à l'optimisation d'un critère d'arrêt (par exemple atteindre une certaine inertie).
- **Les algorithmes hiérarchiques** : Ils sont descendants si, à partir d'une seule classe, ils cherchent à établir une partition par division ; ou ascendants s'ils cherchent à former des classes plus grandes par fusion de classes jusqu'à la satisfaction d'un critère d'arrêt.
- **Les algorithmes à base de densité** : Les classes sont formées selon le voisinage des objets et le niveau de densité de chaque objet.

3.2.1 Les algorithmes de partitionnement

Leur principe général est de démarrer à partir d'un certain nombre de classes qui sont partitionnés d'une manière aléatoire en effectuant une redistribution des objets ou en essayant d'identifier les classes comme étant des régions très peuplées jusqu'à la rencontre d'un critère d'arrêt.

Parmi les algorithmes de partitionnement on peut citer k-Means, CAH.

3.2.1.1 L'algorithme K-means

L'algorithme k-Means (ou l'algorithme des centres mobiles) a été introduit par J.MacQuenn et mis en œuvre sous sa forme actuelle par E.Forgy[14]. Il est le plus utilisé dans les applications scientifiques et industrielles car il est le plus simple et le plus rapide.

Dans cet algorithme itératif, chaque classe est représentée par la moyenne (centroïde). Il commence avec un ensemble de *k* individus de référence choisis de façon aléatoire. Les individus de données sont ainsi partitionnés dans *k* classes ; un individu appartient à une classe si le centre de cette classe est le plus proche de lui (en termes de distance). La mise à jour des

centroïdes et l'affectation des individus de données aux classes sont réalisées pendant les itérations successives[17].

K-means vise donc à minimiser la variance intra classe qui se traduit par la minimisation de l'énergie.

Parmi les avantages et inconvénients de cette algorithme on peut citer :

Tableau II-4 : *Avantages et inconvénients du K-means*

Avantages	Inconvénients
- Il s'adapte bien pour des populations de tailles importantes ; - Il est relativement efficace ; si *n* le nombre d'objets, *k* le nombre de classes et *t* le nombre d'itération, l'algorithme converge, généralement, avec *k* et *t* suffisamment inférieur à *n* (*k*, *t* <<*n*) ; - Il est indépendant de l'ordre d'arrivée des données.	- Il est applicable seulement dans le cas où la moyenne des objets est définie ; - Le nombre de classes *k*, doit être spécifié à priori ; - Il converge souvent vers un optimum local ; - Il est sensible aux objets isolés (bruits) ; - Il n'est pas adapté pour découvrir des classes avec des structures non-convexes, et des classes de tailles et formes différentes

3.2.1.2 Algorithme de clustering hiérarchique

Dans le cas du clustering agglomératif (ou ascendante), on commence par considérer que chaque point est un cluster à lui tout seul. Ensuite, on trouve les deux clusters les plus proches, et on les agglomère en un seul cluster. On répète cette étape jusqu'à ce que tous les points appartiennent à un seul cluster, constitué de l'agglomération de tous les clusters initiaux.

L'approche inverse, le clustering divisif (ou descendante), consiste à initialiser avec un unique cluster contenant tous les points, puis à itérativement séparer chaque cluster en plusieurs, jusqu'à ce que chaque point appartienne à son propre cluster.

Parmi les avantages et inconvénients de cette algorithme on peut citer :

Tableau II-5 : *Avantages et inconvénients du clustering hiérarchique*

Avantages	Inconvénients
- Il n'est pas nécessaire de définir le nombre de clusters à l'avance ; - Possibilité évaluer les différentes partitions trouvées ; - Plus adapté aux échantillons contenant un faible nombre d'individus ;	- Explore toutes les possibilités et complexité algorithmique trop lourde ; - Un coût quadratique en temps de calcul et de stockage (espace mémoire) ; - Une forte complexité algorithmique en temps et en espace,

4 Conclusion

Nous avons présenté dans ce chapitre, les algorithmes de data mining couramment utilisés dans le but d'effectuer l'une des principales tâches de fouille de données (le clustering, la classification).

Choisir le bon algorithme pour son projet de data mining est une tâche qui n'est pas toujours aisée.

Enfin, un mauvais choix de l'algorithme d'application engendre de lourdes conséquences sur le plan de la performance et des résultats. Dans certains cas, il peut faire échouer tout le projet.

CHAPITRE III : APPLICATION DU DATA MINING EN MARKETING ET GESTION DE LA RELATION CLIENT

1 Introduction

Aujourd'hui, des technologies telles que l'entreposage des données et le data mining permettent aux entreprises de collecter, stocker, analyser et manipuler d'énormes volumes de données. Ce qui permettra aux spécialistes du marketing d'offrir un meilleur service et plus de satisfaction aux clients par rapport aux autres concurrents.

Dans ce chapitre nous allons définir le marketing, puis nous présenterons certaines applications de l'explorations de données appliquées en ce domaine.

Le chapitre commence par le problème de la communication avec des clients potentiels dont on sait très peu de choses et se penche sur les diverses opportunités d'exploration de données offertes par les relations clients en cours pouvant impliquer plusieurs produits, plusieurs canaux de communication et des interactions de plus en plus individualisées.

2 Définition du marketing :

De nombreuses définitions existent, nous retiendrons les définitions suivantes :

D'après l'association américaine de marketing : « Le marketing recouvre l'activité, l'ensemble des techniques et les processus visant à créer, communiquer, délivrer et échanger les offres qui ont de la valeur pour les clients, les consommateurs, les partenaires et la société au sens large »[18].

Selon Jacques Lendrevie et Julien Levy : « le marketing est un moyen d'action qu'utilisent les organisations pour influencer en leur faveur le comportement des publics dont elles dépendent »[19].

Sophie Richard-Lanneyrie définit le marketing comme suit : « le marketing est l'ensemble des actions qui ont pour objet de prévoir, constater, stimuler ou renouveler les besoins du consommateur » [20].

A travers les différentes définitions que nous avons présentées, nous constatons que le marketing se concentre sur l'échange, et nous conduit naturellement au marché qui veut dire l'ensemble des clients capables et désireux de procéder à un échange qui leur permettent de satisfaire un besoin ou un désir.

3 Différentes utilisations du DM en marketing

3.1 La prospection

En marketing, un prospect est une personne qui peut raisonnablement s'attendre à devenir un client si elle est approchée de la bonne manière. L'objectif étant de localiser des personnes qui constitueront de précieux clients à l'avenir.

Pour la plupart des entreprises, relativement peu de personnes sur les sept milliards d'habitants de la terre sont réellement des clients potentiels. La plupart peuvent être exclus en fonction de la géographie, de l'âge, de la capacité de payer et du besoin du produit ou du service.

Le Data Mining peut jouer de nombreux rôles dans la prospection. Les plus important sont [21]:

- Identifier les bonne perspectives.
- Choisir un canal de communication pour atteindre les clients potentiels.
- Choisir des messages appropriés pour différents groupes de clients potentiels.

Bien que tous ces éléments soient importants, le premier à identifier de bonnes perspectives est le plus largement mis en œuvre.

3.1.1 Identifier les bonnes perspectives

L'exploration de données est appliquée à ce problème en définissant d'abord ce que signifie être une bonne perspective, puis en recherchant des règles permettant de cibler les personnes présentant ces caractéristiques. Pour de nombreuses entreprises, la première étape vers l'utilisation de l'exploration de données pour identifier de bonnes perspectives consiste à créer un modèle de réponse. Nous aborderons plus loin dans ce chapitre une discussion approfondie sur les modèles de réponse, les différentes manières de les utiliser et ce qu'ils peuvent et ne peuvent pas faire.

3.1.2 Choisir un canal de communication

La prospection nécessite une communication. De manière générale, les entreprises communiquent intentionnellement avec leurs prospects de plusieurs manières. L'une des méthodes consiste à inciter les médias à couvrir l'histoire de la société et à diffuser des messages positifs de bouche à oreille plus loin dans ce chapitre, vous trouverez une section sur l'analyse de réponse différentielle, qui explique comment l'exploration de données peut aider à déterminer quels canaux ont été efficaces pour quels groupes de prospects.

3.1.3 Choisir les messages appropriés

Même lorsque vous vendez le même produit ou service de base, différents messages sont appropriés pour différentes personnes. Le message peut être important, choisir le bon message est encore plus important[21].

3.2 Data Mining pour choisir le meilleur endroit pour annoncer

Une façon de cibler les clients potentiels est de rechercher des personnes qui ressemblent à des clients actuels ce qui facilite la publication de deux manières[21] :

- Premièrement, en ciblant les clients qui correspondent au profil, ainsi augmenter le taux de réponse en offrant des promotions.
- Deuxièmement, ces profils de personnes instruites et à revenu élevé peuvent être utilisé pour vendre des espaces publicitaires à des entreprises souhaitant atteindre un tel public.

Le défi du data mining consistait à trouver une bonne définition de ce que signifie correspondre au profil.

3.2.1 Qui correspond au profil ?

Une façon de déterminer si un client correspond à un profil consiste à mesurer la similarité (ce que nous appelons également la distance) entre le client et le profil. Plusieurs techniques de data mining utilisent cette idée pour mesurer la similarité en tant que distance tels que l’approche du plus proche voisin.

Lors de la comparaison des profils de clients, il est important de garder à l’esprit le profil de la population dans son ensemble[21].

3.3 Data Mining pour améliorer les campagnes de marketing direct

La publicité peut être utilisée pour atteindre des clients potentiels sur lesquels rien n’est connu. Le marketing direct nécessite au moins un petit peu d'informations supplémentaires, telles qu'un nom et une adresse, un numéro de téléphone ou une adresse électronique.

Là où il y a plus d'informations, il y a aussi plus d'opportunités pour le data mining. Au niveau le plus élémentaire, le Data Mining peut être utilisée pour améliorer le ciblage en sélectionnant les personnes à contacter. Ainsi, l’une des principales applications de

l'exploration de données consiste à rechercher les prospects les plus susceptibles de répondre à une offre.

3.3.1 Modélisation de la réponse :

Les modèles de réponse sont utilisés pour améliorer les taux de réponse en identifiant les clients potentiels les plus susceptibles de répondre à une sollicitation directe. Les modèles de réponse les plus utiles fournissent une estimation réelle de la probabilité de réponse, mais il ne s'agit pas d'une exigence stricte. Tout modèle permettant de classer les prospects par probabilité de réponse est suffisant. Avec une liste de classement, les spécialistes du marketing direct peuvent augmenter le pourcentage de répondants touchés par les campagnes en envoyant des courriers ou en appelant des personnes se trouvant en haut de la liste. Il convient toutefois de noter que bon nombre des techniques d'exploration de données peuvent et ont été appliquées à la modélisation de réponse[21].

3.3.2 Optimiser la rentabilité de la campagne

Il ne fait aucun doute que doubler le taux de réponse à une campagne est un résultat souhaitable, mais que vaut-il réellement ? la campagne est-elle même rentable ?

Pour améliorer la rentabilité, davantage d'informations sont nécessaires. En particulier, le calcul de la rentabilité nécessite des informations sur les revenus ainsi que sur les coûts.

Une simple matrice de profits et pertes peut être utilisée pour traduire la réponse à une campagne en chiffre de bénéfices.

En ignorant les coûts fixes de la campagne, si un client potentiel répond pour 44 personnes qui ne répondent pas, la campagne se dissipera. Si le taux de réponse est meilleur que cela, la campagne est rentable.

3.3.2.1 Comment le modèle affecte la rentabilité ?

Comment le modèle affecte-t-il la rentabilité d'une campagne ? La réponse dépend du coût de démarrage de la campagne, de la prévalence sous-jacente des intervenants dans la population et du taux de réponse des personnes contactées.

La modélisation de la rentabilité d'une campagne à l'avance est avant tout une analyse hypothétique permettant de déterminer les limites de la rentabilité probable en fonction de diverses hypothèses. Bien qu'optimiser une campagne à l'avance ne soit pas particulièrement utile, il peut s'avérer utile de mesurer les résultats d'une campagne après son exécution. Toutefois, pour que cela fonctionne efficacement, il est nécessaire que les clients inclus dans la

campagne disposent de toute une gamme de scores de réponse, même les clients des déciles inférieurs[21].

La rentabilité d'une campagne dépend de nombreux facteurs qu'on peut seulement estimer à l'avance, que le seul moyen fiable de le faire est d'utiliser un test de marché réel[21].

3.3.3 Atteindre les personnes les plus influencées par le message

Le but d'une campagne de marketing est de changer les comportements. À cet égard, il est un peu plus efficace de contacter un client qui achètera de toute façon que de contacter un client qui n'achètera pas malgré la réception de l'offre[21].

Un groupe identifié comme répondant probable peut également être moins susceptible d'être influencé par un message marketing. Leur appartenance au groupe cible signifie qu'ils ont probablement déjà été exposés à de nombreux messages similaires de la part de leurs concurrents.

Un message marketing peut faire plus de différence avec des personnes qui n'ont pas connu le produit. Les segments avec les scores les plus élevés auraient peut-être réagi de toute façon, même sans l'investissement marketing. Ainsi on pourra dire que les segments ayant les scores les plus élevés dans un modèle de réponse peuvent ne pas fournir le retour sur investissement le plus important[21].

3.3.4 Analyse de la réponse différentielle

La manière de sortir de ce dilemme est de modéliser directement l'objectif réel de la campagne, qui n'est pas simplement atteindre les prospects qui font ensuite des achats. L'objectif devrait être d'atteindre les prospects qui sont plus susceptibles de faire des achats après avoir été contactés. Ceci est connu sous le nom d'analyse de réponse différentielle[21].

L'analyse de réponse différentielle a pour objet de rechercher les segments dans lesquels la différence de réponse entre les groupes traités et non traités est la plus grande. Cette analyse de réponse différentielle peut être modélisée à l'aide d'un arbre de décision une des techniques de DM. L'arbre de réponse différentielle indique clairement le groupe le plus touché par la campagne.

3.4 Data Mining pour la gestion de la relation client

La gestion de la relation client se concentre naturellement sur les clients établis. Le client paie-t-il ses factures à temps ? Chèque ou carte de crédit ? Quand était le dernier achat ? Quel produit a été acheté ? Combien cela-a-t-il coûté ? Combien de fois le client a-t-il appelé le

service client ? Combien de fois avons-nous appelé le client ? Quelle méthode d'expédition le client utilise-t-il le plus souvent ? Combien de fois le client a-t-il retourné un achat ?

Ce type de données comportementales peut être utilisé pour évaluer la valeur potentielle des clients, le risque qu'ils mettent fin à la relation, le risque qu'ils cessent de payer leurs factures et l'anticipation de leurs besoins futurs.

3.4.1 Faire correspondre les campagnes aux clients

Le marketing ne s'arrête pas une fois les clients acquis. Il existe des campagnes de ventes croisées, des campagnes de vente additionnelle, des campagnes de stimulation de l'utilisation, des programmes de fidélité, etc.

Lorsque chaque campagne est considérée isolément et que tous les clients reçoivent des scores[3] de réponse pour chaque campagne, il en résulte qu'un groupe de clients similaire obtient des scores élevés pour de nombreuses campagnes. Certains clients sont simplement plus réactifs que d'autres, un fait qui se reflète dans les scores du modèle. Cette approche conduit à une mauvaise gestion de la relation client. Le groupe qui obtient les meilleurs résultats est bombardé de messages et devient irrité et insensible. Tandis que, les autres clients n'entendent jamais parler de la société et ne sont donc pas encouragés à développer leurs relations.

Une alternative consiste à envoyer un nombre limité de messages à chaque client, en utilisant les scores pour décider quels messages sont les plus appropriés pour chacun[21].

Même un client avec des scores bas pour chaque offre a des scores plus élevés pour certains que pour d'autres.

3.4.2 Segmentation de la clientèle

La segmentation de la clientèle est une application populaire d'exploration de données avec des clients établis. L'objectif de la segmentation est d'adapter les produits, les services et les messages marketing à chaque segment. Les segments de clientèle ont traditionnellement été basés sur des études de marché et des données démographiques. Le problème des segments basés sur des études de marché est qu'il est difficile de savoir comment les appliquer à tous les clients qui n'ont pas participé à l'enquête. Le problème avec les segments de clientèle basés sur la démographie est de ne pas avoir les goûts et les affinités des produits attribués à leur segment. L'approche d'exploration de données consiste à identifier des segments comportementaux[21].

[3] https://www.definitions-marketing.com/definition/scoring/

3.4.2.1 Trouver des segments comportementaux

Plus généralement, une entreprise souhaite effectuer une segmentation qui place chaque client dans un segment facile à décrire. Souvent, ces segments sont construits dans le respect d'un objectif marketing tel que le renouvellement de l'abonnement ou des niveaux de dépenses élevés. Les techniques d'arbre de décision sont idéales pour ce type de segmentation.

Un autre cas courant concerne la définition de segment préexistant basé sur le comportement du client et le défi de l'exploration de données consiste à identifier des modèles dans les données qui correspondent aux segments. Une application très intéressante de l'exploration de données à la recherche de modèles correspondant à des segments de clientèle prédéfinis pour décider si un téléphone est susceptible d'être utilisé à des fins professionnelles.

3.4.2.2 Lier des segments de recherche de marché aux données comportementales

L'un des grands défis des études de marché traditionnelles basées sur des enquêtes est qu'elles fournissent de nombreuses informations sur quelques clients. Cependant, pour utiliser efficacement les résultats des études de marché, il faut souvent comprendre les caractéristiques de tous les clients. C'est-à-dire que les études de marché peuvent trouver des segments intéressants de clients. Celles-ci doivent ensuite être projetées sur la clientèle existante à l'aide des données disponibles. Les données comportementales peuvent être particulièrement utiles à cet égard, ces données comportementales sont généralement résumées à partir d'historiques de transactions et de facturation. Une des exigences de l'étude de marché est que les clients doivent être identifiés de manière à ce que le comportement des participants à l'étude de marché soit connu[21].

La plupart des techniques d'exploration de données supervisé peuvent être utilisées pour créer un modèle de classification permettant d'affecter des personnes à des segments en fonction des données disponibles. Il suffit de former un groupe de clients déjà classés. Son efficacité dépend en grande partie du degré de prise en charge du comportement des segments de clientèle[21].

4 Conclusion

L'exploration de données est utilisée à la fois en publicité et en marketing direct pour identifier le bon public, choisir les meilleurs canaux de communication et choisir les messages les plus appropriés.

L'analyse du comportement des clients est l'une des applications du DM. Les données disponibles pour les clients actifs sont plus riches que celles disponibles pour les prospects et,

comme elles sont de nature comportementale plutôt que simplement géographiques et démographiques, elles sont plus prédictives. L'exploration de données est utilisée pour identifier les produits et services supplémentaires qui devraient être proposés aux clients en fonction de leurs modèles d'utilisation actuels.

L'un des objectifs d'un programme de gestion de la relation client est de fidéliser des clients précieux. L'exploration de données peut aider à identifier les clients les plus précieux et à évaluer le risque de désabonnement volontaire ou involontaire associé à chaque client. Armées de ces informations, les entreprises peuvent cibler les offres de rétention sur les clients à la fois précieux et à risque et prendre des mesures pour se protéger des clients susceptibles de faire défaut.

CHAPITRE IV : CONCEPTION ET MISE EN ŒUVRE DE LA SOLUTION

1 Introduction

Après avoir fait un tour d'horizon des techniques de data mining qui existent dans la littérature, et son apport au domaine marketing, nous allons entamer dans ce chapitre, la conception des différentes parties de notre système.

Dans ce chapitre on va analyser l'ensemble des besoins de notre projet, et la méthodologie de conception de data mining que nous avons suivie.

Ensuite, nous allons décrire notre solution d'une façon globale, en détaillant chaque phase de celle-ci, et nous terminons ce chapitre en décrivant l'aspect sécurité de notre système.

2 Analyse des besoins

L'étude des besoins est une phase vitale dans tout projet. En effet, elle vise à identifier les différentes attentes et exigences exprimées par les utilisateurs finaux afin de pouvoir comprendre leurs besoins et concevoir la solution adéquate.

2.1 Définition des besoins

Nous allons présenter dans cette section, ces besoins ainsi que les différents cas d'utilisations selon le point de vue de chaque utilisateur.

2.1.1 Besoins fonctionnels

Dans ce qui suit, nous présentons les besoins fonctionnels de notre solution, selon deux volets :

2.1.1.1 L'analyse du comportement des clients

Le volet analyse du comportement des clients, comporte trois analyses :

- L'analyse des consommations : Cette analyse nous permet d'étudier le comportement des clients à travers leurs consommations et cela en termes de revenus et de trafic générés ;
- L'analyse des souscriptions : Cette analyse nous permet d'étudier le comportement des clients à travers les souscriptions qu'ils effectuent et cela en termes de revenus et de nombre d'acquisition de ces souscriptions ;
- L'analyse de churn (perte des clients) : cette analyse nous permet de prédire les clients qui sont susceptibles de quitter l'entreprise en termes de désabonnement afin

de pouvoir agir et les cibler avec des offres personnalisées avant que cela ne se produise.

2.1.1.2 La visualisation des résultats d'analyses

La solution conçue doit permettre de :

- Fournir, aux utilisateurs finaux du système, des rapports visuels, relatifs aux différents résultats de l'analyse du comportement des clients ;
- Interagir avec des tableaux de bord interactifs ;
- Effectuer des campagnes marketing personnalisées.

2.1.2 Besoins techniques

En plus des besoins fonctionnels, le système conçu doit respecter certaines exigences techniques imposées par l'entreprise. De ce fait, les critères suivants ont été recensés :

- L'outil de visualisation doit être programmé en tant qu'application web.
- Le tableau de bord doit être hébergé dans un serveur local.
- Tous les outils utilisés doivent être gratuits.
- Le système doit être compatible avec les systèmes d'exploitation Windows et Linux.

2.2 Définition des cas d'utilisation

Le cas d'utilisation est un moyen permettant de structurer les besoins des utilisateurs liés au système. Ils permettent de classer les acteurs et structurer les objectifs du système.

Dans le cadre de notre projet, nous organisons les cas d'utilisations selon quatre points de vue : celui du développeur, du décideur, de l'analyste et de l'administrateur du système qui sont les utilisateurs principaux de notre système.

Nous allons détailler ces cas d'utilisations dans ce qui suit :

2.2.1 Vue Décideur

Les décideurs accèdent au système d'un point de vue présentation, et peuvent consulter les indicateurs, les rapports, les notifications mais ils peuvent aussi créer un rapport et personnaliser un graphique en appliquant un filtre ou en modifiant un paramètre. La figure ci-dessous, résume les cas d'utilisations des décideurs.

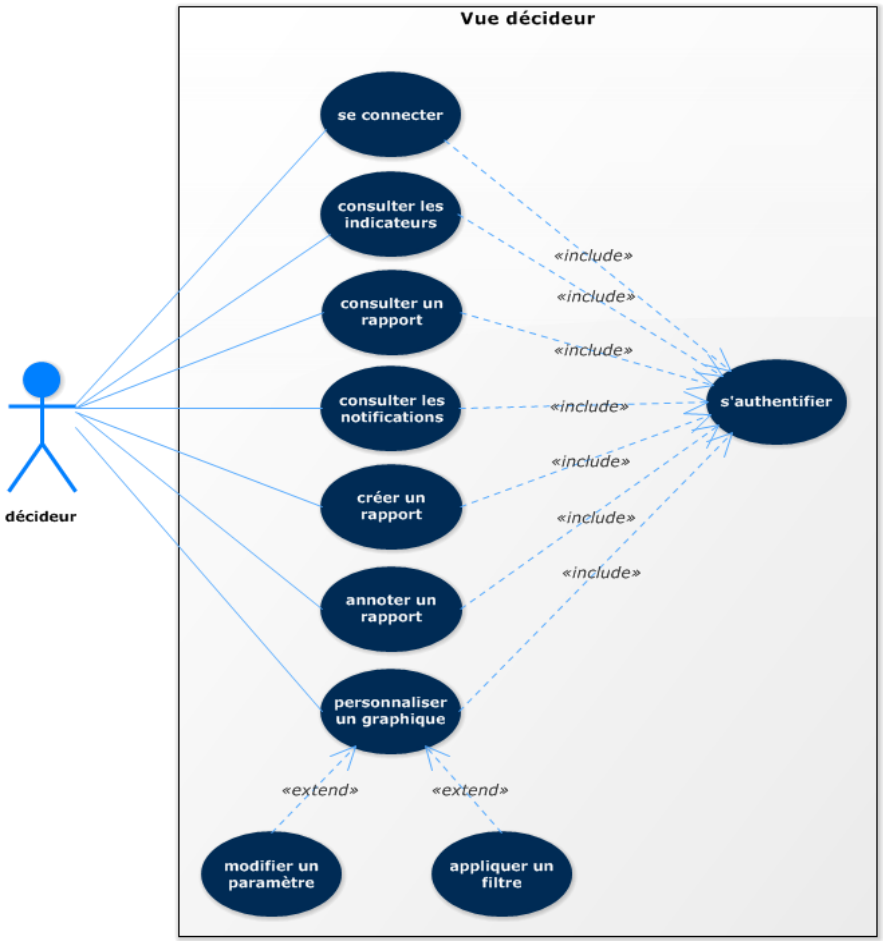

Figure IV-1 : *Diagramme des cas d'utilisations : vue décideur*

Dans ce qui suit, nous allons documenter quelques cas d'utilisations que nous appuyons, selon le besoin, par des diagrammes d'activités permettant de mieux comprendre l'enchaînement logique.

Tableau IV-1 : *Liste des cas d'utilisation du décideur*

ID	CU	Documentation	Diagramme d'activité
1	S'authentifier		
2	Se connecter		
3	Consulter les indicateurs	✓	
4	Consulter un rapport		
5	Consulter une notification		
6	Personnaliser graphique		
7	Modifier paramètre	✓	✓
8	Appliquer un filtre		

- **Cas d'utilisation : Consulter un indicateur**

Tableau IV-2 : *Documentation CU : Consulter indicateur*

CU : Consulter un indicateur
ID : 3
Description brève : consulter les indicateurs selon la répartition proposée.
Acteurs primaires : Administrateurs, Décideurs, Analystes
Acteurs secondaires : Serveur d'application
Pré condition : Utilisateur est déjà connecté
Enchainement principal : Ce cas commence lorsqu'un utilisateur souhaite consulter un ou plusieurs indicateurs. 1- L'utilisateur choisit la catégorie de l'indicateur. 2- Le serveur affiche les valeurs des différents indicateurs de la catégorie choisie. 3- L'utilisateur choisit l'option « plus de détails » pour l'indicateur souhaité. 4- Le serveur traite la table et le graphe d'évolution de l'indicateur choisi selon les paramètres choisis.
Post conditions : le détail de l'indicateur est affiché avec le graphe de son évolution selon les paramètres choisis.
Enchainement alternatif : E1 : la liste des indicateurs ne s'affiche pas.

- **Cas d'utilisation : Modifier un paramètre**

Tableau IV-3 : *Documentation CU : Modifier paramètre*

CU : Modifier un paramètre
ID : 7
Description brève : modifier le paramètre d'un graphique.
Acteurs primaires : Administrateurs, Décideurs, Analystes
Acteurs secondaires : Serveur d'application
Pré condition : Utilisateur est déjà connecté
Enchainement principal : Ce cas commence lorsqu'un utilisateur souhaite modifier un paramètre. 1- L'utilisateur choisit le paramètre à modifier. 2- Il insère ensuite la valeur du paramètre. 3- Si la valeur insérée est valide, le paramètre est modifié. 4- Sinon une erreur s'affiche et l'utilisateur doit réinsérer la valeur du paramètre.
Post conditions : le graphique mis à jour avec la nouvelle valeur du paramètre est affiché.

Enchainement alternatif :
/

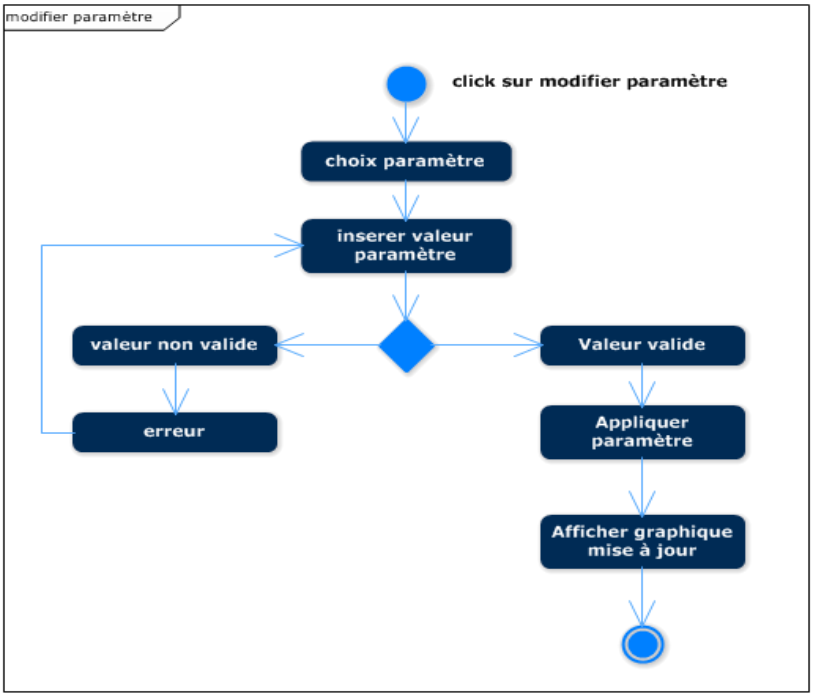

Figure IV-2 : *Diagramme d'activité du CU : Modifier paramètre*

2.2.2 Vue Développeur

Nous rappelons, que le développeur est la personne qui se charge d'une part, d'importer les données, les transformer puis les charger dans une base de données. Et d'autre part, il s'occupe de l'implémentation des modèles de Data mining dans le cadre de l'analyse du comportement client. La figure IV-3, présente les cas d'utilisations propre au développeur.

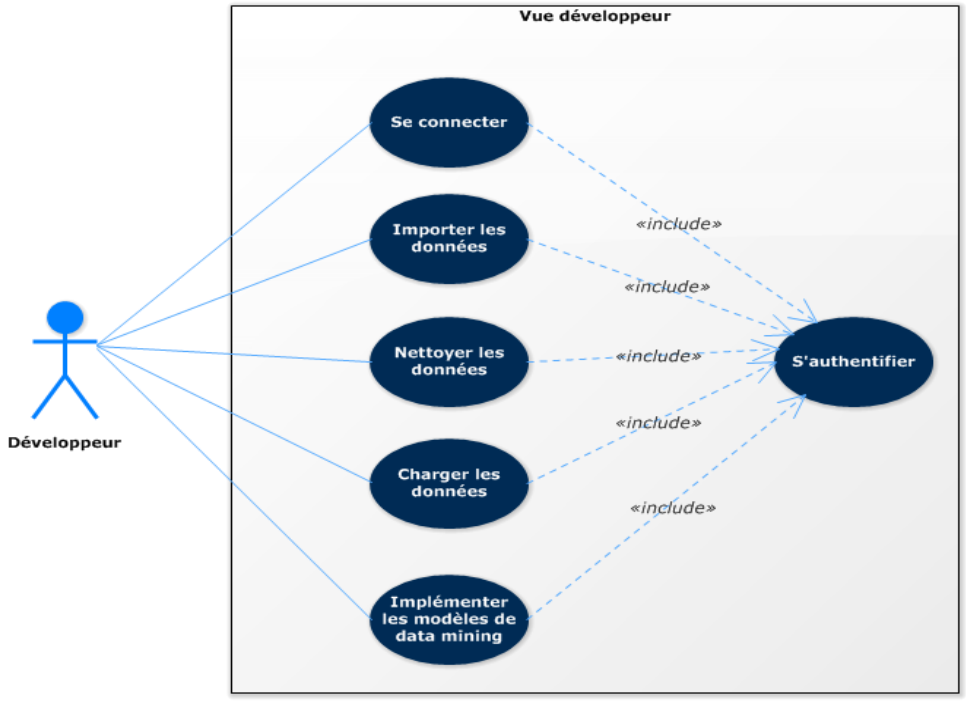

Figure IV-3 : *Diagramme des cas d'utilisations : vue développeur*

Dans ce qui suit, nous allons documenter quelques cas d'utilisations que nous appuyons, selon le besoin, par des diagrammes d'activités permettant de mieux comprendre l'enchaînement logique.

Tableau IV-4 : *Liste des cas d'utilisation du développeur*

ID	CU	Documentation	Diagramme d'activité
9	S'authentifier		
10	Se connecter		
11	Importer les données	✓	
12	Transformer les données		
13	Charger les données		
14	Implémenter les modèles de data mining	✓	✓

- **Cas d'utilisation : Importer les données**

Tableau IV-5 : *Documentation CU : Importer les données*

CU : Importer les données
ID : 11
Description brève : Importer les données à partir de différentes sources de données.
Acteurs primaires : Développeur

Acteurs secondaires : /
Pré condition : Utilisateur est déjà connecté
Enchainement principal : Ce cas commence lorsqu'un utilisateur souhaite importer des sources de données. 1- L'utilisateur accède à la source de données. 2- Il choisit la source à importer. 3- Puis, il importe les données nettoyées et transformées.
Post conditions : les données ont été importées.
Enchainement alternatif : E3 : La source n'a pas été importée.

2.2.3 Vue Analyste

L'analyste doit préparer le terrain pour les décideurs. Il se charge de créer les indicateurs, les rapports, les filtres, les graphiques que les décideurs pourront consulter par la suite. La figure ci-dessous, résume les cas d'utilisations de l'analyste.

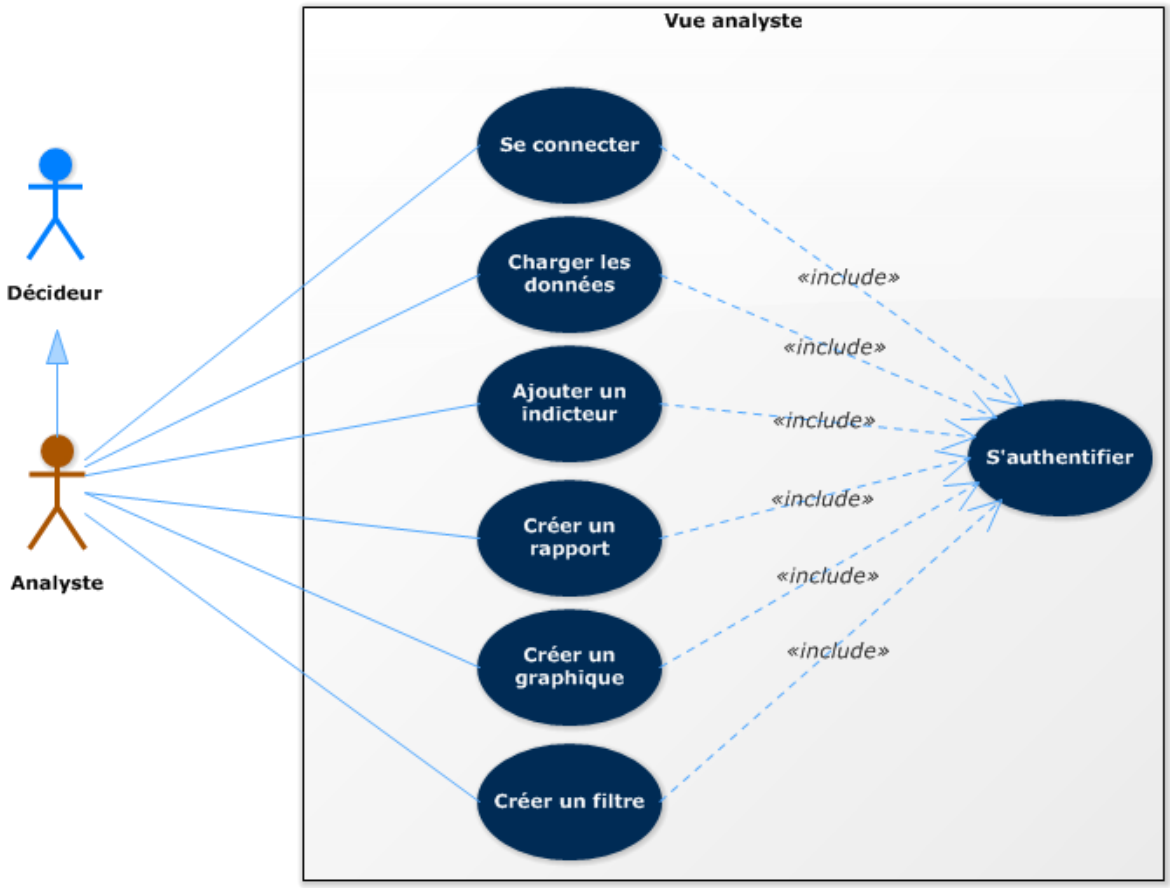

Figure IV-4 : *Diagramme des cas d'utilisation : vue analyste*

Dans ce qui suit, nous allons documenter quelques cas d'utilisations que nous appuyons, selon le besoin, par des diagrammes d'activités permettant de mieux comprendre l'enchaînement logique.

Tableau IV-6 : *Liste des cas d'utilisation de l'analyste*

ID	CU	Documentation	Diagramme d'activité
15	S'authentifier		
16	Se connecter		
17	Charger les données		
18	Ajouter un indicateur	✓	
19	Créer un rapport		✓
20	Créer un graphique	✓	
21	Créer un filtre		

- **Cas d'utilisation : Ajouter un indicateur**

Tableau IV-7 : *Documentation CU : Ajouter indicateur*

CU : Ajouter un indicateur
ID : 18
Description brève : Ajouter un nouvel indicateur.
Acteurs primaires : Administrateur, Analyste
Acteurs secondaires : Serveur d'application
Pré condition : Utilisateur est déjà connecté
Enchainement principal : Ce cas commence lorsqu'un utilisateur souhaite ajouter un nouvel indicateur. 1- L'utilisateur importe les données. 2- Puis, il choisit les champs sur lesquels il souhaite effectuer son calcul. 3- Il attribue un nom à l'indicateur avant d'insérer la formule de calcul. 4- Il choisit le type de graphique qu'il souhaite afficher 5- Et enfin, il valide sa création
Post conditions : Le nouvel indicateur est ajouté, et fait partie de la liste des indicateurs composants le tableau de bord.
Enchainement alternatif : E5 : L'indicateur n'est pas ajouté.

- **Cas d'utilisation : Créer un rapport**

Tableau IV-8 : *Documentation CU : Créer un rapport*

CU : Créer un rapport
ID : 20
Description brève : Créer un nouveau rapport.
Acteurs primaires : Administrateurs, Analystes, décideurs
Acteurs secondaires : Serveur d'application
Pré condition : Utilisateur est déjà connecté
Enchainement principal : Ce cas commence lorsqu'un utilisateur souhaite créer un nouveau rapport. 1- L'utilisateur accède aux données. 2- Il sélectionne les dimensions qu'il souhaite afficher. 3- Puis, il choisit le type du graphique (tableaux, graphe, …). 4- Enfin, il exporte le rapport
Post conditions : Le rapport est exporté.
Enchainement alternatif : /

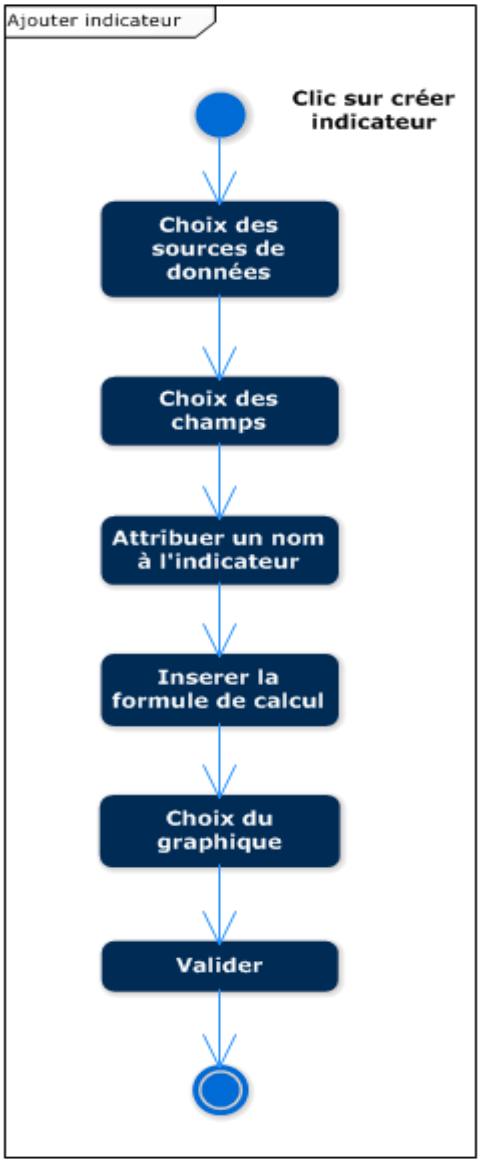

Figure IV-5 : *Diagramme d'activité du CU : Ajouter indicateur*

2.2.4 Vue Administrateur

L'administrateur gère les comptes utilisateurs, les droits d'accès au tableau de bord et il alloue les ressources aux groupes d'utilisateurs si nécessaire. La figure ci-dessous résume les cas d'utilisation de l'administrateur.

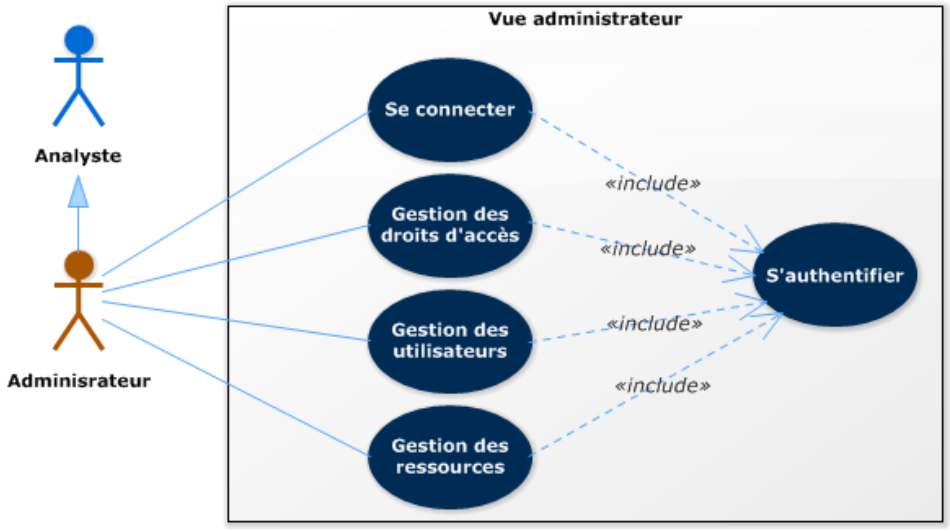

Figure IV-6 : *Diagramme des cas d'utilisations : Vue Administrateur*

Dans ce qui suit, nous allons documenter quelques cas d'utilisations que nous accompagnons d'un diagramme d'activité selon le besoin.

Tableau IV-9 : *Liste des cas d'utilisation de l'administrateur*

ID	CU	Documentation	Diagramme d'activité
22	S'authentifier		
23	Se connecter		
24	Gestion des droits d'accès		
25	Gestion des utilisateurs	✓	✓
26	Gestion des ressources	✓	

- **Cas d'utilisation : Gestion des utilisateurs**

Tableau IV-10 : *Documentation CU : Gestion des utilisateurs*

CU : Gestion des utilisateurs
ID : 25
Description brève : Ajouter un nouvel utilisateur.
Acteurs primaires : Administrateur
Acteurs secondaires : Serveur d'application
Pré condition : L'administrateur doit être connecté au serveur et il doit s'authentifier
Enchainement principal : Ce cas commence lorsqu'un utilisateur souhaite ajouter un nouvel utilisateur. 1- Il choisit l'option : gestion des utilisateurs. 2- Il clique sur ajouter un utilisateur.

3- Il saisit les informations de ce nouvel utilisateur. 4- Il attribue le nouvel utilisateur à un groupe 5- Il valide ses choix
Post conditions : Un nouvel utilisateur est créé.

- **Cas d'utilisation : Gestion des ressources**

Tableau IV-11 : *Documentation CU : Gestion des ressources*

CU : Gestion des ressources
ID : 26
Description brève : Attribuer des ressources à un groupe d'utilisateurs.
Acteurs primaires : Administrateur
Acteurs secondaires : Serveur d'application
Pré condition : L'administrateur doit être connecté au serveur et il doit s'authentifier
Enchainement principal : Ce cas commence lorsqu'un utilisateur souhaite attribuer des ressources à un groupe d'utilisateurs. 1- L'administrateur choisit un groupe d'utilisateurs. 2- Il sélectionne les ressources qu'il souhaite attribuer. 3- Puis, il attribue les ressources 4- Et enfin, il valide son choix
Post conditions : Les ressources ont été attribuées à un groupe d'utilisateurs.

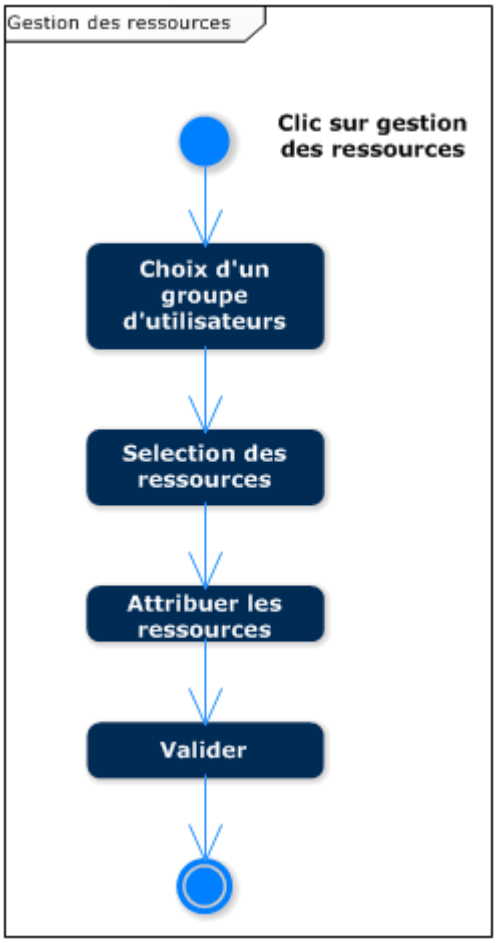

Figure IV-7 : *Diagramme d'activité du CU : Gestion des ressources*

2.3 Analyse du comportement du client

Un système d'analyse du comportement des clients doit permettre aux entreprises d'extraire des connaissances sur leurs clients. Ceci, en se basant sur l'étude des différentes données que possède l'entreprise sur ses clients, qu'elles soient démographiques (Age, Sexe, Occupation…) ou bien comportementales (consommations, recharges, trafic…).

A travers, l'étude et la compréhension du comportement de ces clients, On sera en mesure de les cibler, en leur proposant des offres personnalisées.

Le défi majeur dans ce projet est de recenser l'ensemble des besoins en termes d'analyse du comportement client et de pouvoir les prioriser selon leur importance métier et leur faisabilité technique.

Suite à notre démarche de collecte des besoins, et comme nous l'avons précisé lors de la définition des besoins dans la section précédente de ce chapitre, nous avons pu dégager trois

types d'analyses du comportement des clients : analyse de consommations, analyse de souscriptions et l'analyse de churn. A présent, nous allons détailler ces trois analyses.

2.3.1 Analyse des consommations des clients

L'analyse des consommations des clients est une analyse importante au sein de toute compagnie de télécommunication. Il s'agit d'analyser les consommations des abonnés en termes d'appels, internet et sms selon les quantités et les montants dans le but d'effectuer une segmentation des clients et obtenir des segments de clients ayant des comportements similaires en termes de consommations. Ceci permettra par la suite à l'entreprise de cibler chaque segment de clients avec des offres qui correspondent au mieux à leurs besoins.

La figure ci-dessous, présente les types de consommations clients.

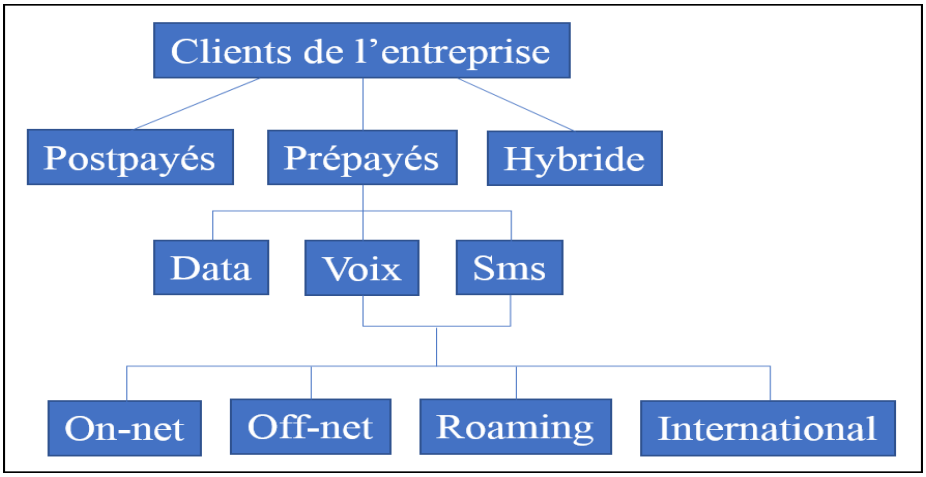

Figure IV-8 : *Les types de consommations client*

Dans le cadre de notre projet, il s'agira de :

- Analyser le nombre, la durée et le montant des appels mensuels ;
- Analyser le volume et le montant de consommation internet mensuelles ;
- Analyser le nombre et le montant des sms mensuels ;
- Analyser le montant total des consommations (appels, internet et sms).

2.3.2 Analyse des souscriptions des clients

L'analyse des souscriptions des clients à une offre est une analyse effectuée au sein d'une compagnie de télécommunication afin de mesurer le taux de souscriptions des clients à une offre proposée. Autrement dit, il s'agit d'effectuer une segmentation des clients et obtenir des segments de clients ayant des comportements similaires en termes de souscriptions. Ceci

permettra par la suite à l'entreprise de cibler chaque segment de clients avec des offres qui correspondent au mieux à leurs besoins.

La figure ci-dessous, présente les types de souscriptions disponibles au sein de l'entreprise.

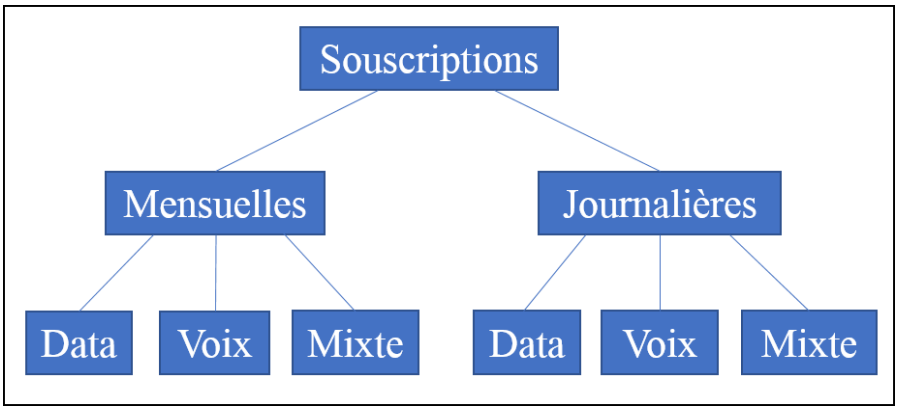

Figure IV-9 : *Les types de souscriptions*

Note : Souscription voix = souscriptions qui offre des minutes et sms gratuits.

Dans le cadre de notre projet, il s'agira de :

- Analyser le nombre et le montant des souscriptions voix journalières et mensuelles.
- Analyser le nombre et le montant des souscriptions mixte journalières et mensuelles.
- Analyser le nombre et le montant de souscriptions journalières et mensuelles d'appels et internet.

2.3.3 Analyse du churn des clients

Le Churn se traduit en français par attrition. Il exprime le taux de déperdition des clients pour une entreprise ou un produit. Le taux de churn représente donc le pourcentage de clients perdus, sur une période donnée (en général une année) par rapport au nombre total de clients. Ce terme est principalement utilisé dans les secteurs des télécommunications et bancaire pour mesurer la part de clients perdus ainsi que la fidélisation aux offres[22].

Le churn peut être divisé en deux principaux types, il peut être volontaire ou involontaire. Le churn volontaire est lié à une insatisfaction sur l'offre ou sur la qualité des services. Le churn involontaire est lié à des circonstances indépendantes de l'organisation (déménagement, décès…).

Le phénomène de churn volontaire des clients engendre une perte de revenue à l'entreprise, celle-ci vise alors à anticiper ce phénomène à travers la prédiction.

A travers l'analyse de churn, nous allons prédire :

- Le taux de churn des clients.
- Le taux de churn des clients prépayés.
- Le taux de churn des clients postpayés.
- Le taux de churn des clients hybride.

2.4 Indicateurs clés de performance

Un indicateur clé de performance est définie comme étant « une information devant aider un décideur, individuel ou plus généralement collectif, à conduire le cours d'une action vers l'atteinte d'un objectif ou devant lui permettre d'en évaluer le résultat. Il interagit avec trois composantes : les objectifs induits par la stratégie, les acteurs qui sont les destinataires des informations, et les actions mises en place par les acteurs pour l'atteinte des objectifs »[23].

En d'autres termes, les KPI constituent un ensemble de mesures concernant la performance de l'organisation, et que, en dépassant un certain seuil, alarmera l'utilisateur pour agir.

L'intérêt d'avoir des indicateurs de performance est que l'utilisateur ne consulte pas les données entières et les analyses pour pouvoir prendre une décision en temps réel, seuls les indicateurs les plus importants s'affichent sous forme d'un graphique.

Dans ce qui suit, nous allons présenter les indicateurs clés de performance pour chacune des trois analyses présentées ci-dessus.

2.4.1 Indicateurs de l'analyse des consommations des clients

Tableau IV-12 : *Indicateurs de l'analyse des consommations des clients*

Indicateur	Objectif
Taux de consommation voix	Permet de connaitre le taux de clients consommant des appels téléphoniques
Taux de consommation on-net	Permet de connaitre le taux de clients consommant des appels
Taux de consommation off-net	Permet de connaitre le taux de clients consommant des appels vers les autres opérateurs

Taux de consommation international	Permet de connaitre le taux de clients consommant des appels vers l'international
Taux de consommation roaming	Permet de connaitre le taux de clients consommant des appels roaming
Taux de consommation Data	Permet de connaitre le taux de clients consommant de la data (internet)
Taux de consommation sms	Permet de connaitre le taux de clients consommant les sms

2.4.2 Indicateurs de l'analyse des souscriptions

Tableau IV-13 : *Indicateurs de l'analyse des souscriptions des clients*

Indicateur	Objectif
Taux de souscriptions journalières	Permet de connaitre le taux de clients qui ont effectué des souscriptions journalières.
Taux de souscriptions mensuelles	Permet de connaitre le taux de clients qui ont effectué des souscriptions mensuelles.
Taux de souscriptions voix journalières	Permet de connaitre le taux de clients qui ont effectué des souscriptions d'appels journalières
Taux de souscriptions data journalières	Permet de connaitre le taux de clients qui ont effectué des souscriptions d'internet journalières
Taux de souscriptions mixte journalières	Permet de connaitre le taux de clients qui ont effectué des souscriptions mixte journalières
Taux de souscriptions voix mensuelles	Permet de connaitre le taux de clients qui ont effectué des souscriptions d'appels mensuelles
Taux de souscriptions data mensuelles	Permet de connaitre le taux de clients qui ont effectué des souscriptions d'internet mensuelles
Taux de souscriptions mixte mensuelles	Permet de connaitre le taux de clients qui ont effectué des souscriptions mixtes mensuelles

2.4.3 Indicateurs de l'analyse de churn

Tableau IV-14 : *Indicateurs de l'analyse de churn des clients*

Indicateur	Objectif
Taux de churn des clients	Permet de connaitre le taux de clients susceptibles de churner
Taux de churn des clients prépayée	Permet de connaitre le taux de clients prépayée susceptibles de churner
Taux de churn des clients postpayée	Permet de connaitre le taux de clients postpayée susceptibles de churner
Taux de churn des clients hybrides	Permet de connaitre le taux de clients hybride susceptibles de churner

3 Méthodologie de conception de Data mining

Nous rappelons que notre solution doit permettre aux utilisateurs finaux d'analyser le comportement de leurs clients à travers des indicateurs clés de performance relatifs aux analyses défini lors de la collecte des besoins dans le but d'améliorer l'efficacité des campagnes marketing par un ciblage personnalisé des clients. Cette solution sera axée principalement sur des modèles de Data Mining. Pour le faire, nous avons choisi d'appliquer une démarche de conception de Data mining afin de mieux structurer notre projet.

Il existe des méthodologies connues qui sont utilisées dans les projets de data mining. Nous citons : la méthode CRISP-DM (Cross Industry Standard Process for Data Mining) et la méthode SEMMA (Sample, Explore, Modify, Model, Assess).

Après une étude comparative entre ces deux méthodes (présente à l'annexe A), nous avons opté pour la méthode CRISP-DM. Dans ce qui suit, nous allons décrire cette méthode.

3.1 La méthode CRISP-DM

Le concept CRISP-DM est une méthodologie qui consiste à définir un cadre pour la conduite de projets de data mining. Cette méthodologie a été mise au point en 1996 par trois pionniers dans le domaine du data mining, grâce aux travaux de Daimler, Chrysler et Benz [24].

La méthode CRISP-DM se compose de six étapes permettant de structurer le travail et de l'ancrer dans un processus industriel ; plus qu'une théorie normalisée, c'est un processus d'extraction des connaissances métiers. La méthode CRISP-DM est itérative, un retour en

arrière vers une étape précédente est nécessaire. Le détail des six étapes est présenté à l'annexe A.

La figure ci-dessous, illustre les six étapes de la méthode CRISP-DM et les relations qui réside entre elles.

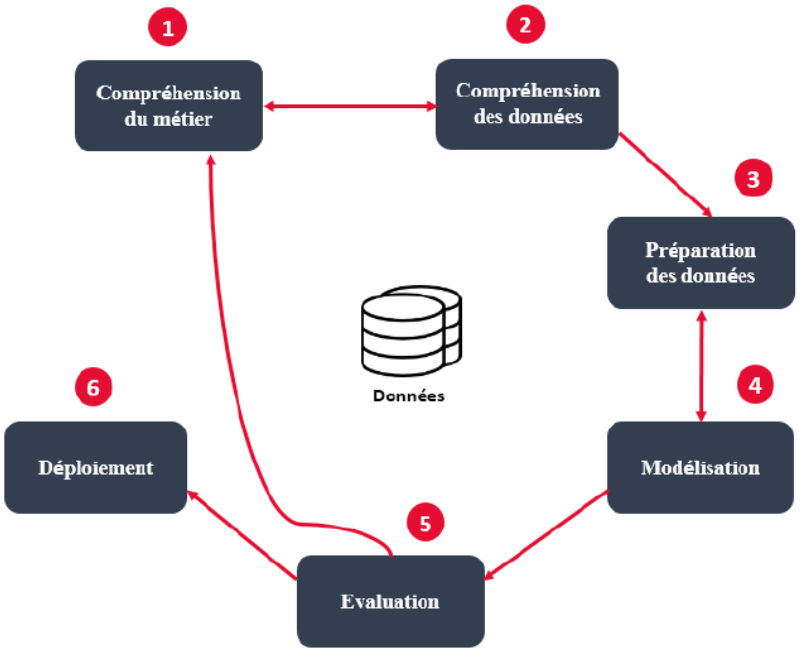

Figure IV-10 : Méthode CRISP-DM

Dans la suite de ce chapitre, nous serons amenés à appliquer ces six étapes dans la conception des différentes parties qui composent notre solution.

3.2 Description de la solution

Nous allons présenter dans cette section l'architecture globale proposée pour notre système. Pour ce faire, nous allons l'illustrer par le schéma ci-dessous que nous accompagnons d'une description de chaque composant.

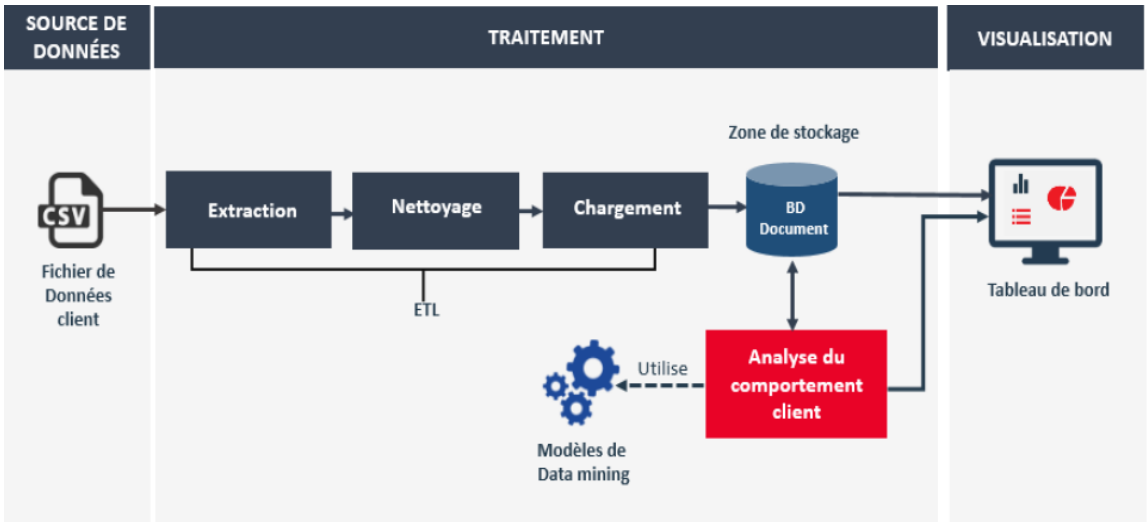

Figure IV-11 : *Architecture globale de la solution*

Le processus général du système passe par plusieurs étapes, chaque étape fait appel à des traitements particuliers. Les phases du processus sont présentées comme suit :

- Extraction des données ;
- Nettoyage des données ;
- Chargement des données dans une base de données orienté document ;
- Analyse du comportement client en utilisant les modèles de Data mining ;
- Visualisation.

La phase d'extraction des données récupère les données à partir de sources de données, dans notre cas, il s'agit de fichiers de format .csv contenant les informations relatives aux clients.

Par la suite, nous passons à la phase de nettoyage, où nous préparons les données pour qu'elles soient exploitées lors de l'analyse du comportement client, en effectuant des transformations sur ces données tel que l'élimination des champs vides et des doublons, l'unification des types de données, etc.

Une fois les données nettoyées, nous passons à la phase de chargement des données dans une base de données orientée document.

Dans une BDD orienté documents, les données sont organisées en collections de documents. La structure des documents est définie par l'intermédiaire d'attributs. Nous distinguons deux types d'attributs : les attributs simples dont les valeurs sont atomiques et les attributs composés dont les valeurs sont elles-mêmes des documents appelés documents imbriqués[25].

Les données étant nettoyées et chargées dans la base de données, nous pouvons à présent passer à la phase d'analyse du comportement client. Cette analyse est effectuée à l'aide de modèles de Data mining. En appliquant ces modèles sur les données présentes dans la base de données, nous aboutirons à des résultats qui nous serons utiles dans la compréhension du comportement. De plus, nous pouvons automatiser le processus de Data mining, en mettant en place un mécanisme de recommandation des algorithmes. Ainsi, pour chaque chargement de données, nous obtiendrons le résultat d'un algorithme optimal qui dépend uniquement des données chargées, ce résultat sera stocké dans notre base de données et sera accessible pour la phase de visualisation.

La dernière phase du processus de notre système est celle de la visualisation ou nous allons visualiser les résultats de l'analyse du comportement client en se basant sur des indicateurs clés de performances. Par exemple, nous pouvons visualiser les indicateurs relatifs aux taux de consommations des clients aux appels téléphoniques, à internet et sms.

A présent, nous allons procéder à la conception des phases que nous venons de présenter, pour ce faire, nous avons divisé cette conception en cinq sections principales.

3.3 Nettoyage des données

La phase de nettoyage des données correspond à l'étape trois de la méthodologie CRISP-DM, qui consiste en la transformation des données brutes, récupérées à partir des sources de données, en des données prêtes à être analyser (comme illustré au niveau de la figure ci-dessous).

Figure IV-12 : *phase de nettoyage des données*

Afin d'effectuer le nettoyage des données, nous allons utiliser le mécanisme de l'ETL (relatif aux phases : Extraction, Transformation et Chargement). Il s'agit d'abord d'accéder aux sources de données afin d'identifier, et de récupérer les données utiles. Par la suite, les données doivent être vérifiées, reformatées et nettoyées afin d'éliminer les valeurs aberrantes et les

doublons. Enfin, les données sont insérées dans la base de données, et seront ainsi disponibles pour les analyses de Data mining (comme illustré au niveau de la figure IV-12).

Dans ce qui suit, nous décrivons la démarche suivie lors de la réalisation des trois étapes de l'ETL : Extraction, transformation et chargement des données.

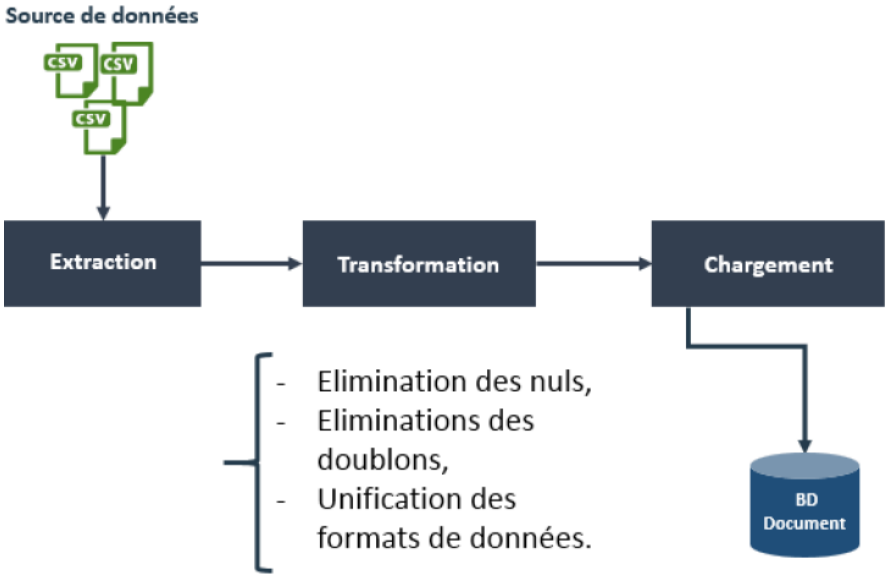

Figure IV-13 : *Processus ETL*

3.3.1 Identification des sources de données

Avant d'aller plus loin dans la description du processus de l'ETL, nous devons identifier les sources de données sur lesquels opère notre système. Dans le cadre de ce projet de fin d'études, nos sources de données, comme nous l'avons présenté dans les chapitres précédents, sont des fichiers de format csv.

3.3.2 Extraction de données

Comme nous venons de le citer, nos sources de données sont des fichiers de données qui concernent le client. Il s'agira dans cette partie, d'extraire les données à partir de cette source de données pour ainsi les charger dans notre base de données après avoir effectué les traitements nécessaires.

3.3.3 Transformation des données

Afin de garantir une bonne transformation des données à la base de données, une stratégie de traitement a été élaborée et qui se résume dans les points suivants :

- **Traitement des champs vides et nuls** : les champs vides ou nuls présents au sein de la source de données peuvent fausser nos analyses. Par conséquent, nous devons les éliminer et remplacer leurs champs par des valeurs valides.

- **Elimination des doublons** : il s'agit d'éliminer les doublons d'identifiants que nous pouvons trouver dans la source de données.
- **Unification des types de données** : il s'agit d'unifier les types de données afin de faciliter les analyses. Par exemple, dans l'attribut « sexe », nous pouvons définir deux valeurs possibles « H » pour homme et « F » pour femme.

3.3.4 Chargement des données

Une fois les données traitées, nous pouvons les charger dans notre base de données NoSQL. Les données sont chargées dans une collection de documents de format JSON. Les documents représentent les clients et contiennent toutes les informations relatives au client.

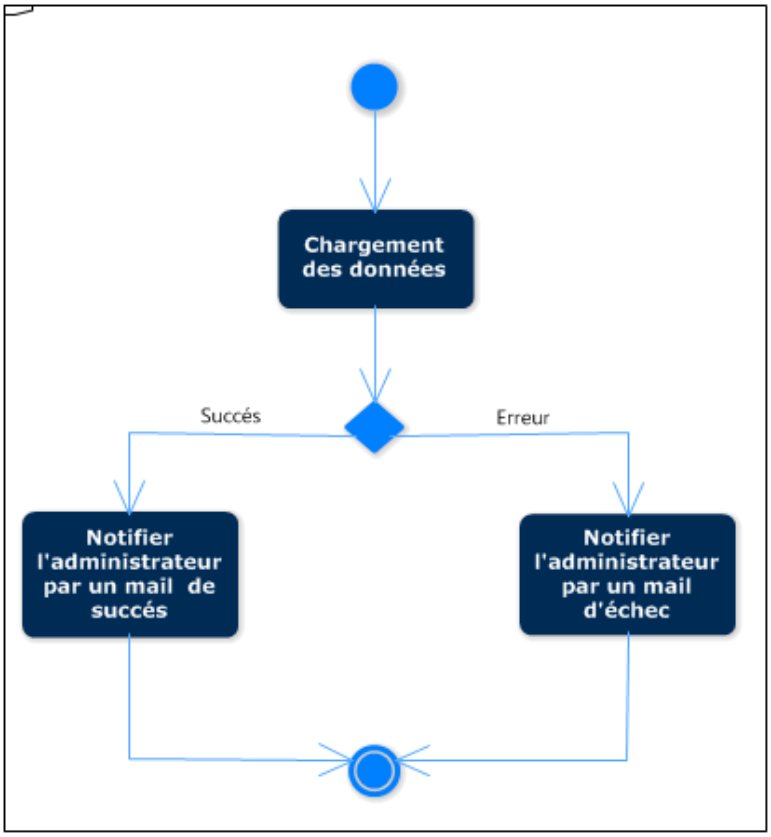

Figure IV-14 : *Processus de chargement des données*

Note : Les chargements des données seront planifiés d'une façon automatique, et une fois le chargement effectué, l'administrateur sera notifié par email.

3.4 Stockage des données

Durant la phase précédente, nous avons parlé du chargement des données nettoyées, relatives aux clients dans une base de données. Dans cette section, nous allons décrire en détail le type de cette base de données.

La zone de stockage, utilisée dans le cadre de ce projet, est une base de données non relationnelle (NoSQL) orientée documents, il s'agit donc de modéliser les données non sous forme relationnelles SQL (comme on peut le voir dans la figure) mais sous formes de documents de format JSON[4].

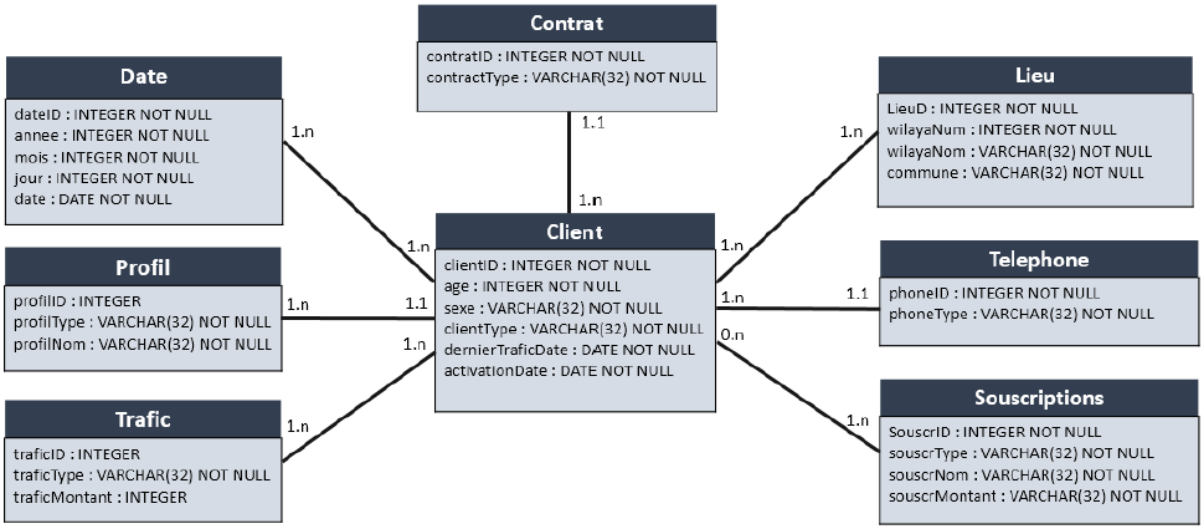

Figure IV-15 : *Exemple de schéma de la base de données SQL*

Le choix d'une base de données NoSQL a été adopté pour les différents avantages que présente celui-ci pour notre solution, notamment :

- La flexibilité en termes d'ajouts de nouvelle source de données, par exemple, dans le cas, ou on souhaite enrichir le modèle d'analyse de comportement client en incluant des données sociales, le NoSQL sera très bien adapté.
- Dans notre projet, nous avons beaucoup de lecture et très peu d'écriture. Avec l'absence de jointure, le NoSQL présente une bonne performance en ce qui concerne les lectures.
- Le NoSQL gère de grande taille de source de données.
- Il gère aussi d'une façon efficace, les données non structurées et semi-structuré.

Une base de données NoSQL est composée de plusieurs collections. Chaque collection comporte un ensemble de documents (les collections sont analogues aux tables dans les bases de données SQL). Les documents dans une collection n'ont pas une structure statique. En

[4] JSON est un format léger d'échange et de stockage de données. Il est décrit par la RFC7159 (http://tools.ietf.org/html/rfc7159).

d'autres termes dans une même collection nous pouvons avoir plusieurs documents avec des schémas différents[25].

Nous optons pour le modèle dénormalisé pour la modélisation logique des clients qui est le plus adapté dans notre cas. Ceci est dû au fait que le modèle normalisé nécessite souvent l'utilisation des jointures qui impliquent un coût supplémentaire pour l'agrégation dégradant par conséquent les performances du système.

La figure IV-15 décrit le modèle logique d'un document client, comportant les données démographiques du client ainsi que des tableaux contenant les données de leurs consommations, de trafic et de souscriptions.

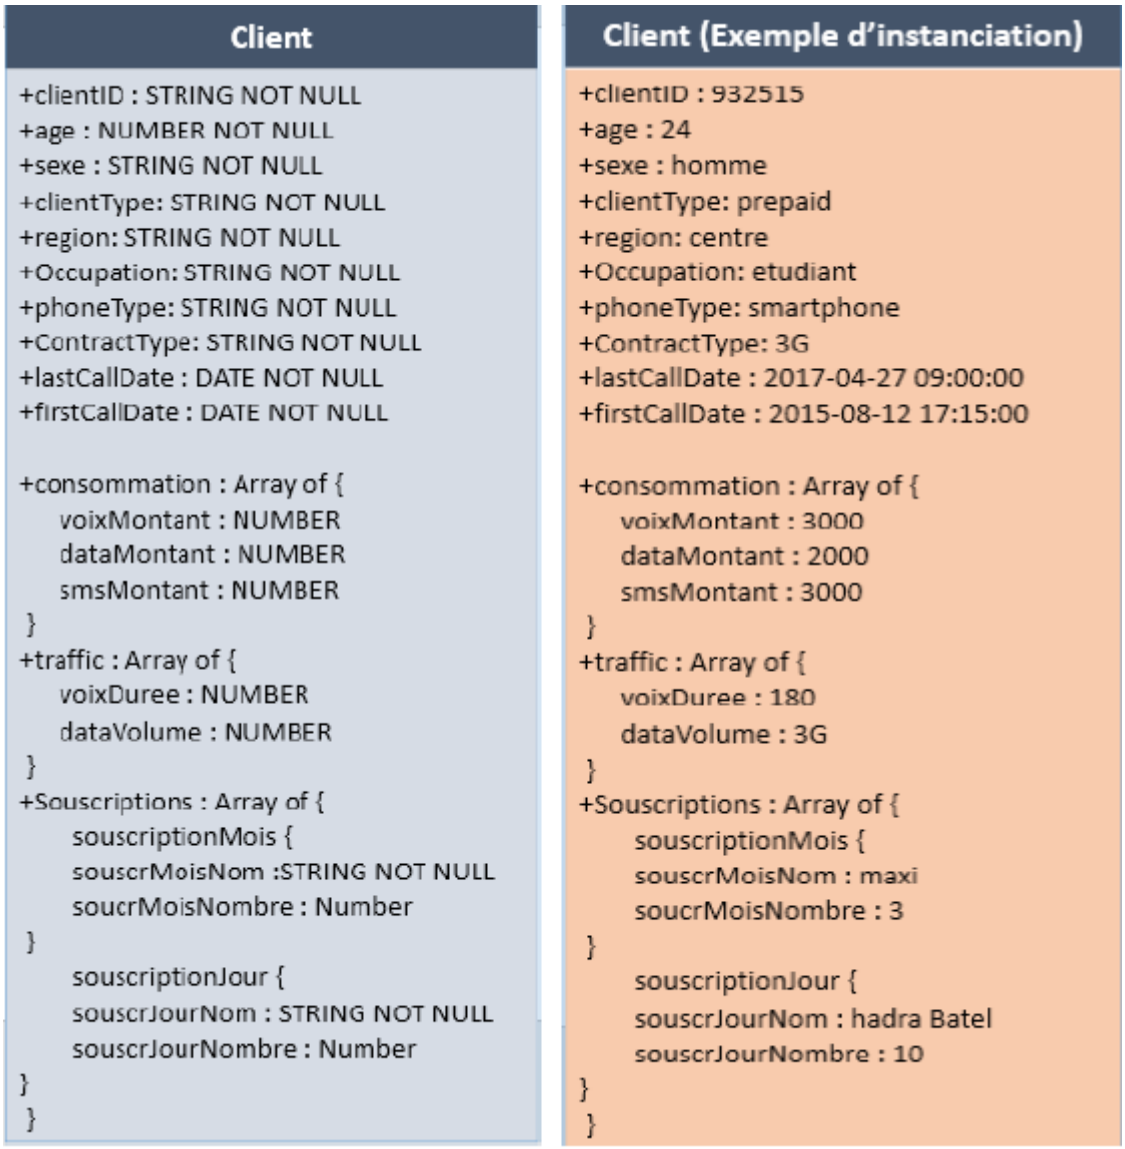

Figure IV-16 : *structure d'un document de la collection client*

3.5 Module d'analyse du comportement client

Nous arrivons au cœur de notre travail, où nous allons procéder à la construction du modèle d'analyse du comportement client. Mais avant cela, nous devons identifier les types de modèles de data mining que nous devrons utiliser à cet effet.

Suivant l'étude bibliographique, que nous avons effectué dans le deuxième chapitre de ce mémoire, et aux résultats de l'analyse des besoins présenté dans ce chapitre, nous sommes arrivés à identifier les types de data mining que nécessite notre solution, à savoir :

- **Le clustering :** le modèle de clustering est adapté aux analyses de consommations et de souscriptions des clients (défini lors de l'analyse des besoins), dans le but d'effectuer une segmentation des clients par rapport aux revenues de consommations, au trafic et au nombre, type et montant des souscriptions. Le résultat de cette segmentation nous permettra d'obtenir des segments de clients ayant des caractéristiques communes, qu'on pourra par la suite cibler avec des offres personnalisées.
- **La prédiction :** tandis que le modèle prédictif est adapté à l'analyse de churn des clients (défini lors de l'analyse des besoins) dans le but de prédire le comportement des clients qui ont l'intention de quitter (devenir non client de l'entreprise) prochainement. Cette information permettra à l'entreprise d'anticiper et d'éviter le churn de ces clients en les ciblant avec des offres personnalisées.

A présent, nous pouvons entamer la construction de ces deux modèles :

3.5.1 Modèle de clustering

Pour mieux cibler sa clientèle lors de la proposition des offres, l'entreprise souhaite avoir une segmentation des abonnés en k clusters, tel que k est le nombre d'offres à proposer. Le modèle à concevoir et à réaliser doit permettre donc d'avoir un partitionnement des utilisateurs en k ensemble(s) par rapport aux consommations et souscriptions des clients et ainsi lister l'ensemble des caractéristiques de chaque cluster.

Le diagramme d'activité ci-dessous, illustre les étapes du processus du modèle de clustering. L'étape de nettoyage a été présenté dans la section 3 de ce chapitre. Nous pouvons à présent passer à la construction de notre modèle de clustering.

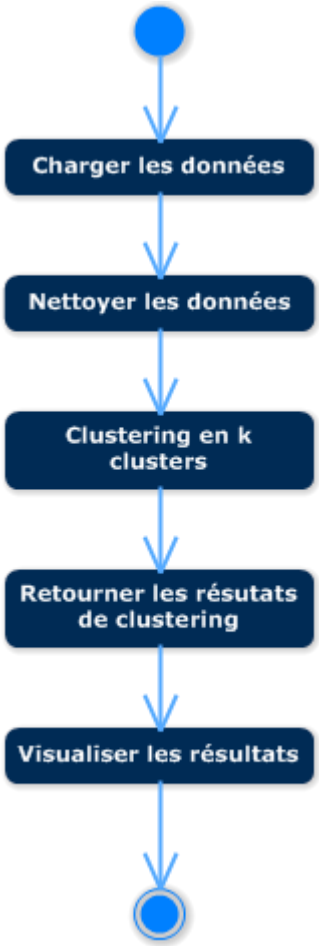

Figure IV-17 : *Diagramme d'activité qui illustre le processus de clustering*

Afin de concevoir notre modèle de clustering, nous devons suivre un certain nombre d'étapes que nous allons présenter dans ce qui suit.

3.5.1.1 Sélection des attributs

Après avoir étudier les besoins des analyses à effectuer et pris connaissance, dans la littérature, des types d'attributs utilisés au sein des compagnies de télécommunication. Nous avons pu effectuer une sélection des attributs clients disponibles au niveau de notre source de données. Le tableau ci-dessous, présente les attributs sélectionnés pour chacune de nos deux analyses.

Tableau IV-15 : *les attributs sélectionnés pour le clustering*

Attributs sélectionnés		
Analyse de consommation		**Analyse de souscriptions**
Revenu voix	Durée voix	Type de souscriptions
Revenu data	Volume data	Nom de la souscription
Revenu sms	Nombre sms	Montant de la souscription

3.5.1.2 Analyse de corrélation

Après avoir sélectionné les attributs, nous allons à présent, effectuer une analyse de corrélation entre ces attributs afin d'identifier d'éventuelles dépendances entre eux, et ceci en utilisant une matrice de corrélation.

Une matrice de corrélation est utilisée pour évaluer la dépendance entre plusieurs variables en même temps. Le résultat est une table contenant les coefficients de corrélation entre chaque variable et les autres.

Il existe différentes méthodes de test de corrélation : le test de corrélation de Pearson, la corrélation de Kendall et de Spearman (voir annexe C).

3.5.1.3 Choix des algorithmes

Dans cette partie, il s'agira de tester des algorithmes de clustering sur un échantillon de clients pour pouvoir choisir, après l'étape de l'évaluation, celui qui fournit les meilleurs résultats concernant nos analyses.

Nous avons sélectionné trois algorithmes de clustering à tester :

1. K-means

La méthode des k-means (ou k-moyennes en français) est une méthode de partitionnement de données introduite par MacQueen en 1967, dont le but est de former des sous-ensembles des individus appelés partitions tel que les individus formant chaque partition soit le plus proches possible.

Pour comprendre le fonctionnement de l'opération de partitionnement nous donnons le pseudo-algorithme de la méthode K-means :

Etant donné k le nombre de clusters qu'on veut obtenir :

1. Choisir k points centroïdes initiaux (au hasard par exemple).
2. Répéter tanque la distance entre les points et les centroïdes ne sont pas minimisée :
   a) Former k clusters en affectant chaque point à la partition avec le centroïde le plus Proche.
   b) Calculer les nouveaux centroïdes.

Sortie : Une partition des individus caractérisée par les K centroïdes

2. La classification ascendante hiérarchique (C.A.H)

La classification ascendante hiérarchique (CAH) est une méthode de classification itérative. Elle est dite ascendante car elle part d'une situation où tous les individus sont seuls dans une classe, puis sont rassemblés en classes de plus en plus grandes. Le qualificatif hiérarchique vient du fait qu'elle produit une hiérarchie. Nous donnons ci-dessous, le pseudo-algorithme de la méthode CAH :

Initialisation : les classes initiales sont les n singletons individus.

1. Calculer la matrice de leurs distances deux à deux
2. Itérer les deux étapes suivantes jusqu'à l'agrégation en une seule classe :
   a) Regrouper les deux éléments (classes) les plus proches au sens de la distance entre groupes choisie
   b) Mettre à jour le tableau de distances en remplaçant les deux classes regroupées par la nouvelle et en calculant sa distance avec chacune des autres classes
3. Nécessité de définir une distance entre groupes d'individus (appelé stratégie d'agrégation).
4. Nécessite de choisir le nombre de classes à retenir

Le choix de ces algorithmes ci-dessus s'est basé sur les critères suivants :

- **Taille de l'ensemble de données** : ces algorithmes sont performants pour les petits et grands échantillons de données.
- **Type de l'ensemble** : pour les ensembles de données idéales mais aussi pour les ensembles aléatoires.
- **Nombre de clusters** : ils donnent de bons résultats pour des petits et grands nombre de clusters.

3.5.1.4 Sélection du nombre optimal de clusters

L'inconvénients avec les algorithmes cités est que le nombre de cluster doit être défini au préalable. Il existe des méthodes, qui aident à déterminer le nombre de cluster optimal. Parmi ces méthodes, nous citons la méthode **Elbow**[5].

La figure ci-dessous, montre le résultat de la méthode **Elbow**. Dans cet exemple, nous pouvons remarquer que le nombre de cluster optimal retenu est k=3.

[5] https://en.wikipedia.org/wiki/Elbow_method_(clustering)

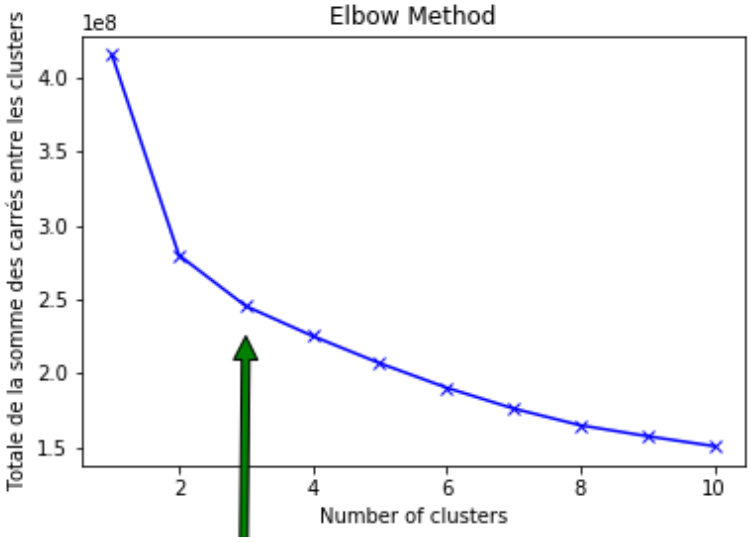

Figure IV-18 : *Exemple de résultat de la méthode Elbow*

3.5.1.5 Evaluation

L'évaluation des résultats d'un clustering est une tâche difficile, et ceci revient au fait qu'il n'y ait pas de modèle de référence pour effectuer une comparaison. Cependant il existe des indices de qualité qui opère sur les clusters et s'intéressent aux liens entre les éléments à l'intérieur des clusters. Ces critères se basent sur le principe que les éléments appartenant à une même classe sont plus liés entre eux qu'avec les éléments appartenant à des classes différentes.

Plusieurs indices de qualité qui utilisent la distance entre les individus ont été développés dont l'indice de validation de Davies Bouldin (DB) et l'indice de Silhouette (Voir annexe C).

3.5.2 Modèle de prédiction

Chaque compagnie de télécommunication a sa propre définition d'un churner. En ce qui nous concerne, un churner est considéré comme tel, dans le cas où il n'a pas utilisé les services de l'opérateur pendant une période de trois mois.

Parmi les raisons pour lesquelles les clients churnent, nous trouvons :

- Les clients ne sont pas satisfaits des services offerts.
- Les clients ont besoin d'un nouveau téléphone.
- Les clients sont attirés vers une offre des concurrents.
- Le contrat du client est expiré.

L'analyse prédictive est une technique qui utilise des expériences précédentes (données historiques) pour prédire les futurs comportements des individus dans le but d'aider à la prise de meilleures décisions et de minimisation des risques en anticipant les micro risques[26].

L'analyse prédictive, va nous permettre de prédire les clients qui sont susceptibles de churner pour ainsi leurs proposer des services personnalisés pour éviter l'évènement.

Le diagramme d'activité ci-dessous, résume les étapes du processus de prédiction.

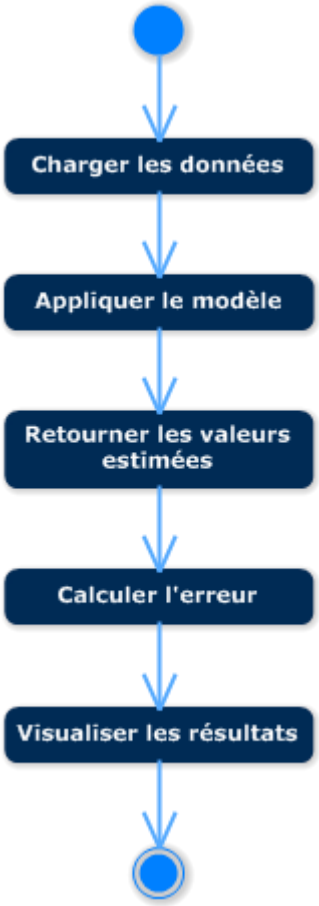

Figure IV-19 : *Diagramme d'activité qui illustre le processus de prédiction*

Afin de concevoir notre modèle de prédiction, nous allons suivre les étapes ci-dessous.

3.5.2.1 Sélection des attributs

Afin de sélectionner les attributs à retenir pour l'analyse de churn, nous nous sommes inspirés dans la littérature, des types d'attributs utilisés au sein des compagnies de télécommunication. Le tableau ci-dessous, présente les attributs que nous avons retenus.

Tableau IV-16 : *Les attributs sélectionnés pour le modèle prédictif*

Attributs sélectionnés	
Age	Durée d'appels
Sexe	Volume data
Région	Nombre sms
Type client	Indice de churn

3.5.2.2 Choix des algorithmes

Le choix de ces algorithmes est basé sur une étude faite par [27],où il avait recensé les algorithmes de prédiction les plus utilisé pour le churn dans les télécommunications. La figure ci-dessous, montre les proportions d'utilisation des quatre algorithmes.

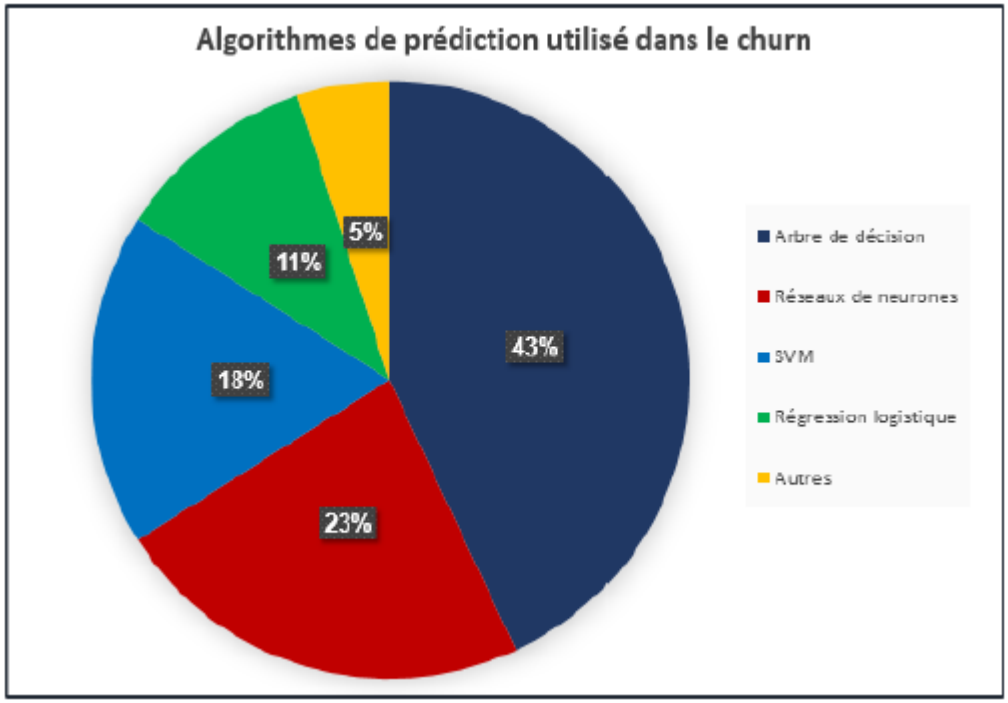

Figure IV-20 : *Algorithmes de prédiction utilisé dans le churn*[27]

Nous avons donc choisi les trois algorithmes les plus utilisés, à savoir : les arbres de décision, le plus proche voisin KNN et les SVM. Nous présentons ci-dessous, les arbres de décision, les deux autres algorithmes sont présentés au deuxième chapitre.

1. Les arbres de décisions

Nous présentons ci-dessous l'algorithme de construction d'un arbre de décision :

1- La situation actuelle vérifie-t-elle un critère d'arrêt ? Si oui, on s'arrête ici.
2- Si aucun critère d'arrêt n'est vérifié :
   a) Parmi toutes les variables du jeu de données, trouver celle permettant de poser la question conduisant à un gain d'information maximal.
   b) Partitionner les individus en fonction de la question trouvée, créer le nœud correspondant sur l'arbre.
   c) Recommencer l'algorithme en partant du nœud nouvellement créé.

3.5.2.3 **Echantillonnage de l'ensemble des données**

Afin de construire notre modèle de prédiction de churn, nous devons faire un apprentissage du modèle sur un certain nombre de données clients. Comme nous n'avons pas besoin des données de tous les clients, nous avons procédé à un échantillonnage des clients pour prendre un nombre suffisant [28]de données afin de construire notre modèle de prédiction Churn.

Nous avons pris un échantillon de 10 000 clients de manière aléatoire de tous les clients de l'entreprise, qui ont un point commun d'avoir eu au moins une activité durant l'année 2018, sur lesquels nous avons ajouté **l'indice de churn**[6] qui a les valeurs 0 et 1, 0 pour dire qu'il n'a pas churné, et 1 pour dire qu'il a churné. Il est primordial de connaitre la valeur de la propriété du churn car avec cet échantillon et ces valeurs nous allons pouvoir procéder à l'apprentissage et à la vérification de notre modèle de prédiction.

En effet nous avons découpé notre échantillon selon une bonne pratique proposée par [Hwang et al., 2004], pour les méthodes d'apprentissage supervisées. Cette pratique consiste à découper notre échantillon en deux parties 70/30 ; C'est-à-dire que 70% de l'échantillon soit 7000 clients ; cette partie a été utilisée pour l'apprentissage du modèle, et la deuxième partie contient 30% de l'échantillon soit 3000 clients, et est utilisée pour la vérification du modèle.

[6] Indice de churn : peut prendre la valeur 1 pour un client qui a churné et la valeur 0 pour le cas contraire.

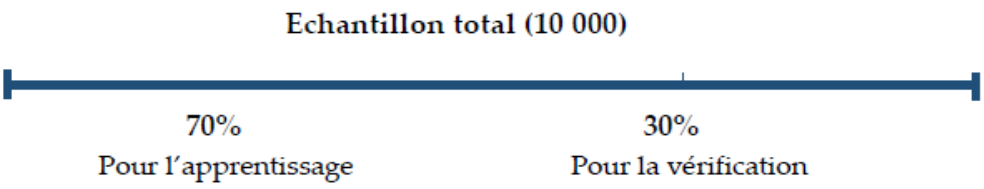

Figure IV-21 : *Echantillonnage de l'ensemble des données*

3.5.2.4 Apprentissage du modèle prédictif

Nous avons le jeu de données nécessaire pour effectuer l'apprentissage de notre Modèle de prédiction, ce jeu de données est constitué de 7000 clients avec leurs valeurs de churn. L'apprentissage s'effectue de la manière suivante :

- Tout d'abord, il faudra charger le jeu de données des 7000 clients ;
- Puis, lancer l'apprentissage de notre modèle prédictif sur le jeu de données des 7000 clients, en précisant que la propriété « churn » qui a la valeur 0 ou 1 et la variable à classifier.

3.5.2.5 Evaluation

Une fois l'apprentissage effectué, il faudra vérifier la fiabilité de notre modèle de prédiction, sa fiabilité à la bonne prédiction du churn d'un client. Pour cela nous utiliserons la deuxième partie de notre échantillon, qui est un jeu de données de 3000 clients.

Le résultat d'une vérification et un pourcentage du taux de bonnes prédictions, et cela en comparant les valeurs réelles de la propriété churn des 3000 clients avec les valeurs de la propriété de churn prédites par le modèle de prédiction.

Il existe des mesures d'évaluation qui sont appliquées pour mesurer les performances des modèles prédictifs. Nous citons le rappel, la précision et la F-mesure (Voir annexe C).

3.6 Visualisation : tableau de bord

Nous exposons dans cette partie la méthodologie de conception du tableau de bord ainsi que la liste des indicateurs de performance, ces derniers sont extraits à partir des besoins métiers élaborés dans le chapitre « analyse des besoins ».

3.6.1 Méthodes de mise en œuvre des tableaux de bords

La conception des premiers tableaux de bords se limitait à la considération de mesures économiques et financières. Cependant pour garantir une analyse plus réelle, les tableaux de bord ont été orientés vers des stratégies plus globales et complètes où les indicateurs financiers ne sont plus les seuls déterminants. C'est pourquoi une conception méthodique d'un tableau de bord est nécessaire pour la réussite de la mise en œuvre de ce dernier.

Les méthodes les plus utilisées dans la conception des tableaux de bord sont : la méthode GIMSI et la méthode BSC. Une étude comparative présente à l'annexe B a été effectué afin de comparer ces deux méthodes. Finalement, le choix s'est porté sur la méthode BSC. Dans ce qui suit, nous allons décrire la méthode BSC, puis nous justifions le choix de cette méthode.

Le Balanced Scorecard (BSC) est un système de mesure de performance qui privilégie l'approche « Top – Down » qui est particulièrement efficace pour garantir une mise en œuvre assez étroite de la stratégie, telle qu'elle a été définie par les dirigeants. Selon les concepteurs de ce système « Le tableau de bord prospectif (ou Balanced Scorecard) est un concept de management qui se focalise sur la stratégie et la vision plutôt que sur le contrôle, fournissant les moyens de traduire la vision de l'organisation en actions concrètes »[29].

Les étapes de la méthode BSC sont présentées à l'annexe B.

La synthèse de l'étude comparative présentée en annexe B entre les deux méthodes de conception (BSC et GIMSI), nous a permis de choisir la BSC comme méthode pour la mise en place de notre tableau de bord pour les raisons suivantes :

- Le tableau de bord en question est conçu pour les hauts dirigeants et plus précisément pour la direction stratégie de l'entreprise, dans ce cas c'est la performance globale de l'entreprise qui nous intéresse, et la BSC s'accorde parfaitement avec ce point contrairement à la GIMSI qui prend en compte les besoins et attentes de l'opérationnel ;
- La démarche privilégiée dans notre cas est la démarche Top-down adoptée par la BSC qui donne une vision claire et globale des données de l'entreprise contrairement la GISMI qui favorise l'approche Botton-up. Ce qui s'accorde parfaitement avec notre projet dont l'objectif est de faciliter la remontée des données à la direction stratégie ;
- Le besoin des décideurs de se focaliser sur les indicateurs critriques de l'entreprise nous impose d'avoir recours à la BSC vu sa structuration et sa vision concise sur la performance globale de l'entreprise.

3.6.2 Définition des indicateurs de performance (KPI)

Ainsi, dans notre cas, les KPI devront refléter les différentes dimensions que nous mesurons à travers nos tâches d'analyse du comportement client. Nous présentons ci-dessous, la documentation des différents indicateurs de performance de notre solution.

Tableau IV-17 : *Documentation du KPI : Taux de consommation Voix*

Nom du KPI	Taux de consommation voix
Objectif	Permet de connaitre le taux de clients consommant des appels téléphoniques
Dimensions	Age, sexe, region, type_client, occupation
Unité de mesure	%
Type de graphe	Valeur, ligne ou histogramme
Formule de calcule	$100 * \frac{revenu\ voix}{revenu\ total}$

Tableau IV-18 : *Documentation du KPI : Taux de consommation on-net*

Nom du KPI	Taux de consommation on-net
Objectif	Permet de connaitre le taux de clients consommant des appels
Dimensions	Age, sexe, region, type_client, occupation
Unité de mesure	%
Type de graphe	Valeur, ligne ou histogramme
Formule de calcule	$100 * \frac{revenu\ on - net}{revenu\ voix}$

Tableau IV-19 : *Documentation du KPI : Taux de consommation off-net*

Nom du KPI	Taux de consommation off-net
Objectif	Permet de connaitre le taux de clients consommant des appels vers les autres opérateurs concurrents
Dimensions	Age, sexe, region, type_client, occupation
Unité de mesure	%
Type de graphe	Valeur, ligne ou histogramme
Formule de calcule	$100 * \frac{revenu\ off - net}{revenu\ voix}$

Tableau IV-20 : *Documentation du KPI : Taux de consommation international*

Nom du KPI	Taux de consommation international
Objectif	Permet de connaitre le taux de clients consommant des appels vers l'international
Dimensions	Age, sexe, region, type_client, occupation

Unité de mesure	%
Type de graphe	Valeur, ligne ou histogramme
Formule de calcule	$100 * \frac{revenu\ international}{revenu\ voix}$

Tableau IV-21 : *Documentation du KPI : Taux de consommation roaming*

Nom du KPI	Taux de consommation roaming
Objectif	Permet de connaitre le taux de clients consommant des appels roaming
Dimensions	Age, sexe, region, type_client, occupation
Unité de mesure	%
Type de graphe	Valeur, ligne ou histogramme
Formule de calcule	$100 * \frac{revenu\ roaming}{revenu\ voix}$

Tableau IV-22 : *Documentation du KPI : taux de consommation Data*

Nom du KPI	Taux de consommation Data
Objectif	Permet de connaitre le taux de clients consommant de la data (internet)
Dimensions	Age, sexe, region, type_client, occupation
Unité de mesure	%
Type de graphe	Valeur, ligne ou histogramme
Formule de calcule	$100 * \frac{revenu\ data}{revenu\ voix}$

Tableau IV-23 : *Documentation du KPI : taux de consommation Sms*

Nom du KPI	Taux de consommation sms
Objectif	Permet de connaitre le taux de clients consommant les sms
Dimensions	Age, sexe, region, type_client, occupation
Unité de mesure	%
Type de graphe	Valeur, ligne ou histogramme
Formule de calcule	$100 * \frac{revenu\ sms}{revenu\ total}$

Tableau IV-24 : *Documentation du KPI : taux de souscriptions mensuelle*

Nom du KPI	Taux de souscriptions mensuelle
Objectif	Indique le taux de souscriptions mensuelle
Dimensions	Age, sexe, region, type_client, occupation
Unité de mesure	%
Type de graphe	Valeur, ligne ou histogramme
Formule de calcule	$100 * \frac{nbr_souscription\ mensuelle}{nbr_total_souscriptions}$

Tableau IV-25 : *Documentation du KPI : taux de souscriptions journalière*

Nom du KPI	Taux de souscriptions journalière
Objectif	Indique le taux de souscriptions journalière
Dimensions	Age, sexe, region, type_client, occupation
Unité de mesure	%
Type de graphe	Valeur, ligne ou histogramme
Formule de calcule	$100 * \frac{nbr_souscription\ journalière}{nbr_total_souscriptions}$

Tableau IV-26 : *Documentation du KPI : taux de souscriptions par souscripteurs*

Nom du KPI	Taux de souscriptions par souscripteurs
Objectif	Indique le taux de souscriptions par souscripteur
Dimensions	Age, sexe, region, type_client, occupation
Unité de mesure	%
Type de graphe	Valeur, ligne ou histogramme
Formule de calcule	$100 * \frac{nbr_souscription}{nbr_souscripteurs}$

Tableau IV-27 : *Documentation du KPI : taux de churn des clients*

Nom du KPI	Taux de churn de clients
Objectif	Indique le taux de clients susceptible de churner
Dimensions	Age, sexe, region, type_client, occupation
Unité de mesure	%

Type de graphe	Valeur, ligne ou histogramme
Formule de calcule	$100 * \frac{nbr_churners}{nbr\ de\ client\ de\ l'échantillon}$

4 Sécurité du système

Nous optons pour une solution qui sépare l'authentification du reste du système, un serveur d'authentification est responsable de l'identification des utilisateurs et l'attribution des rôles. Cette solution permet de :

- Centraliser la gestion des utilisateurs et des rôles dans notre système,
- Isoler les données confidentielles des utilisateurs du reste des ressources afin de limiter le risque de défaillance de sécurité.

Le principe d'authentification est représenté sur le diagramme de séquence ci-dessous. Avant d'accéder à une ressource, l'utilisateur doit d'abord s'authentifier à l'ouverture de session en introduisant un couple (émail, mot de passe), le couple est envoyé au serveur d'authentification à travers un canal sécurisé avec SSL afin d'être identifié dans la base de données des utilisateurs. A l'issue de cette étape, le serveur d'authentification génère un Ticket de service (token en anglais), ce ticket contient les informations de base de l'utilisateur dont son identifiant, les rôles ainsi que la date d'expiration du ticket. Le ticket est crypté en utilisant la clé privée du serveur d'authentification avant d'être transféré à l'utilisateur. L'utilisateur peut désormais demander une ressource à partir du serveur de ressources en utilisant le ticket récupéré. Le serveur de ressource vérifie l'authenticité de l'utilisateur en décryptant le ticket avec la clé publique du serveur d'authentification afin de garantir l'accès aux ressources autorisées par les rôles de l'utilisateur.

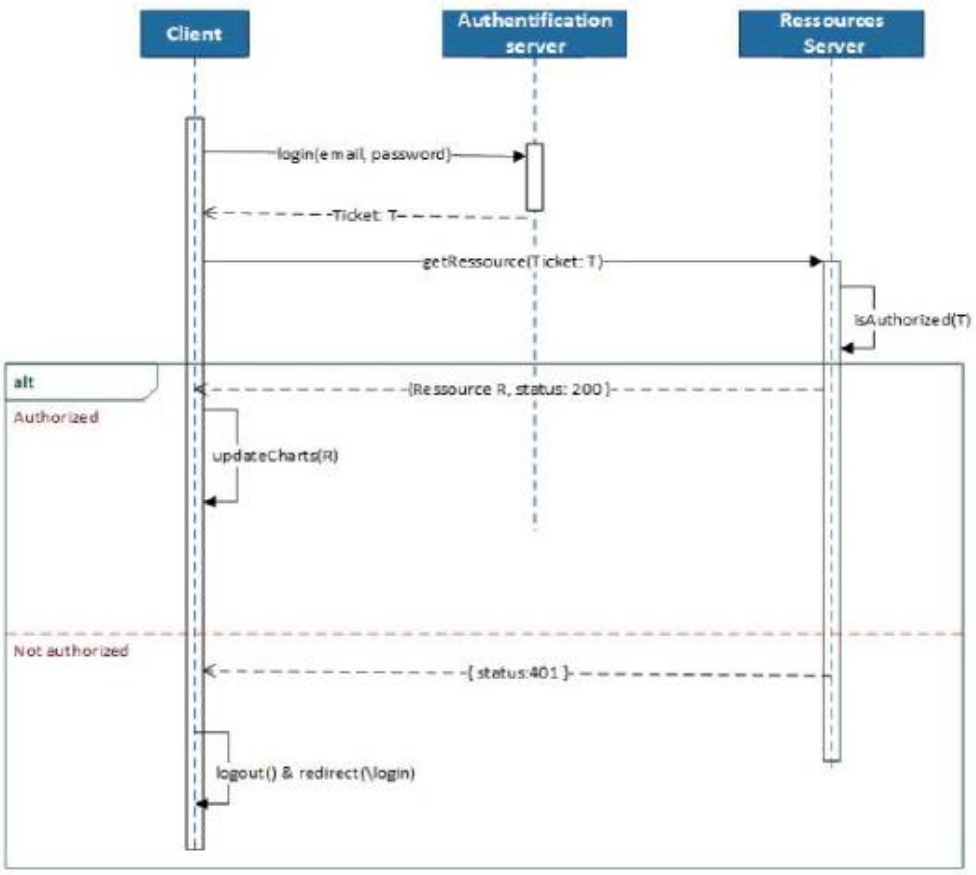

Figure IV-22 : *Diagramme de séquence représentant le processus d'accès aux données en utilisant un ticket.*

5 Conclusion

Dans ce chapitre, nous avons expliqué la démarche suivie et la conception préconisée pour le système selon les sections : conception de l'ETL, de la zone de stockage, des modèles de data mining, du tableau de bord et de la sécurité du système.

Maintenant que notre système a été conçu, nous pouvons dorénavant entamer la partie réalisation et tests de notre solution, qui feront l'objet du chapitre suivant.

CHAPITRE V : **REALISATION ET TESTS**

1 Introduction

Après avoir conçu notre solution, nous allons à présent entamer dans ce chapitre la réalisation et le test de celle-ci.

Dans ce chapitre nous allons présenter les différentes technologies utilisées lors de la réalisation de la solution en essayant de justifier le choix de chacune .Puis nous détaillons par la suite, les différentes étapes d'implémentation et de tests de notre solution.

2 Présentation des technologies utilisées

Dans cette section, nous allons présenter les différents outils que nous avons utilisé pour la réalisation de notre solution.

2.1 Data mining : Python

Python est un langage de programmation open source créé par le programmeur Guido van Rossum en 1991. Il s'agit d'un langage interprété, qui ne nécessite donc pas d'être compilé pour fonctionner. Python est un langage qui peut s'utiliser dans de nombreux contextes et s'adapter à tout type d'utilisation grâce à des bibliothèques spécialisées. Il est particulièrement répandu dans le monde scientifique, et possède de nombreuses bibliothèques optimisées destinées au calcul numérique. Par ailleurs, ce langage est aussi utilisé dans le domaine de la science des données et en Machine Learning. Avec l'essor de l'analyse de données dans toutes les industries, c'est d'ailleurs devenu l'un de ses principaux cas d'usage[7].

Nous l'avons utilisé pour toutes les étapes de construction du modèle. Les bibliothèques utilisées sont :

2.1.1 Pandas :

Pandas est une bibliothèque permettant la manipulation et l'analyse des données. Pour ce faire, Pandas propose les structures de données suivantes :

- Les séries : stocker les données selon une dimension.
- DataFrames : stocker les données selon deux dimensions.
- Les panels : représenter les données selon 3 dimensions.

[7] Lebigdata.fr et Wikipédia

- Les Multi Index : pour représenter les données selon plus de trois dimensions.

A partir des Data Frames, il est facile de lire et écrire à partir ou vers un fichier tabulé, mais aussi de tracer des graphes grâce à Matplotlib.

2.1.2 Numpy :

Numpy est une bibliothèque logicielle libre et open source destinée à manipuler des tableaux multidimensionnels. Elle fournit toutes les fonctions mathématiques nécessaires opérant sur ces tableaux, telles que la création, les opérations de base, les fonctions universelles et l'algèbre linéaire. Toutes les autres librairies et packages cités ci-dessous ne peuvent être utilisés sans Numpy.

2.1.3 Matplotlib :

Matplotlib est une bibliothèque destinée à la visualisation des données. Elle permet de tracer des graphes et peut être combinée avec les bibliothèques de calcul telles que Numpy et SciPy. Les graphes peuvent être exportés dans de nombreux formats matriciels (PNG, JPEG…) et vectoriels (PDF, SVG…). Elle a une forte communauté qui est très active et qui travaille continuellement sur son amélioration.

2.1.4 SciPy :

SciPy est un ensemble de bibliothèques unifiées dans le but de créer un environnement de travail scientifique tel que Matlab ou R. On y trouve des modules pour l'optimisation, les statistiques, le traitement d'images ou encore l'algèbre linéaire. La manipulation des matrices est possible grâce à Numpy et la visualisation des données est très avancée grâce au module Matplotlib. La plupart des algorithmes de SciPy sont codés en C pour obtenir d'excellentes performances d'exécution.

2.1.5 Scikit-Learn :

Scikit-Learn est une bibliothèque destinée au machine learning. Sa communauté est constituée notamment de contributeurs issus des instituts français d'enseignement supérieur et de recherche comme Inria et Télécom Paris Tech.

Parmi les fonctions qui existent dans cette bibliothèque on trouve : les forêts aléatoires, régression logistique, classification, SVM…

Selon le centre de recherche Inria Saclay : « Scikit-Learn peut être utilisé comme un middleware pour des tâches de prédiction. Par exemple, un grand nombre de start-ups du Web s'approprient Scikit-Learn pour prédire des comportements d'achat d'utilisateurs, proposer des recommandations de produits ou détecter les tendances ainsi que les comportements abusifs. »

2.1.6 Bokeh

Bokeh est une bibliothèque de visualisation interactive pour les navigateurs Web modernes. Il fournit une construction élégante et concise de graphiques polyvalents et offre une interactivité haute performance sur des ensembles de données volumineux ou en streaming. Bokeh peut aider quiconque souhaitant créer rapidement et facilement des tracés interactifs, des tableaux de bord et des applications de données.

2.1.7 Django

Django est un framework Web Python de haut niveau qui encourage un développement rapide et une conception propre et pragmatique. Conçu par des développeurs expérimentés, il prend en charge une grande partie des tracas du développement Web, vous pouvez donc vous concentrer sur l'écriture de votre application sans avoir à réinventer la roue. C'est gratuit et open source.

2.1.8 Jupyter notebook

Jupyter notebook est une application Web open source qui vous permet de créer et de partager des documents contenant du code en direct, des équations, des visualisations et du texte narratif. Les utilisations incluent: le nettoyage et la transformation des données, la simulation numérique, la modélisation statistique, la visualisation des données, l'apprentissage automatique et bien plus encore.

2.2 SGBD : MongoDB

MongoDB est un système de gestion de base de données NoSQL orientée documents. Chaque entrée dans une base

MongoDB est un document BSON (Binary JSO Serialisation binaire de documents JSON) qui possède une structure de données composée de couples (champ : valeur). Comme dans les documents JSON, les champs sont des chaines de caractères, et les valeurs peuvent être de différents types (nombre, chaine de caractères, tableau ou un autre document imbriqué).

Une base MongoDB est composée de plusieurs collections. Chaque collection comporte un ensemble de documents (les collections sont analogues aux tables dans les bases de données SQL). Les documents dans une collection dans MongoDB n'ont pas une structure statique. En d'autres termes dans une même collection nous pouvons avoir plusieurs documents avec des schémas différents.

Parmi les avantages que présente MongoDB, nous citons :

- Classé parmi les leaders des SGBD
- Flexibilité : absence de schéma, ce qui le rend idéal pour le développement et la maintenance des applications ;
- Scalabilité : la scalabilité horizontale est plus simple qu'avec une base de données relationnelle ;
- Rapidité de traitement ;
- Sécurité : gestion des utilisateurs par rôle

3 Présentation de la solution

Dans ce qui suit, nous allons procéder à l'implémentation de ces étapes en les appuyant à chaque fois par les résultats associés.

A travers la figure ci-dessous, nous présentons l'architecture technique de notre solution qui illustre les outils et technologies utilisés.

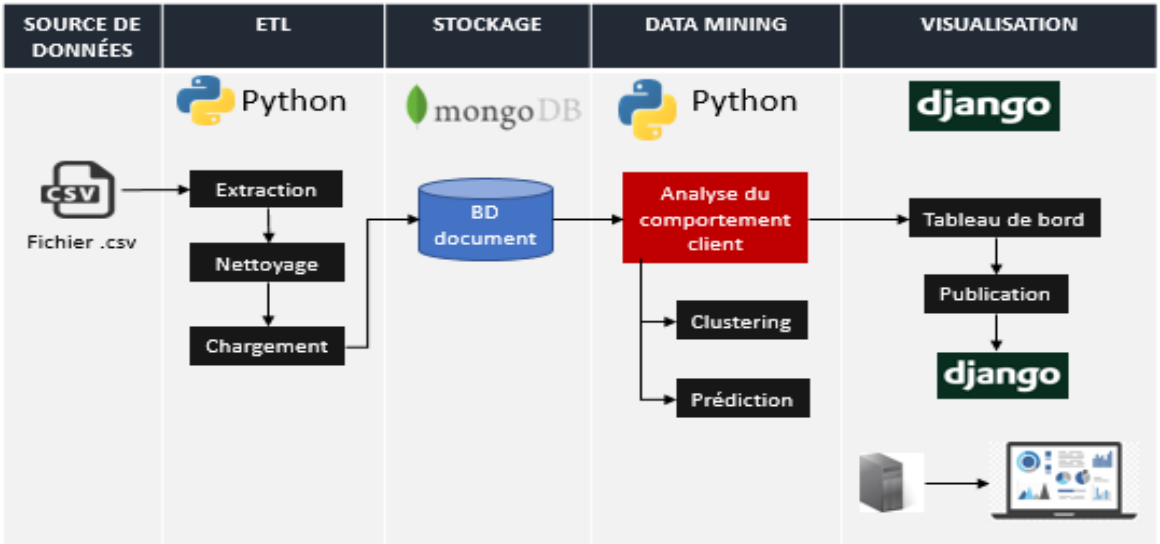

Figure V-1 : Architecture technique de la solution proposée

3.1 Implémentation de l'ETL

Dans cette étape, nous allons d'abord importer la source de données qui est un fichier .csv, sur lequel nous allons effectuer certains traitements, on peut citer :

1. Elimination des nuls

Il s'agit d'éliminer les nuls et les remplacer par des « 0 ».

```
# Illimination des valeurs null et les remplacer par 0
def fill_null(nulval, replacement):
    if pd.isnull(nulval):
        print('Imputation par la moyenne : {}'.format(replacement))
        return replacement
    return nulval
val_remplace=0
X['duration_min'] = [fill_null(t, val_remplace) for t in X['duration_min']]
```

2. Unification des types de données

Nous donnons l'exemple d'unification de l'attribut « sexe » par « H » ou « F ».

```
# unification de l'attribut sexe  homme remplacé par h et femme par f
X['sexe'] = X['sexe'].map({'homme': 'h', 'femme': 'f'})
```

La figure V-1 présente les données chargées dans les bases de données MongoDB.

Key	Value	Type
(1) 1	{ 12 fields }	Object
_id	1	Int32
Num	75483075	String
Age	18	String
Sexe	F	String
Region	centre	String
Type	Prepaid	String
SPEND_TOTAL	876	String
SPEND_DATA	66	String
SPEND_VOIX	778	String
SPEND_SMS	31	String
DURATION_MIN	180	String
VOLUME_DATA	19	String
(2) 2	{ 12 fields }	Object
_id	2	Int32
Num	75483088	String
Age	35	String
Sexe	H	String
Region	Est	String
Type	Prepaid	String
SPEND_TOTAL	876	String
SPEND_DATA	500	String
SPEND_VOIX	300	String
SPEND_SMS	76	String
DURATION_MIN	260	String
VOLUME_DATA	120	String

Figure V-2 : *chargement des données dans la BDD*

3.2 Implémentation des modèles de Data mining

Dans cette partie, nous allons implémenter les modèles de data mining de clustering et de prédiction relative aux analyses de consommations, de souscriptions et de churn.

3.2.1 Modèle de clustering

Dans le but d'effectuer une segmentation des clients de l'entreprise par rapport à leurs consommations et à leurs souscriptions, nous allons implémenter le modèle Data mining de clustering.

Ce modèle passe par des étapes préliminaires tel que l'analyse des corrélations entre les différents attributs ainsi que la sélection du nombre optimal du nombre de clusters. Une fois avoir réalisé ses étapes, nous procédons au test des algorithmes de clustering choisis lors de la conception. Dans ce qui suit, nous allons détailler chacune des étapes de modèle de clustering.

1. Analyse de corrélation

Nous allons commencer par effectuer une analyse de corrélation entre les attributs retenus lors de la conception du modèle. Pour cela nous allons appliquer trois méthodes de test : Pearson, Kendall et Spearman.

Les figures V-3 et V-4 montrent les résultats du test de ces méthodes :

```
# Application des différentes corrélations
pearsoncorr = data.corr(method='pearson')
kendallcorr = data.corr(method='kendall')
spearmancorr = data.corr(method='spearman')
pearsoncorr
```

	spend_total	spend_data	volume_data	spend_voix	duration_min	spend_sms
spend_total	1.000000	0.875738	0.875738	0.954192	0.954192	0.006959
spend_data	0.875738	1.000000	1.000000	0.691271	0.691271	0.000055
volume_data	0.875738	1.000000	1.000000	0.691271	0.691271	0.000055
spend_voix	0.954192	0.691271	0.691271	1.000000	1.000000	-0.000576
duration_min	0.954192	0.691271	0.691271	1.000000	1.000000	-0.000576
spend_sms	0.006959	0.000055	0.000055	-0.000576	-0.000576	1.000000

Figure V-3 : *Matrice de corrélation*

Note : *L'argument method = indique le type du coefficient de corrélation à calculer.*

Figure V-4 : *Corrélogramme de résultats de corrélations*

Suite aux résultats obtenus lors de l'analyse de corrélation et que l'on peut observer à travers la matrice de corrélation de la figure V-3 et du corrélogramme de la figure V-4, nous remarquons que :

- Les attributs spend_voix et duration_min, relatifs à la consommations et durées d'appels, sont fortement corrélés avec l'attribut spend_total relatif à la consommation totale ;
- Les attributs spend_voix et duration_min sont fortement corrélés entre eux ;
- Les attributs spend_data et volume_data sont fortement corrélés entre eux ;
- L'attribut spend_sms est faiblement corrélé avec tous les attributs.

De ces observations, nous pouvons émettre des premières constatations :

- Les clients consomment beaucoup plus d'appels téléphoniques ;
- Ils consomment aussi internet mais moins que les appels téléphoniques ;
- Ils consomment très peu de sms par rapport aux deux premiers.

2. Sélection du nombre optimal de cluster

A présent nous allons utiliser la méthode « Elbow » afin de déterminer le nombre de clusters optimal. Nous donnons l'exemple de l'application de la méthode sur l'algorithme « Kmeans ». Les résultats sont présentés dans la figure V-5 :

```
# Utilisation de la méthode elbow
wcss = []
for i in range(1, 11):
    kmeans = KMeans(n_clusters=i, init='k-means++', max_iter=300, n_init=10, random_state=0)
    kmeans.fit(X)
    wcss.append(kmeans.inertia_)
plt.plot(range(1, 11), wcss,'bx-')
plt.title('Elbow Method')
plt.xlabel('Number of clusters')
plt.ylabel('WCSS')

plt.savefig('elbow.png')
plt.show()
```

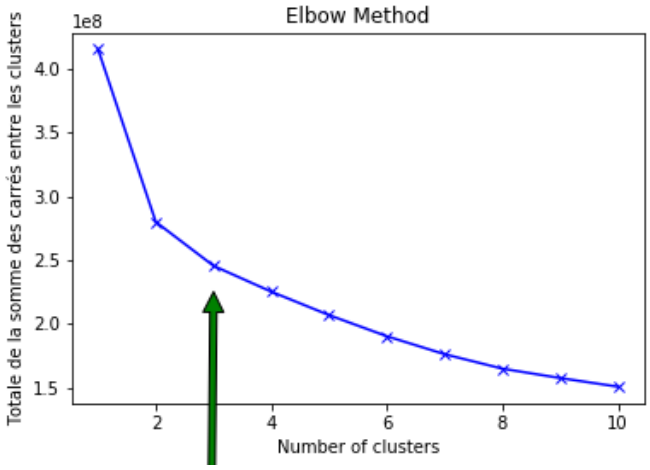

Figure V-5 : *Résultat de la méthode Elbow*

Les résultats de la méthode « Elbow » sur les données de consommation client montre que le nombre de cluster optimal appliqué à l'algorithme « Kmeans » pour ces données est K=3.

3. Test des algorithmes

Nous allons maintenant tester les deux algorithmes de clustering que nous avons défini dans la section précédente du chapitre conception. Les figures ci-dessous, représentent les scripts respectifs des algorithmes testés.

- **K-means**

```
# Clustering par K-means
km = KMeans(n_clusters=3)
km.fit(X)

# Récupération des clusters attribués à chaque individu
clusters = km.labels_

# Affichage du clustering par projection des individus sur le premier plan factoriel
pca = decomposition.PCA(n_components=3).fit(X)
X_projected = pca.transform(X)
plt.scatter(X_projected[:, 0], X_projected[:, 1], c=clusters.astype(np.float), cmap = 'jet', alpha=.2)
plt.title("Projection des {} individus sur le 1e plan factoriel".format(X_projected.shape[0]))
plt.show(block=False)
```

- **CAH**

```
# préparation des données pour le clustering
names = dataset.index

# Centrage et Réduction
std_scale = preprocessing.StandardScaler().fit(X)
X_scaled = std_scale.transform(X)

# Clustering hiérarchique
Z = linkage(X_scaled, 'ward')
```

Note : *Les résultats de ces algorithmes sont visualisés via l'application web.*

4. Evaluation

A présent, nous allons donner les résultats des métriques de validation pour les deux modèles de Data mining.

- **Pour le modèle de clustering (Analyse des consommations)**

Nous allons découvrir les résultats des métriques (Davis-Bouldin et silhouette) par rapport aux algorithmes de clustering (k-means, et cah), le nombre de cluster est varié de deux à six.

	silhouette_kmeans	db_kmeans	silhouette_cah	db_cah	nombre de clusters
2	0.643572	0.760702	0.708707	0.678562	2
3	0.554444	0.836909	0.508304	0.839224	3
4	0.504456	0.876175	0.508322	0.823894	4
5	0.515005	0.827175	0.435708	1.028503	5
6	0.471473	0.836578	0.444997	0.915872	6

Figure V-6 : *Les résultats de validation pour le clustering*

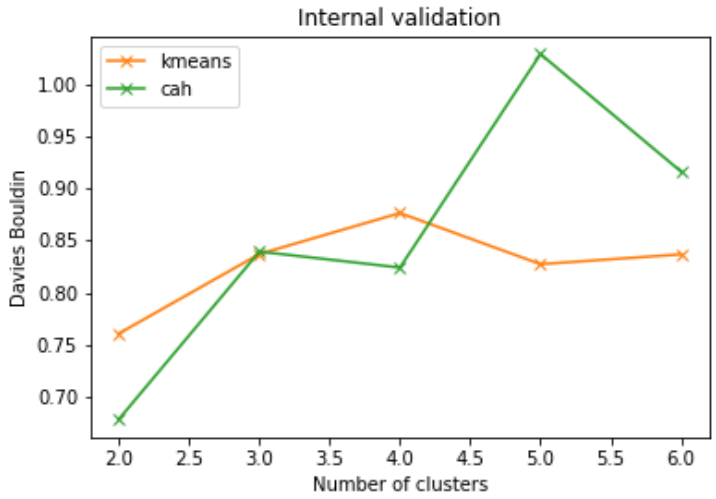

Figure V-7 : *Les résultats de la mesure DB*

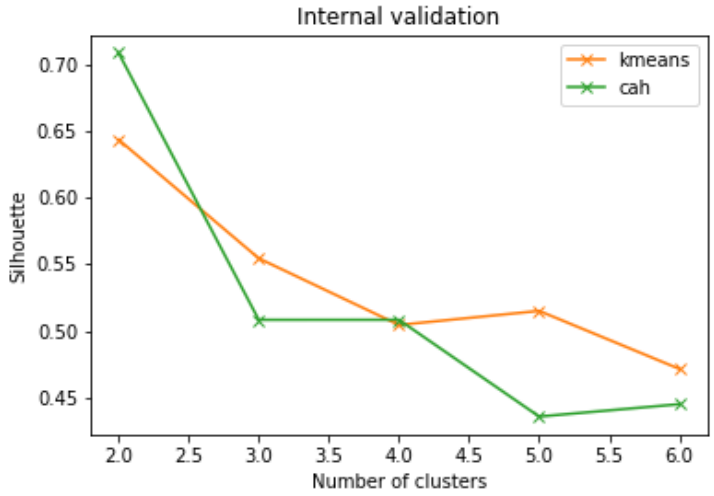

Figure V-8 : *Résultat de la mesure de Silhouette*

Les résultats des deux métriques de validation montrent que l'algorithme « k-means » est celui qui a obtenu les meilleurs résultats en termes de performances, avec k=3 selon le coefficient de silhouette.

3.2.2 Modèle de prédiction

Dans le but d'anticiper le churn des clients, nous allons implémenter un modèle prédictif qui nous renseigne sur les clients qui ont l'intention de churner.

Nous rappelons que nous travaillons sur un échantillon de 10 000 clients et que 7000 clients, soit 70% du total, seront exploités pour l'apprentissage du modèle et 3000 clients, soit 30% du total, pour le test.

A présent nous allons tester les algorithmes de prédiction défini lors de la conception sur notre échantillon de 7000 clients.

Les figures ci-dessous, représentent les scripts respectifs des algorithmes testés.

1- Arbre de décision

```
# Résumé de l'algorithme d'arbre de décision
# Selectionner un estimateur et préciser ces hyperparamètres
# Sauvegarder le modele et le tester
modele_dtree = grid_dt.best_estimator_

# Entrainer le modéle sur les données d'entrainnements Xtrain et y_train
modele_dtree.fit(X_train,y_train)
# Evaluer le modéle et Tester la performance du modele
modele_dtree.score(X_test,y_test)
# Utiliser le modèle avec modele_dtree.predict(x)
t=churn_ou_pas(modele_dtree,age=21, sexe =0, region =1, offre =1,spend_total=150, spend_data=60,
       volume_data =20, spend_voix = 62, duration_min=19, spend_sms=19)
print(t)
```

2- KNN plus proche voisin

```
# Résumé de l'algorithme KNN
# Selectionner un estimateur et préciser ces hyperparamètres
# Sauvegarder le modele et le tester
modele_knn = grid_knn.best_estimator_

# Entrainer le modéle sur les données d'entrainnements Xtrain et y_train
modele_knn.fit(X_train, y_train)
# Evaluer le modéle et Tester la performance du modele
modele_knn.score(X_test,y_test)
# Utiliser le modèle avec modele_dtree.predict(x)
t=churn_ou_pas(modele_knn,age=21, sexe =0, region =1, offre =1,spend_total=150, spend_data=60,
       volume_data =20, spend_voix = 62, duration_min=19, spend_sms=19)
print(t)
```

3- SVM

```
# Résumé de l'algorithme SVM
# Selectionner un estimateur et préciser ces hyperparamètres
# Sauvegarder le modele et le tester
model_df_svm = svm.SVC(kernel='rbf')

# Entrainer le modéle sur les données d'entrainnements Xtrain et y_train
model_df_svm.fit(X_train, y_train)
# Evaluer le modéle et Tester la performance du modele
model_df_svm.score(X_test,y_test)
# Utiliser le modèle avec modele_dtree.predict(x)
t=churn_ou_pas(model_df_svm,age=21, sexe =0, region =1, offre =1,spend_total=150, spend_data=60,
       volume_data =20, spend_voix = 62, duration_min=19, spend_sms=19)
print(t)
```

A présent nous allons comparer les performances des trois algorithmes que nous venons de tester. A cet effet, nous allons utiliser les trois mesures de qualités que nous avons défini lors du chapitre précédant : Précision, Rappel et F-Mesure.

Nous présentons les résultats d'évaluation dans le tableau ci-dessous :

Tableau V-1 : *Evaluation de la prédiction de churn*

	Précision	**Rappel**	**F-Mesure**
Arbre de décision	0.942	0.999	0.970
KNN	0.942	0.999	0.970
SVM	0.942	1	0.970

Nous pouvons observer à travers le tableau ci-dessus, que les meilleurs résultats sont obtenus par l'algorithme de SVM pour les trois mesures : Précision, Rappel et F-Mesure.

3.3 Tableau de bord

A présent, nous arrivons à la section de visualisation des résultats de Data mining. La visualisation s'effectue grâce à l'application web faite à base du framework Django et qui permet de :

- Créer les graphes relatifs aux résultats de Data mining ;
- Créer des tableaux de bords ;
- Créer des indicateurs clés de performance ;
- Exporter des rapports de format PDF.

Dans ce qui suit, nous allons présenter quelques visualisations tout en expliquant à chaque fois les résultats obtenus.

La figure ci-dessous représente les résultats de la segmentation des clients par rapport aux revenus : total, data, voix et SMS.

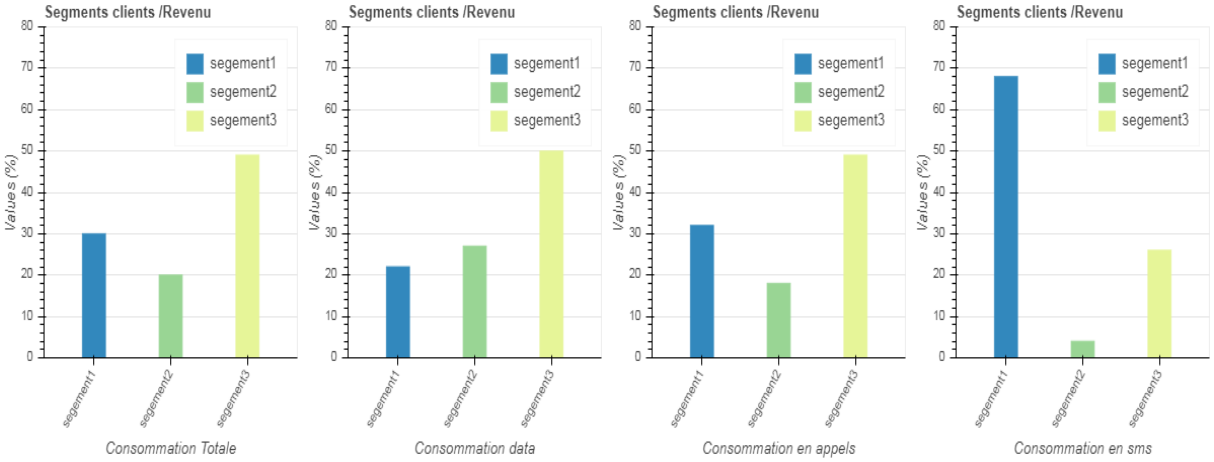

Figure V-9 : *Segmentation client par rapport aux revenus*

Nous observons la présence de trois segments obtenu grâce à l'algorithme « K-means » (nombre que nous avons défini lors de la section précédente avec la méthode Elbow).

Segment 1 : représente un segment moyen soit 30% du revenu total, les clients de ce segment consomment plus de SMS près de 70% du revenu sms, un peu de 22% du revenu de la data, et près de 33% du revenu de la voix.

Segment 2 : représente le segment le moins rentable des trois soit moins de 20% du revenu totale, les clients de ce segment consomment près de 28% du revenu de data, près de 18% du revenu de la voix et un peu plus de 3% du revenu de SMS.

Segment 3 : représente le segment le plus rentable des trois soit 50% du revenu total, les clients de ce segment consomment près de 60% du revenu de la data, près de 50% du revenu de la voix et un peu de 25% du revenu des SMS.

La figure ci-dessous représente les résultats de la segmentation des clients par rapport au trafic : durée d'appels et volume data.

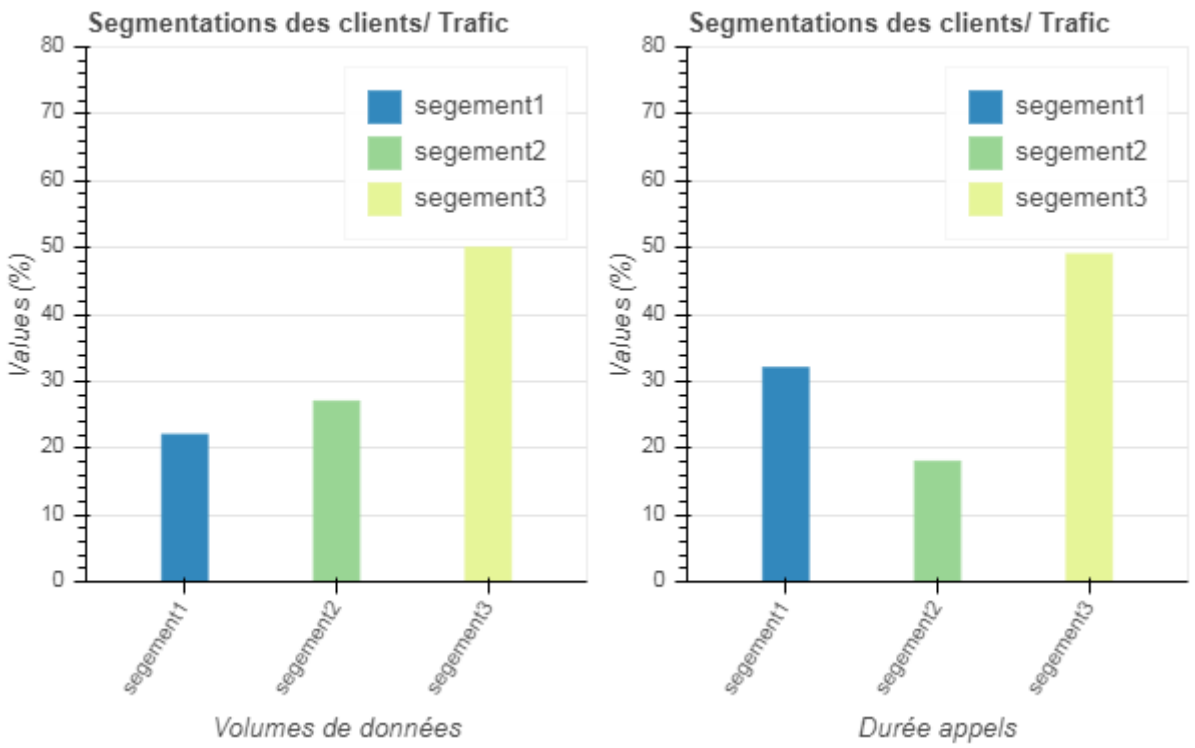

Figure V-10 : *Segmentation client par rapport au trafic*

Dans les figures V-10, nous remarquons que le trafic des clients, en termes de durée d'appels et de volume data, dans les trois segments coïncident avec les consommations de voix et de data en termes de revenus dans la figure V-9. Ainsi, nous trouvons :

Segment 1 : les clients de ce segment consomment peu d'internet, soit 21%, et un peu plus d'appels téléphoniques, nous trouvons un taux de 33% d'appels téléphoniques et 21% de consommation d'internet. Nous pouvons qualifier les clients du segment 1 de « petit client ».

Segment 2 : les clients de ce segment ressemblent beaucoup à ceux du segment 1 sauf qu'ils consomment plus d'internet par rapport aux appels téléphoniques soit 18 % de voix et 28% de data.

Segment 3 : les clients de ce segment consomment beaucoup d'internet, soit 52 %, et un peu moins d'appels téléphoniques, soit un peu plus de 47%. Nous pouvons qualifier les clients du segment 3 de « bon client » ayant un profil orienté data(internet).

Nous pouvons qualifier les clients du segment 3 de « bon client » ayant un profil orienté data(internet).

La figure ci-dessous représente les résultats de la segmentation des clients par rapport à la voix et la data ensemble.

Figure V-11 : *Segmentation client par rapport aux revenus*

Nous pouvons observer à travers cette figure que :

Segment 1 (en jaune) : les clients de ce segment consomment très peu de voix et de data.

Segment 2 (en violet) : les clients de ce segment ont une consommation moyenne de voix et de la data.

Segment 3 (en vert) : les clients de ce segment consomment beaucoup de voix et de data.

La figure ci-dessous représente les indicateurs relatifs aux taux de consommations data, voix et sms des types de clients « prépayée » et « postpayée ».

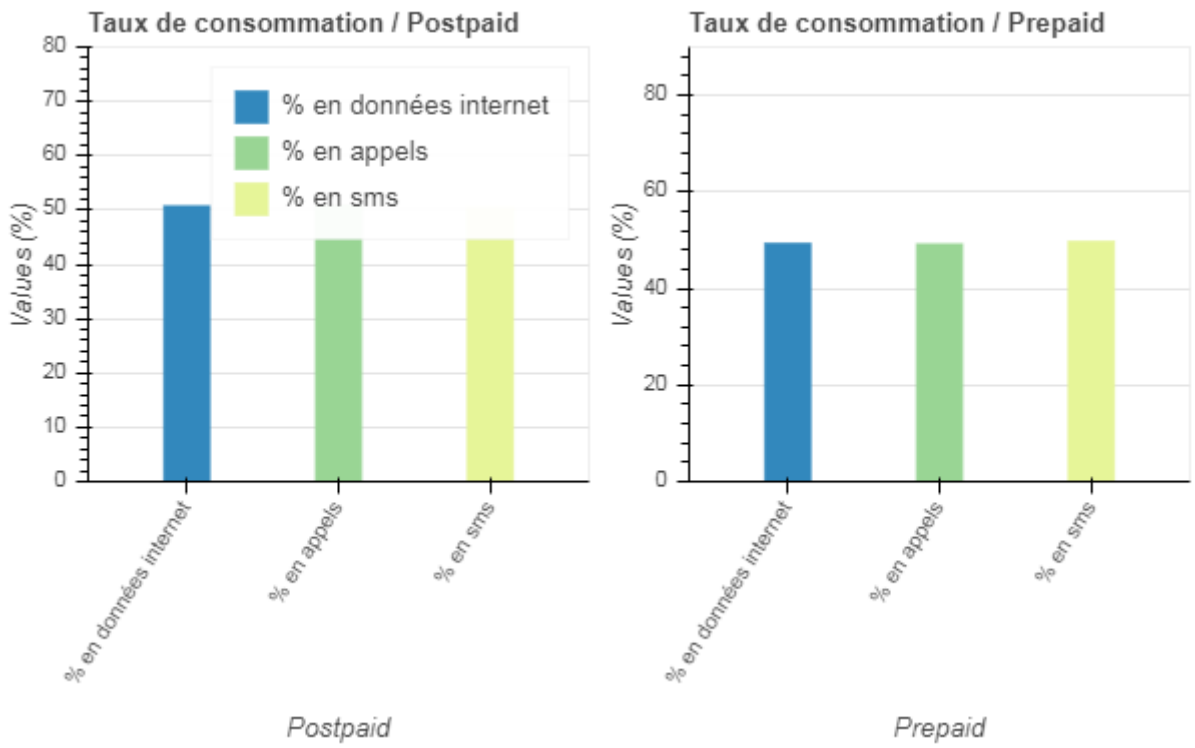

Figure V-12 : *Indicateurs clés du taux de consommation Prépayée et Postpayés*

A travers la figure V-12, nous pouvons constater dans un premier temps, que le taux de clients prépayée est presque identique à celui des postpayés.

Pour les clientes postpayés : nous remarquons un taux considérable de consommation data, suivi d'un taux important de consommation voix et enfin un taux considérable de consommation des SMS mais moins par rapport aux autres.

Pour les clients prépayés : nous remarquons un taux considérable de consommation data, suivi d'un taux important de consommation voix et enfin un taux considérable de consommation des SMS mais moins par rapport aux autres.

La figure ci-dessous représente les indicateurs relatifs aux taux de churn des clients selon les trois clusters définis lors de l'étape de segmentation.

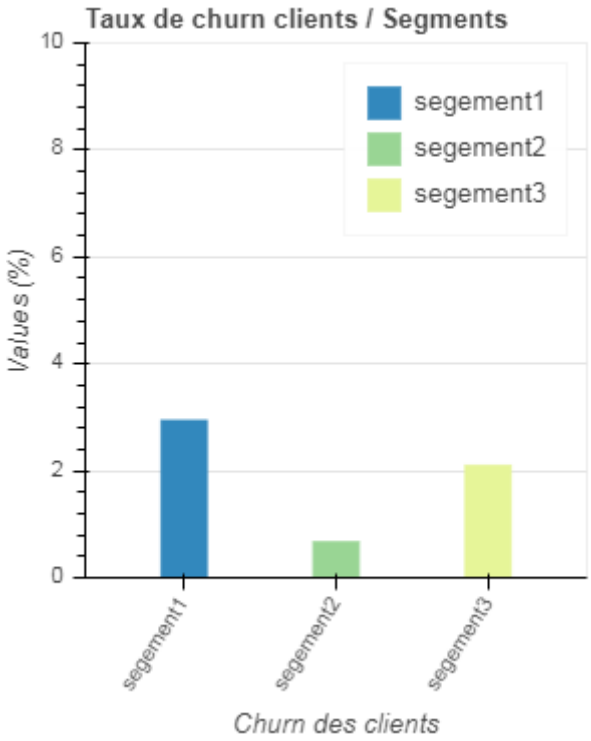

Figure V-13 : *Indicateurs clés du taux de churn des clients Prépayée et postpaid*

On remarque à travers la figure V-13 que le segment 1, présente le taux le plus élevé de risque de churn. Rappelons que ce segment, comme nous l'avons vu plus haut, représente celui qui consomme le moins de services. Ceci explique le risque élevé de churn.

La figure ci-dessous représente les indicateurs relatifs aux taux de churn selon les deux types de clients (prépayée et post payée). Le client prépayé présente presque le même taux de churn que les postpayés.

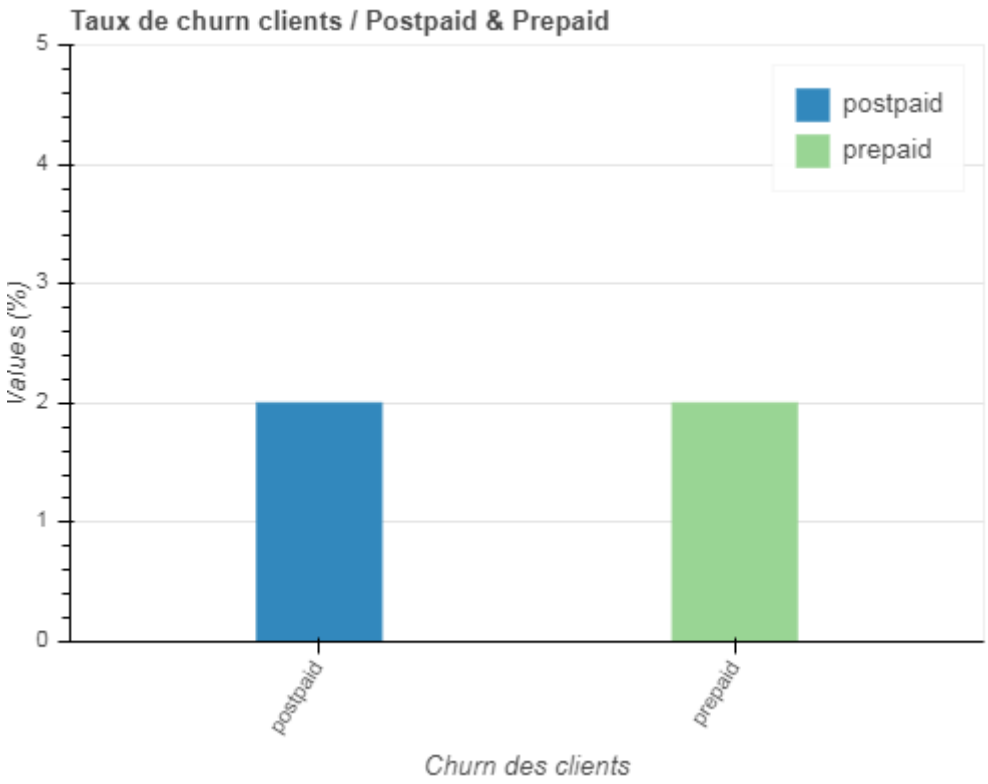

Figure V-14 : *Indicateurs clés du taux de churn des clients Prépayée et Postpaid*

Nous arrivons à la création du tableau de bord, notons que nous pouvons créer autant de tableaux de bords qu'on le souhaite.

La figure V-15, illustre un exemple de tableau de bord relatif aux consommations client, auquel nous avons sélectionné quelques graphiques présentés auparavant.

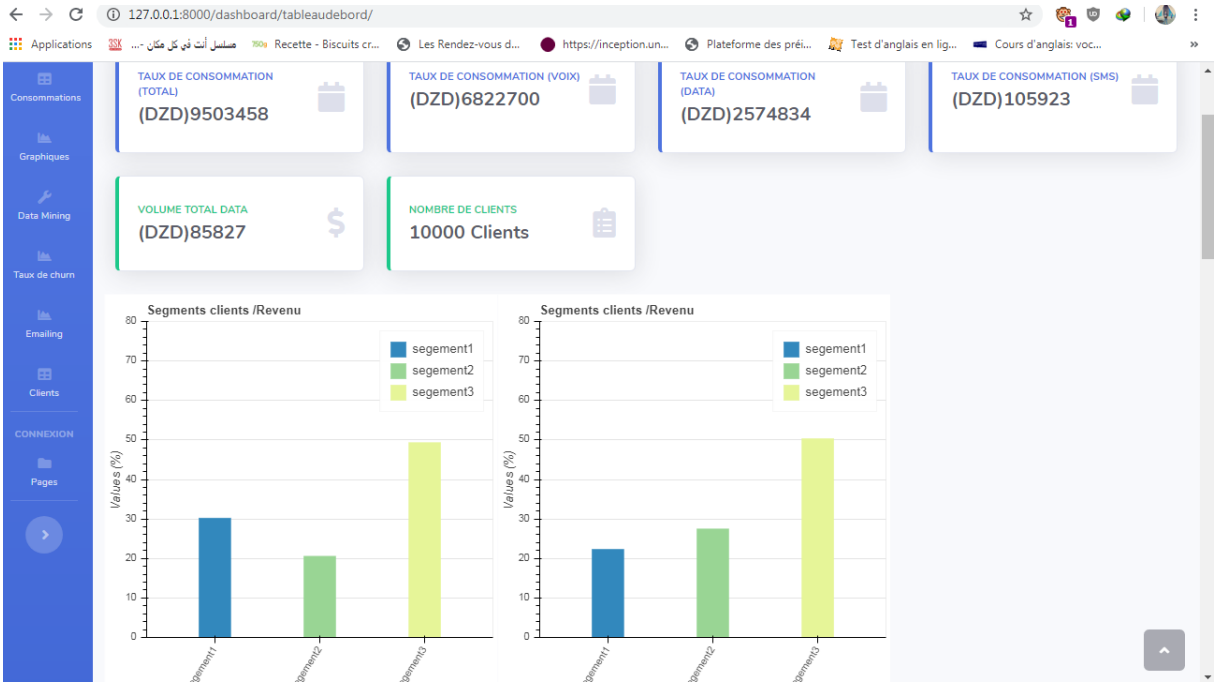

Figure V-15 : *Tableau de bord concernant la consommation client*

4 Sécurité du système

A travers l'application web faite en Django, l'administrateur peut assurer la gestion des utilisateurs et des droits d'accès au système.

L'administrateur effectue les tâches suivantes :

- Ajouter des nouveaux utilisateurs ;
- Créer des groupes et affecter les utilisateurs à ces derniers ;
- Affecter un rôle à chaque groupe d'utilisateurs.

5 Conclusion

Nous arrivons à terme de notre réalisation, à travers ce chapitre, nous avons d'abord présenter les technologies utilisées pour réaliser notre solution. Par la suite, nous avons dérouler les étapes de notre solution, allant de l'implémentation de l'ETL, en passant par l'implémentation des modèles de Data mining, la visualisation des résultats de Data mining via le tableau de bord ainsi que l'aspect sécurité de notre système. Et enfin, nous venons de terminer ce chapitre avec l'évaluation des modèles de Data mining.

A présent, nous pouvons passer à la conclusion générale de notre projet tout en donnant les perspectives de notre solution.

CONCLUSION GENERALE

Il n’y pas si longtemps, on avait tendance à considérer qu’un client était acquis, parce qu’il n’avait pas d’autres choix. Aujourd’hui et en l’espace de quelques années, nous sommes passés du monopole à la concurrence, autrement dit à la course au client. Le client est ainsi devenu le principal sujet de conversation de l’entreprise. Les entreprises se concentrent dorénavant sur la fidélisation de leurs clients et aux moyens d’y parvenir.

Afin de conserver sa clientèle, les entreprises ont compris qu’il était primordial d’étudier le comportement de ses clients pour répondre au mieux à leurs besoins et augmenter leurs satisfactions. Ainsi, un client qui est satisfait, reste fidèle à l’entreprise.

A travers notre projet de fin d’études, nous nous sommes concentrés sur le moyen de répondre aux besoins d’améliorer l’efficacité des campagnes marketing en mettant en place un système d’analyse du comportement de ses clients, à l’aide des techniques de data mining.

Nous avons entamé notre rapport par une introduction générale dans laquelle nous avons situé le contexte, et exposer la problématique liée à notre projet.

Puis nous avons réalisé une synthèse bibliographique qui comprend trois chapitres. A travers le premier chapitre, nous avons exposé les différentes notions et concepts lié au data mining, et les techniques utilisées à ce jour dans le but est de gérer et fidéliser les clients. Quant au deuxième chapitre, nous nous sommes intéressés de près aux méthodes et techniques de datamining. Puis en troisième chapitre nous avons présenté l’ensemble des applications du datamining utilisé dans le domaine marketing.

Par la suite, nous nous sommes dirigés vers la récolte des besoins et les attentes du projet en termes d'informations conduisant à de meilleures prises de décisions. Grâce à une démarche basée sur les meilleures pratiques, nous avons pu tracer les grands volets d'analyse portant sur les analyses de consommations, de souscriptions et de churn des clients puis de lister les différents indicateurs clés de performance liée à chacun de leurs besoins.

Une fois les besoins définis, nous avons discuté les différentes solutions qui s'offrent à nous pour choisir celle qui convient le mieux à l'existant et qui répond le mieux aux besoins définis, sans négliger l'aspect flexibilité de la solution qui devra s'adapter aux changements envisagés sur le système actuel.

Ensuite, nous avons enchainé sur la conception décrivant la manière de mettre en place les différentes parties de notre solution. Parallèlement, nous avons cherché les technologies les plus adaptées pour la réaliser.

La réussite de la phase de réalisation découle de la qualité de celles qui la précède, qui sont la conception et la documentation sur les technologies choisies. Il s'agit de l'ultime travail récompensé par la concrétisation et la consécration d'importants efforts d'analyse et de réflexion. La réalisation doit être constamment validée par des tests.

Finalement à terme de ce projet de fin d'études, nous avons pu, atteindre les objectifs que nous nous sommes fixés au tout début du projet d'une part, et répondre aux besoins qu'on s'est fixé, c'est-à-dire :

L'objectif était de mettre en place un système d'analyse du comportement des client afin de pouvoir fidéliser les clients ainsi améliorer l'efficacité des campagnes marketing. Ces analyses portent essentiellement sur les consommations des services, les souscriptions effectuées et les churn des clients.

Plus précisément ce système permet de récupérer les données d'analyse à partir différentes sources qui sont après prétraitement chargées dans une base NoSQL.

Par la suite, il permet d'effectuer les analyses de comportement client en termes des consommations, souscriptions et churn des clients en utilisant des techniques de Data mining ;

Pour enfin pouvoir visualiser les résultats des analyses à travers des tableaux de bords interactifs.

Ce projet ouvre sur différentes perspectives, parmi lesquelles nous évoquons :

- ***Intégrer d'autres sources de données :*** nous pouvons enrichir notre modèle, par exemple, avec des données sociales. De nos jours les clients s'expriment systématiquement sur les réseaux sociaux, en récupérant leurs avis et en analysant leurs sentiments, nous pourrons comprendre davantage sur le comportement. De plus, avec notre système de stockage NoSQL qui est très flexible, l'intégrations sera simple ;
- ***Etablir un portrait-robot du client :*** à travers l'étude du comportement du client sur les réseaux sociaux, nous pourrons réaliser un portrait-robot détaillé sur le client ;
- ***Rajouter d'autres analyses :*** comme l'étude des plaintes des clients auprès du service client ainsi que l'étude des enquêtes de satisfaction client ;
- ***Inclure des campagnes marketing automatique***

Durant ce projet, nous avons eu l'occasion de surmonter quelques difficultés dont l'accès aux données d'analyses, chose due à la sensibilité des données des clients et donc la difficulté de se les procurer.

En définitive, ce projet nous a été bénéfique sur plusieurs points. Académiquement, d'abord, nous avons pu développer une certaine méthodologie dans la recherche scientifique à travers l'étude bibliographique. Professionnellement, nous avons appris à intégrer un milieu de travail multinational. Enfin, sur un plan personnel, nous avons mis en pratique des connaissances et sens de résolution des problèmes complexes, acquis à travers notre formation. De plus, nous avons eu l'opportunité de valider notre attirance pour le domaine.

Bibliographie

[1] D. A. Zighed and R. Rakotomalala, "Extraction de connaissances à partir de données (ECD)," *Tech. l'Ingénieur, H*, vol. 3, p. 744, 2002.

[2] R. König, "Predictive techniques and methods for decision support in situations with poor data quality." 2009.

[3] U. M. Fayyad, G. Piatetsky-Shapiro, and P. Smyth, "Knowledge Discovery and Data Mining: Towards a Unifying Framework.," in *KDD*, 1996, vol. 96, pp. 82–88.

[4] R. Lefébure and G. Venturi, "Le data mining," Eyrolles, 1998.

[5] U. Fayyad, G. Piatetsky-Shapiro, and P. Smyth, "From data mining to knowledge discovery in databases," *AI Mag.*, vol. 17, no. 3, p. 37, 1996.

[6] D. T. Larose, "An introduction to data mining," *Discov. Knowl. Data, John Wiley Sons Publ. Hoboken, New Jersey, USA*, pp. 1–25, 2005.

[7] M. J. A. Berry and G. Linoff, *Data Mining: Techniques appliquées au marketing, à la vente et aux services clients*. InterEditions, 1997.

[8] X. Wu *et al.*, "Top 10 algorithms in data mining," *Knowl. Inf. Syst.*, vol. 14, no. 1, pp. 1–37, 2008.

[9] Michel VOLLE, "Intranet et Datamining." .

[10] G. Calas, "Etudes des principaux algorithmes de data mining," *Spécialisation Sci. Cogn. Inform. Avancée, Fr.*, 2009.

[11] C. LAMICHE, "FUSION ET FOUILLE DE DONNEES GUIDEES PAR LES CONNAISSANCES: APPLICATION A L'ANALYSE D'IMAGE."

[12] B. Agard and A. Kusiak, "Exploration des bases de données industrielles à l'aide du datamining–Perspectives," in *9ème colloque national AIP PRIMECA*, 2005.

[13] I. H. LE Anh Tuan, "Reduction De Base De Donnees Par La," 2004.

[14] J. Han, J. Pei, and M. Kamber, *Data mining: concepts and techniques*. Elsevier,

2011.

[15] P.-E. JOUVE, “Apprentissage Non Supervisé et Extraction de Connaissances à partir de Données,” 2003.

[16] Pavel Berkhin, “Survey Of Clustering Data Mining Techniques,” pp. 1–56, 2002.

[17] E. G. Talbi, “Fouille de données (Data Mining): Un tour d’horizon,” *Lab. d’informatique Lille*.

[18] L. recommandées hors Cyberlibris, P. KOTLER, K. KELLER, and D. MANCEAU, “Marketing Management, 15ème édition.” Paris, Pearson, 2015.

[19] J. Lendrevie and J. Lévy, *Mercator 11e édition: Tout le marketing à l’ère numérique*, vol. 1. Dunod, 2014.

[20] N. Djouadi, S. Lamari, and A. E. Mahnaou, “La démarche du marketing touristique.” Université Abderrahmane mira bejaia/Aboudaou, 2018.

[21] G. S. Linoff and M. J. A. Berry, *Data mining techniques: for marketing, sales, and customer relationship management*. John Wiley & Sons, 2011.

[22] “🔎 Churn : définition et explications.” [Online]. Available: https://www.techno-science.net/definition/11624.html. [Accessed: 19-Oct-2019].

[23] F. Juglaret, “Indicateurs et tableaux de bord pour la prévention des risques en santé-sécurité au travail.” 2012.

[24] P. Chapman *et al.*, “CRISP-DM 1.0: Step-by-step data mining guide,” *SPSS inc*, vol. 16, 2000.

[25] M. El Malki, “Modélisation NoSQL des entrepôts de données multidimensionnelles massives.” 2016.

[26] E. Siegel, *Predictive analytics: The power to predict who will click, buy, lie, or die*. John Wiley & Sons, 2013.

[27] S. Babu and N. R. Ananthanarayanan, “A review on customer Churn prediction in telecommunication using data mining techniques,” *Int. J. Sci. Eng. Res.*, 2014.

[28] C. Archaux, “Conception d’un système d’information dédié à l’estimation de la valeur des clients en téléphonie mobile prépayée.” Nantes, 2005.

[29] R. S. Kaplan, “Conceptual foundations of the balanced scorecard,” *Handbooks Manag. Account. Res.*, vol. 3, pp. 1253–1269, 2009.

[30] D. L. Davies and D. W. Bouldin, “A cluster separation measure,” *IEEE Trans. Pattern Anal. Mach. Intell.*, no. 2, pp. 224–227, 1979.

[31] P. J. Rousseeuw, “Silhouettes: a graphical aid to the interpretation and validation of cluster analysis,” *J. Comput. Appl. Math.*, vol. 20, pp. 53–65, 1987.

ANNEXES

Annexe A : Méthodes de conception de Data mining

L'intérêt progressif pour le Datamining a permis l'apparition des méthodologies pour la mise en place d'un processus de découverte de connaissances simple et efficace, applicable dans tous les secteurs d'activités. De ce besoin sont né les initiatives CRISP-DM (Cross Industry Standard Process for Data Mining), SEMMA (Sample, Explore, Modify, Model, Asses) et la plus connue KDD (Knowledge Data Discovery) au début des années 1990. Dans ce qui suit, nous allons décrire les étapes de chacune des méthodes, puis nous effectuons une comparaison entre elles et enfin nous présenterons les avantages et inconvénients de chacune des méthodes.

A.1 Méthodologie CRISP-DM

À partir du processus utilisé dans les premiers projets de Datamining, CRISP-DM a défini et validé une méthodologie potentiellement applicable dans tous les secteurs, dont les données stockables sont importantes. Elle permet de rendre les projets Datamining à grande échelles plus rapides, moins coûteux, plus fiables et surtout améliorer leur gestion. Cette méthodologie ne vise pas que les grands projets car même les petits projets de Datamining peuvent tirer profit de son utilisation.

Par cette méthodologie, on a un aperçu du cycle de vie d'un projet de Datamining. Elle identifie clairement les principales phases de ce processus au travers des tâches et des relations entre ces tâches. Il y a des relations possibles entre toutes les tâches en fonction des objectifs d'analyse et des données qui sont à analyser. Les six phases importantes du processus sont[12]:

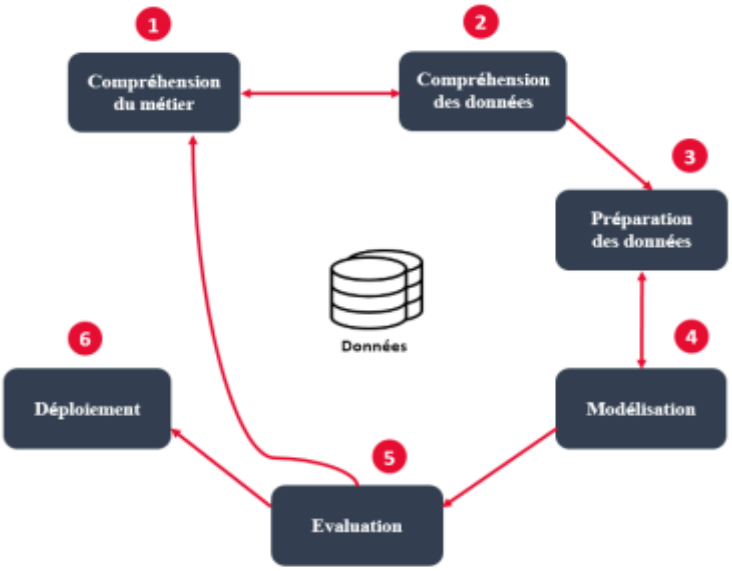

Figure A-1 : *Méthode CRISP-DM (Agard & Kusiak, 2005)*

Figure A-1 : **La compréhension du problème métier :** cela concerne la définition du problème d'analyse sur la base des objectifs métier qui en sont à l'origine.

1. **La compréhension des données :** cette phase vise à déterminer précisément les données à analyser et à identifier la qualité des données.
2. **La préparation des données :** elle regroupe les activités liées à la construction de l'ensemble précis des données à analyser à partir des données brutes. Elle inclue le classement des données en fonction de critères choisis, le nettoyage des données, etc.
3. **La modélisation :** c'est la phase la plus importante dans le paramétrage et le test de différentes techniques, sachant que l'objectif est d'optimisé un modèle et ainsi les connaissances obtenues.
4. **L'évaluation :** elle vise à vérifier le modèle ou les connaissances obtenues afin de s'assurer qu'ils répondent aux objectifs formulés au début du processus. Elle contribue aussi à la décision de déploiement du modèle, ou si besoin est, à son amélioration.
5. **Le déploiement :** c'est l'étape finale du processus de découverte de connaissance. Son objectif est de mettre la connaissance obtenue par la modélisation, dans une forme adaptée et l'intégrer au processus de prise de décision. Le déploiement peut aller, selon les objectifs, de la simple génération d'un rapport décrivant les connaissances obtenues jusqu'à la mise en place d'une application, permettant l'utilisation du modèle obtenu, pour la prédiction de valeurs inconnues d'un élément d'intérêt.

A.2 Méthodologie SEMMA

La méthode SEMMA est composé cinq étapes représentées par :

- « Sample, Explore, Modify, Model, Asses ». Cette méthodologie facilite pour les analystes de données la manière d'appliquer des techniques d'exploration statistique et de visualisation des données, de sélection et de transformation des variables prédictives les plus importantes, de modélisation des variables pour prédire les résultats et de confirmation de la précision du model.

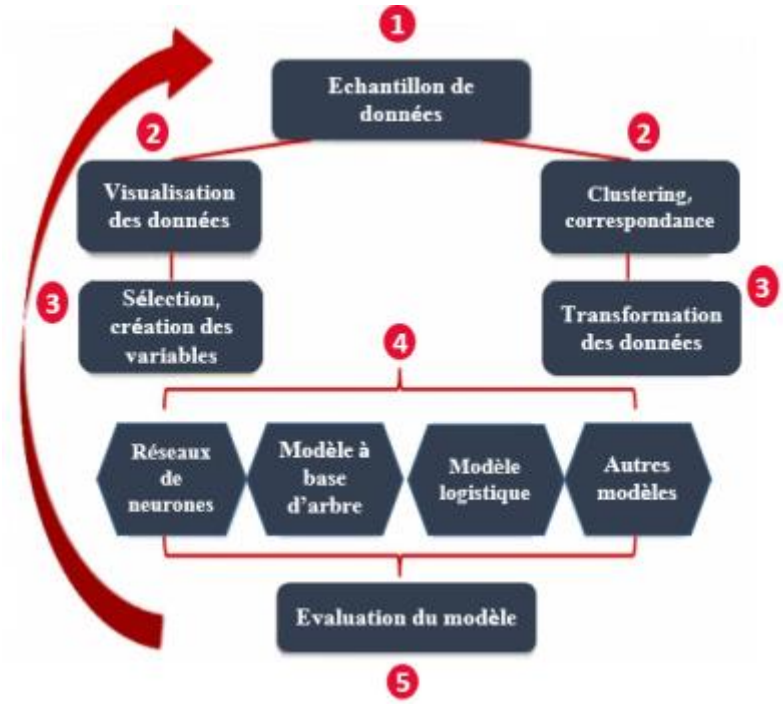

Figure A-2 : *Les étapes de la méthode SEMMA*

1. **Sample** (Echantillon des données) - extrait des échantillons d'un vaste ensemble de données, en nombre suffisamment grand pour contenir l'information importante, mais assez petit pour être manipulé rapidement.
2. **Explore** (Exploitation des données) - cette étape consiste dans l'exploration des données en recherchant les tendances et les anomalies imprévues afin de mieux comprendre les données.
3. **Modify** (Modifier) - modifie les données en créant, en sélectionnant et en transformant les variables afin de s'axer sur le processus de sélection de modèles.
4. **Model** (Modélisation) - modélise les données en permettant au logiciel de rechercher automatiquement une combinaison des données qui prédit de façon fiable le résultat souhaité. Il y a plusieurs techniques de modélisation : les réseaux de neurones, arbres de décision, modèles statistiques - l'analyse en composantes principales, l'analyse de séries temporelles, etc.
5. **Assess** (Evaluer) - évalue l'utilité et la fiabilité des résultats du processus de Data Mining et estime comment il va s'exécuter.

En évaluant les résultats obtenus à chaque étape du processus de SEMMA, nous pouvons déterminer la façon de modéliser les nouveaux problèmes déterminés par les résultats précédents, et donc de refaire la phase d'exploration supplémentaire pour le raffinement des données.

Nous présentons dans le tableau A-1, les avantages et inconvénients de chaque méthode.

Tableau A-1 : *les avantages et inconvénients de chaque méthode*

	KDD	**CRISP-DM**	**SEMMA**
Avantages	- Le processus est interactif et itératif ; - Peut traiter de grande quantité de données ; - Description technique détaillé sur l'analyse des données.	- Modèle hiérarchique ; - La séquence des phases n'est pas stricte ; - C'est la méthodologie de Data mining la plus utilisé dans l'industrie ; - A une perspective plus large sur les aspects du business ; - Est plus proche du concept réel du projet ; - Facile à comprendre ; - Très bien documenté.	On peut procéder de retour à la phase d'exploration pour un raffinement supplémentaire des données.
Inconvénients	- Omet des aspects importants dans le cadre du business ; - Parfois c'est indispensable de faire beaucoup des boucles de retours non-nécessaires ; - Les auteurs ne donnent pas assez d'information sur les itérations entre les étapes.	- Des informations limitées sur les boucles de retours ; - Le modèle a besoin d'être mis à jour.	N'inclut pas une étape explicite pour utiliser les connaissances découvertes.

Annexe B : Méthodes de conception de tableau de bord

B.1 Etapes de la méthode GIMSI

N°	Etape	Objectif
1	**Stratégie de l'entreprise**	Étude des spécificités de l'entreprise, ses produits, son management, son environnement économique et concurrentiel. Cette étape se déroule dans une logique d'examen en perspective de la démarche stratégique engagé.
2	**Processus de l'entreprise**	Étude approfondie des métiers de l'entreprise et de ses activités afin d'identifier les processus critiques, cibles de projet.
3	**Objectifs de performance**	Identification des objectifs tactiques, une tâche réalisée en coopération avec les décideurs.
4	**Conception du tableau de bord**	Comprendre les principes du tableau de bord de pilotage afin de concevoir un instrument d'aide à la décision efficace.
5	**Indicateurs de performance**	Identification des indicateurs de performance, une tâche réalisée en coopération avec les décideurs.
6	**Collecte des données**	Recherche et collecte des informations indispensables pour le tableau de bord de pilotage.
7	**Système de tableaux de bord**	Étude des interactions entre les tableaux de bord, contrôle de la cohérence globale.
8	**Outils de Business Intelligence**	Étude des besoins technologiques en matière de Business Intelligence, application d'une méthode de choix des outils BL.
9	**Déploiement de la solution**	Déploiement et mise en œuvre de la solution sur le terrain.
10	**Audit du système BI**	Vérification périodique de la parfaite adéquation entre le système de pilotage et les besoins exprimés.

B.2 Etapes de la méthode BSC

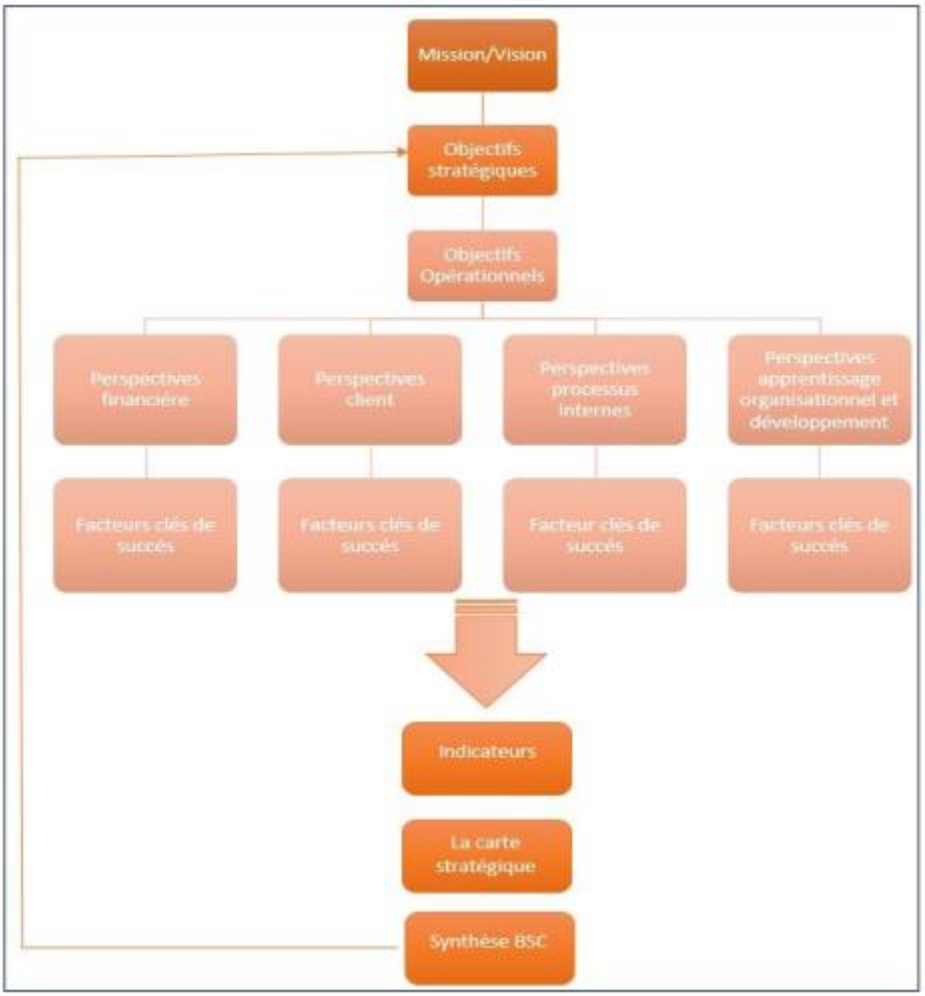

Figure B-1 : *Les étapes de la méthode BSC*

La démarche que nous avons suivie passe principalement par trois phases :

Phase 1 : Etablissement de la vision et les orientations stratégiques

Le point de départ de l'élaboration du Balanced Scorecard est la mission, la vision et la stratégie. Ensuite il est primordial de déterminer les objectifs stratégiques et opérationnels de l'entreprise et ceci pour chaque perspective.

Phase 2 : Identification des facteurs clés de succès et choix des indicateurs

La définition des facteurs clés de succès est l'un des éléments les plus décisifs dans notre démarche de construction de la BSC cible. L'objectif est de définir les variables d'action primordiales que les décideurs de l'entreprise doivent suivre de près car leur évolution conditionne l'atteinte des objectifs que la structure s'est assigné, Ces FCS sont identifiés grâce à la démarche SWOT et les 5 forces de M.Porter.

Phase 3 : Etablissement de la carte stratégique et canevas BSC

Selon les concepteurs de la méthode Kaplan et Norton, nous allons proposer à l'entreprise un diagramme pour chaque objectif stratégique.

B.3 Analyse comparative des méthodes GIMSI et BSC

Dans ce qui suit, nous allons présenter une analyse comparative entre les deux méthodes de GIMSI et BSC.

Tableau B-1 : *analyse comparative des méthodes GIMSI et BSC.*

Méthode	Avantages	Inconvénients
Le Balanced Scorecard [Kaplan et Norton, 1992, 1996, 2000]	- Une démarche qui lie les 4 perspectives pour la réussite de l'objectif financier afin d'assurer la pérennité de l'entreprise. - Présente une vision complète et globale de la performance concise et facile à comprendre par les utilisateurs. - Bien structurée et bien centralisée. - Aide les décideurs à se concentrer sur les indicateurs citriques.	- Conçu pour fournir aux hauts dirigeants une vue globale de la performance et donc n'est pas destiné et n'est pas applicable aux niveaux opérationnels d'entreprise. - Ne tient pas compte des autres parties prenantes (les concurrents, les fournisseurs et autres).
Le GIMSI [A. Fernandez, 2013]	- Axé surtout sur l'aide à la décision pour un pilotage performant. - Dispose d'une démarche méthodologique pour la conception et l'implémentation des indicateurs de performance. - Focaliser sur l'amélioration permanente.	- Ne peut pas proposer des indicateurs de performance génériques car le système conseille aux utilisateurs de ne pas se fier aux indicateurs génériques et prédéfinis.

Annexe C : les différentes mesures d'évaluation

C.1 Les différents coefficients de corrélation :

Le coefficient de corrélation de "Pearson" mesure une corrélation linéaire entre deux variables. Dans le cas où la méthode utilisée est de type "Kendall" ou "Spearman", les statistiques tau de Kendall et rho de Spearman sont respectivement utilisées pour estimer le coefficient de corrélation basé sur le rang. Ce sont des tests statistiques dits robustes car ils ne dépendent pas de la distribution des données.

Nous présentons ci-dessous les formules de ces trois coefficients :

- **Corrélation de Pearson**

$$r = \frac{\sum(x - m_x)(y - m_y)}{\sqrt{\sum(x - m_x)^2 \sum(y - m_y)^2}}$$

x Et y sont des vecteurs de longueur n.
m_x Et m_y correspondent respectivement aux moyennes de x et y.

- **Corrélation de Kendall**

$$rho = \frac{\sum(x' - m_{x'})(y'_i - m_{y'})}{\sqrt{\sum(x' - m_{x'})^2 \sum(y' - m_{y'})^2}}$$

$x' = rank(x)\ Et\ y' = rank(y)$

- **Corrélation de Spearman**

$$Tau = \frac{n_c - n_d}{\frac{1}{2}n(n-1)}$$

n_c : nombre total des paires concordantes
n_d : nombre total des paires discordantes
n : taille de x et y

C.2 Les différents indices d'évaluation du clustering :

1. L'indice de Davies-Bouldin (DB)

L'indice de Davis-Bouldin [30]traite chaque classe individuellement et cherche à mesurer à quel point elle est similaire à la classe qui lui est la plus proche. L'indice DB est formulé de la façon suivante :

$$DB = \frac{1}{n}\sum_{i=1}^{n} \max_{j \neq i}\left\{\frac{I(c_i) + I(c_j)}{I(c_i, c_j)}\right\}$$

Pour chaque classe i de la partition, on cherche la classe j qui maximise l'indice de similarité décrit comme suit :

$$R_{ij} = \frac{I(c_i) + I(c_j)}{I(c_i, c_j)}$$

$I(c)$ Représente la moyenne des distances entre les clients appartenant à la classe c_i et son centre. Et $I(c_i, c_j)$ représente la distance entre les centres des deux classes c_i et c_j. La meilleure partition est donc celle qui minimise la moyenne de la valeur calculée pour chaque classe. En d'autres termes, la meilleure partition est celle qui minimise la similarité entre les classes.

2. L'indice Silhouette

L'indice de Silhouette [31]est différent, des indices de qualité traités ci-dessus ; il travaille à l'échelle microscopique, c'est à dire qu'il s'intéresse aux clients en particulier et non pas aux classes. Le but de Silhouette est de vérifier si chaque client a été bien classé. Pour cela, et pour chaque client i de la partition, on calcule la valeur suivante :

$$-1 \leq S(i) = \frac{b(i) - a(i)}{max\{a(i), b(i)\}} \leq 1$$

$a(i)$ Représente la distance moyenne qui le sépare des autres clients de la classe à laquelle il appartient et $b(i)$ représente la distance moyenne qui le sépare des clients appartenant à la classe la plus proche.

Quand $S(i)$ est proche de 1, le client est bien classé : la distance qui le sépare de la classe la plus proche est très supérieure à celle qui le sépare de sa classe. Par contre, si $S(i)$ est proche de -1, cela veut dire que le client est mal classé. Mais si $S(i)$ est proche de 0 alors il pourrait également être classé dans la classe la plus proche. L'indice Silhouette de la partition est calculé à partir de la moyenne entre les indices de ses éléments.

C.3 Les mesures d'évaluation de la performance d'un modèle prédictifs

Les *faux positifs* et les *faux négatifs* sont deux concepts importants dans la mesure de performances de la classification. On parle de faux négatif quand le résultat du test indique que le fait étudié est négatif alors que dans la réalité, celui-ci est positif. Par analogie, on dit d'un test que le fait est faux positif s'il indique qu'un cas est positif alors que ce dernier est négatif.

Nous introduisons donc la matrice de confusion représentée ci-dessous qu'on peut générer pour chacune des classes.

Tableau C-1 : *Table de confusion*

		Prédiction	
		Positive	**Négative**
Réalité	**Positive**	TP	FN
	Négative	FP	TN

1. **Précision**

La précision mesure le ratio du churn correctement prédits par le modèle dans une classe donnée par rapport au nombre total de clients assignés à cette même classe par le modèle. Une précision est calculée pour chaque classe selon la formule suivante :

$$Précision = \frac{Nombre\ de\ clients\ correctement\ prédits}{Nombre\ de\ clients\ appartenant\ \text{à}\ la\ classe}$$

Pour simplifier les formules, nous utilisons les données de la table de confusion. La précision se calcule donc comme suit :

$$Précision = \frac{TP}{TP + FP}$$

2. **Rappel**

Le rappel mesure le ratio des clients correctement assignés à une classe par rapport au nombre total de documents que comporte cette même classe. De la même manière que pour la précision, un rappel est calculé pour chaque classe de la manière suivante :

$$Rappel = \frac{Nombre\ de\ clients\ correctement\ prédits}{Nombre\ total\ de\ clients\ appartenant\ \text{à}\ la\ classe}$$

De même que pour la précision, nous simplifions la formule du rappel comme suit :

$$Rappel = \frac{TP}{TP + FN}$$

Le rappel et la précision sont des mesures qui sont très souvent considérés ensemble pour évaluer un classifieur. En effet ces deux dernières sont très liées car elles sont inversement proportionnelles, nous pouvons parvenir à une haute précision en ne classant que quelques échantillons pour lesquels nous avons une forte confiance. Dans ce cas, le rappel diminue à mesure que nous perdons de nombreux échantillons pertinents. De même, nous pouvons

marquer tous les échantillons comme positifs, ainsi la réalisation d'un rappel élevé, mais la réduction de la précision. En général, un système équilibré est le meilleur choix avec une précision et un rappel relativement élevé.

3. F-Mesure

La F-Mesure est une mesure qui combine la précision et le rappel selon la formule suivante :

$$F - Mesure = 2\frac{Précision * Rappel}{Précision + Rappel}$$